

# Introduction to Philosophy



Department of Philosophy  
Central South University  
[xieshenlixi@163.com](mailto:xieshenlixi@163.com)  
[github](#)

October 9, 2026

# Contents

1. Introduction

2. 逻辑与论证

3. 形而上学

4. 认识论

5. 伦理学

6. 美学

7. 科学哲学

8. 心灵哲学

9. 语言哲学

10. 博弈与社会

▶ 以什么心态学哲学？

- ▶ 以什么心态学哲学?
- ▶ 哲学不是用来学的, 是用来做的.

- ▶ 以什么心态学哲学?
- ▶ 哲学不是用来学的, 是用来做的.
- ▶ 输赢看淡, 不服就干!

- ▶ 以什么心态学哲学?
- ▶ 哲学不是用来学的, 是用来做的.
- ▶ 输赢看淡, 不服就干!
- ▶ 往深了干!  
— “严肃性和深度是解压的最好方式.”

— 项飙

你有哪些感兴趣的“哲学”问题？

# 哲学问题

一只蝌蚪希望自己变成青蛙吗？

- ▶ 形而上学: 存在什么? (例如蝌蚪、物质的东西、心理状态、关系, 实体与关系哪个更基本?)
- ▶ 认识论: 我们能知道什么? 如何知道? 我们能知道我们自己的/他人的/蝌蚪的心理吗?
- ▶ 心灵哲学: 什么是心理状态、心理过程? 一堆物质是否足以涌现出心理状态? 希望变青蛙是目标导向的 Agency 吗?
- ▶ 逻辑学: 我们应该如何思考? 决策?
- ▶ 伦理学: 我们 (不) 应该做什么? 我们是否有权让蝌蚪痛苦?
- ▶ 科学哲学: 蝌蚪希望变青蛙, 有因果解释吗? 可测量证伪吗? 什么是科学理论? 模型? 解释? 证据? 新概念的提出与新理论的构建之间是什么关系?
- ▶ 概念分析: 我们所说的  $x$  是什么意思? 说一只蝌蚪“希望” 是什么意思? AI“希望” 优化自己的目标函数吗?
- ▶ ...



## 带着问题探索

1. 下面哪种东西最“真实”——你所坐的椅子？构成这张椅子的分子？椅子有四条腿的“4”？还是你坐在上面的感觉？还是“你”（“自我”）？
2. 你相信宇宙有目的吗？
3. 如何看待“事实”与“价值”的二分？
4. 怎么证明你不是“缸中之脑”？
5. 你相信万事皆有因吗？
6. 刚出生的婴儿是否具有自由意志？
7. 如果有一个你知道你一旦进去就快乐到不愿意出来的“快乐箱”，你愿意进去吗？
8. 什么使得昨天的你和今天的你是同一个“你”？
9. 如果你的意识被上传到云端，那个“你”还是你吗？
10. 你怎么看待“知识”和“信念”之间的关系？
11. 语词的意义能从纯粹的句法形式中涌现吗？
12. “科学”与“非科学”之间有明确的界限吗？
13. 你是否认为有原则上永远不可知的问题？
14. 有没有某种你愿意为之付出生命的东西？
15. 你是否认同“追求真理可以不计利害”？
16. 如果撒谎可以救一个无辜的人，你会撒谎吗？

# 什么是哲学？

- ▶ 爱智慧
- ▶ 亚里士多德：哲学是研究“作为存在的存在”，以及属于它的本质属性的科学。
- ▶ 康德：哲学是理性批判的体系，它最终归结为回答四个问题：1. 我能知道什么？2. 我应该做什么？3. 我可以希望什么？4. 人是什么？
- ▶ 马克思：哲学是时代精神的精华。
- ▶ 维特根斯坦：哲学的目的在于思想的逻辑澄清。
- ▶ 罗素：哲学是介于神学与科学之间的无人区。
- ▶ 德勒兹：哲学是创造概念的艺术。
- ▶ 冯友兰：哲学就是对于人生有系统的反思。

# 哲学有哪些主要分支？

- ▶ 形而上学
- ▶ 认识论
- ▶ 逻辑学
- ▶ 伦理学
- ▶ 美学
- ▶ 科学哲学
- ▶ 心灵哲学
- ▶ 语言哲学
- ▶ 数学哲学
- ▶ 逻辑哲学
- ▶ 政治哲学
- ▶ 宗教哲学
- ▶ ...

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

## Why Study Logic?

- ▶ 最高的幸福, 在于 “完满性” 的最大可能的增加.
- ▶ “完满” 这种得到增强后的状态, 它超越 “健康” 的程度, 就如同 “疾病” 低于 “健康” 的程度一样.
- ▶ 正如 “疾病” 在于官能的损伤, “完满” 在于官能的增强.
- ▶ 人的官能中, 最有力的是思维能力.
- ▶ 思维能力可以通过身体的治疗或心灵的治疗加以增强.
- ▶ 心灵的疗方, 在于采用特定的思维方法, 凭借这种思维方法, 其他的思考得以变得容易起来.


— 莱布尼茨《论思想的工具或大衍术》

Don't argue. Let us calculate!

# Contents

1. Introduction
2. 逻辑与论证  
Toy Logic  
穆勒五法  
类比/归纳/溯因  
谬误与扯淡
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

- ▶ 什么是“真”? 有效?
- ▶ 什么是“证明”?
- ▶ 所有有效论证都可以被证明吗?
- ▶ 所有真理都可以被证明吗?
- ▶ 什么是“理论”?
- ▶ 什么是“模型”?
- ▶ 你会关心理论的哪些性质?





# 一个超级简单的 Toy Logic

► **语法:** 符号集  $\text{Var} = \{X, Y, \dots\}$ , 公式  $\text{All}(X, Y)$

► **语义:** 结构  $\mathcal{M} := (M, \llbracket \cdot \rrbracket)$ , 其中  $\llbracket X \rrbracket \subset M$

$$\mathcal{M} \models \text{All}(X, Y) \quad \text{当且仅当} \quad \llbracket X \rrbracket \subset \llbracket Y \rrbracket$$

► **逻辑蕴涵:**  $\Gamma \models \varphi$  当且仅当对任意结构  $\mathcal{M}$ : 若  $\mathcal{M} \models \Gamma$  则  $\mathcal{M} \models \varphi$

► **形式系统:**

$$\frac{\text{All}(X, Y) \quad \text{All}(Y, Z)}{\text{All}(X, Z)} \qquad \frac{}{\text{All}(X, X)}$$

► **证明:**  $\Gamma \vdash \varphi$  当且仅当存在一棵以  $\varphi$  为“根”节点的有穷“树”, 其每一节点或是公理或属于前提  $\Gamma$ , 或通过推理规则由前面的节点生成

► **例子:** 怎么证明  $\text{All}(A, B), \text{All}(B, C), \text{All}(C, D) \vdash \text{All}(A, D)$

$$\frac{\frac{\text{All}(A, B) \quad \text{All}(B, C)}{\text{All}(A, C)} \quad \text{All}(C, D)}{\text{All}(A, D)}$$

► **元定理:** 能推出的都有效? 有效的都能推出?  $\Gamma \vdash \varphi \iff \Gamma \models \varphi$

► **思考一下:** 怎么证明推不出?  $\text{All}(A, B) \not\models \text{All}(B, A)$

形式语言

语义

模型

$\text{All}(A, B), \text{All}(B, C) \xrightarrow{\text{证明}} \text{All}(A, C)$

语义

语义

$\llbracket A \rrbracket \subset \llbracket B \rrbracket, \llbracket B \rrbracket \subset \llbracket C \rrbracket \xrightarrow{\text{蕴含}} \llbracket A \rrbracket \subset \llbracket C \rrbracket$

## Theorem (Toy Logic 的可靠性定理 )

$$\Gamma \vdash \varphi \implies \Gamma \models \varphi$$

### Proof.

对证明树  $\Gamma \vdash \varphi$  线性排列, 对其证明长度应用数学归纳法.

- ▶ 长度为 1:  $\varphi \in \Gamma$  或  $\varphi$  是公理  $\text{All}(X, X)$  的特例. 显然  $\Gamma \models \varphi$ .
- ▶ 假设证明长度不超过  $n$  时都有  $\Gamma \vdash \varphi \implies \Gamma \models \varphi$ , 下证长度为  $n + 1$  时也成立.

第  $n + 1$  步或是公理或属于前提或由推理规则得到.

若由推理规则  $\frac{\text{All}(X, Y) \quad \text{All}(Y, Z)}{\text{All}(X, Z)}$  得到, 由归纳假设,  $\Gamma \models \text{All}(X, Y)$  且  $\Gamma \models \text{All}(Y, Z)$ .

即  $\llbracket X \rrbracket \subset \llbracket Y \rrbracket$  且  $\llbracket Y \rrbracket \subset \llbracket Z \rrbracket$ .

所以  $\llbracket X \rrbracket \subset \llbracket Z \rrbracket$ , 即  $\Gamma \models \text{All}(X, Z)$ .

**Remark:** 公理有效, 推理规则保真

## Theorem (Toy Logic 的完备性定理 )

$$\Gamma \models \varphi \implies \Gamma \vdash \varphi$$

### Proof.

- 不妨证其逆否命题: 假设  $\Gamma \not\models \varphi$ , 往证  $\Gamma \not\vdash \varphi$ , 即, 找一个结构  $\mathcal{M}$ , 使得  $\mathcal{M} \models \Gamma$  但  $\mathcal{M} \not\models \varphi$ .
- 令  $\mathcal{M}^\Gamma := (\mathcal{M}, \llbracket \cdot \rrbracket)$ , 其中

$$\mathcal{M} := \text{Var}, \quad \llbracket X \rrbracket := \{Y : \Gamma \vdash \text{All}(Y, X)\}$$

1. 检查  $\mathcal{M}^\Gamma \models \Gamma$ .

任给  $\text{All}(A, B) \in \Gamma$ , 根据  $\llbracket A \rrbracket, \llbracket B \rrbracket$  的定义和 
$$\frac{\text{All}(Y, A) \quad \text{All}(A, B)}{\text{All}(Y, B)},$$
 可得  $Y \in \llbracket A \rrbracket \implies Y \in \llbracket B \rrbracket$ , 即  $\mathcal{M}^\Gamma \models \text{All}(A, B)$ .

2. 检查  $\mathcal{M}^\Gamma \not\models \varphi$ . (往证:  $\mathcal{M}^\Gamma \models \varphi \implies \Gamma \vdash \varphi$ , 从而与假设  $\Gamma \not\models \varphi$  矛盾)  
假设  $\varphi = \text{All}(A, B)$ , 若  $\mathcal{M}^\Gamma \models \varphi$ , 则  $\llbracket A \rrbracket \subset \llbracket B \rrbracket$ .  
即, 对任意  $Y, Y \in \llbracket A \rrbracket \implies Y \in \llbracket B \rrbracket$ .

因为  $\text{All}(A, A)$ , 所以  $A \in \llbracket A \rrbracket$ . 从而  $A \in \llbracket B \rrbracket$ . 因此  $\Gamma \vdash \varphi$ .

# 让语言表达力更丰富一点儿?

- ▶ **语法:**  $All(X, Y)$ ,  $Some(X, Y)$ ,  $All(X, \bar{Y})$ ,  $Some(X, \bar{Y})$ ,  $Most(X, Y)$
- ▶ **语义:** 结构  $\mathcal{M} := (M, \llbracket \cdot \rrbracket)$ , 其中  $\llbracket X \rrbracket \subset M$ ,  $\llbracket \bar{X} \rrbracket = M \setminus \llbracket X \rrbracket$

$\mathcal{M} \models Some(X, Y)$  当且仅当  $\llbracket X \rrbracket \cap \llbracket Y \rrbracket \neq \emptyset$

$\mathcal{M} \models Most(X, Y)$  当且仅当  $|\llbracket X \rrbracket \cap \llbracket Y \rrbracket| > |\llbracket X \rrbracket \setminus \llbracket Y \rrbracket|$

- ▶ **形式系统:**

$$\frac{Some(X, Y)}{Some(Y, X)} \quad \frac{Some(X, Y)}{Some(X, X)} \quad \frac{All(X, \bar{Y})}{All(Y, \bar{X})}$$

$$\frac{Some(X, Y) \quad All(Y, Z)}{Some(X, Z)} \quad \frac{All(X, Y) \quad Some(X, Z)}{Some(Y, Z)}$$

$$\frac{Most(X, Y)}{Some(Y, X)} \quad \frac{Some(X, X)}{Most(X, X)} \quad \frac{Most(X, Y) \quad All(Y, Z)}{Most(X, Z)}$$

$$\frac{Most(X, Z) \quad All(X, Y) \quad All(Y, X)}{Most(Y, Z)} \quad \frac{All(Y, X) \quad All(X, Z) \quad Most(Z, Y)}{Most(X, Y)}$$

# 命题逻辑 & 谓词逻辑 & 模态逻辑

|                   |           |
|-------------------|-----------|
| $\neg$            | 非         |
| $\wedge$          | 与         |
| $\vee$            | 或         |
| $\rightarrow$     | 如果.....那么 |
| $\leftrightarrow$ | 当且仅当      |
| $\forall$         | 所有        |
| $\exists$         | 存在        |
| $\Box$            | 必然        |
| $\Diamond$        | 可能        |


$$\forall x \left( \text{Event}(x) \rightarrow \Box \exists y [\text{Event}(y) \wedge \text{Cause}(y, x)] \right)$$

万事必有因.

# 逻辑求真

“真”为逻辑指引方向, 正如“美”为美学、“善”为伦理指引方向.  
— 弗雷格

形式与内涵的  
分离与统一



数理逻辑是先于一切科学的科学, 包含着位于一切科学底层的观念和原理.

— 哥德尔

一个概念是“逻辑”的, 当且仅当, 它对“论域”到自身的所有可能的——变换都保持不变.

— 塔斯基

## 思考一下

1. 什么是“语法”/“语义”?
2. 什么是“对象语言”/“元语言”?
3. 什么是“满足”?
4. 什么是“真”?
5. 什么是“有效命题”/“有效论证”?
6. 什么是“形式系统”?
7. 什么是“定理”?
8. 什么是“证明”?
9. 什么是“理论”?
10. 什么是“可 (有穷) 公理化”?
11. 什么是“结构”? “模型”?
12. 什么是“一致”?
13. 什么是“可靠”? “完备”?
14. 什么是“紧致”?
15. 什么是“定义”?
16. 什么是“表示”?
17. 什么是“归纳”/“递归”?
18. 什么是“有穷”/“无穷”?
19. 什么是“可数”/“不可数”?
20. 什么是“可判定”?
21. 什么是“计算复杂性”?
22. 什么是“表达力”?
23. 什么是“简洁性”?
24. 什么是“可解释性”?
25. 什么是“同态”?
26. 什么是“同构”?
27. 什么是“初等等价”?
28. 什么是“范畴性”?



# Contents

1. Introduction
2. 逻辑与论证
  - Toy Logic
  - 穆勒五法
  - 类比/归纳/溯因
  - 谬误与扯淡
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

## 简单枚举归纳

- ▶ 我们都是瞎子.
- ▶ 吝啬的人是瞎子, 他只看见金子看不见财富.
- ▶ 挥霍的人是瞎子, 他只看见开端看不见结局.
- ▶ 卖弄风情的女人是瞎子, 她看不见自己脸上的皱纹.
- ▶ 有学问的人是瞎子, 他看不见自己的无知.
- ▶ 诚实的人是瞎子, 他看不见坏蛋.
- ▶ 坏蛋是瞎子, 他看不见上帝.
- ▶ 上帝也是瞎子, 他在创造世界的时候, 没有看到魔鬼也跟着混进来了.
- ▶ 我也是瞎子, 我只知道说啊说啊, 没有看到你们全都是聋子.

# 求同法

$$ABC \rightarrow xyz$$

$$ADE \rightarrow xuv$$

$$\hline A \rightarrow x$$


|    | 缺碘 | 职业 | 年龄 | 甲状腺 |
|----|----|----|----|-----|
| 张三 | 缺  | 工人 | 老年 | 肿大  |
| 李四 | 缺  | 农民 | 中年 | 肿大  |
| 王五 | 缺  | 士兵 | 青年 | 正常  |

缺碘  $\rightarrow$  甲状腺肿大

甲状腺肿大人群的相同点是缺碘  
缺碘是肿大的“必要”条件

|    |     |     |    |
|----|-----|-----|----|
| 泡脚 | 看小说 | 喝浓茶 | 失眠 |
| 泡脚 | 看电视 | 抽烟  | 失眠 |
| 泡脚 | 听音乐 | 喝咖啡 | 失眠 |

泡脚  $\rightarrow$  失眠



# 求异法

$$ABC \rightarrow xyz$$

$$\overline{ABC} \rightarrow \overline{x}yz$$

$$\hline A \rightarrow x$$

|     |    |    |    |      |
|-----|----|----|----|------|
| 冰激凌 | 沙拉 | 面包 | 牛奶 | 肚子疼  |
| 酸奶  | 沙拉 | 面包 | 牛奶 | 肚子不疼 |

冰激凌  $\rightarrow$  肚子疼

吃了冰激凌的人肚子疼  
肚子不疼的人没吃冰激凌  
冰激凌是肚子疼的“充分”条件

|     |     |
|-----|-----|
| 上课  | 头疼  |
| 不上课 | 头不疼 |

上课  $\rightarrow$  头疼

上课  $\longrightarrow$  戴眼镜  $\longrightarrow$  头疼



取健康的蜘蛛, 大吼一声, 蜘蛛被吓跑了  
砍掉蜘蛛的腿, 大吼一声, 蜘蛛纹丝不动

---

蜘蛛的听觉器官长在腿上. 😞

秋末冬初街道旁的响叶杨纷纷落叶, 但高压水银灯下的响叶杨却迟迟不落叶, 因此, 高压水银灯照射可能是响叶杨落叶迟的原因.

# 求同求异共用法

$$ABC \rightarrow xyz \quad ABC \rightarrow xyz$$

$$ADE \rightarrow xuv \quad \overline{ABC} \rightarrow \overline{xyz}$$


---


$$A \rightarrow x$$

| 动物 | 纲  | 环境 | 形态                                                                                |
|----|----|----|-----------------------------------------------------------------------------------|
| 鲨鱼 | 鱼纲 | 海  |  |
| 鱼龙 | 爬行 | 海  |  |
| 鲸鱼 | 哺乳 | 海  |  |
| 鼯鼠 | 哺乳 | 陆  |  |
| 蝙蝠 | 哺乳 | 空  |  |

达尔文: 环境  $\rightarrow$  形态

|    | 咖啡 | 嗦粉 | 熬夜           | 看书 | 肚子疼 |
|----|----|----|--------------|----|-----|
| 张三 | ●  | ●  | ●            | ●  | ●   |
| 李四 | ●  |    | ●            |    | ●   |
| 王五 |    | ●  |              | ●  |     |
| 赵六 |    |    | <div>●</div> | ●  |     |

## 剩余法

$$\begin{array}{lcl} ABC \rightarrow xyz & & ABC \rightarrow x \\ B \rightarrow y & & B \not\rightarrow x \\ C \rightarrow z & & C \not\rightarrow x \\ \hline A \rightarrow x & & A \rightarrow x \end{array}$$

受其他行星吸引, 天王星运行轨道上有四个地方发生偏斜  
三个地方偏斜是已知行星吸引的结果

剩余一个地方偏斜是未知行星吸引的结果 (发现海王星)

|    | 咖啡 | 嗦粉 | 熬夜 | 看书 | 疲惫 | 肚子疼 |
|----|----|----|----|----|----|-----|
| 张三 | •  | •  | •  | •  | •  | •   |
| 李四 | •  |    | •  |    | •  | •   |
| 王五 |    | •  |    | •  |    |     |
| 赵六 |    |    | •  | •  | •  |     |

**Remark:** 预设了一个原因确定一个结果; 原因彼此独立; 结果彼此独立;  
所有可能的原因已知; 所有其它结果的原因已知.

# 共变法

$$ABC \rightarrow xyz$$

$$A^{\uparrow}BC \rightarrow x^{\uparrow}yz$$

$$A^{\downarrow}BC \rightarrow x^{\downarrow}yz$$


$$\hline A \rightarrow x$$

## Example


热胀冷缩、体温表

**禁烟人士** 抽烟越多越容易患肺癌，所以抽烟是导致肺癌的重要原因。


**烟草公司** 某种基因是导致人们容易抽烟和容易得肺癌的共同原因。



# Simpson's Paradox



**Figure:** Exercise appears to be beneficial in each age group but harmful in the population as a whole. — Older people exercise more.



$$\mathbb{E}[\text{cholesterol} \mid \text{exercise}] > \mathbb{E}[\text{cholesterol} \mid \text{no exercise}]$$

$$\mathbb{E}[\text{cholesterol} \mid \text{do}(\text{exercise})] < \mathbb{E}[\text{cholesterol} \mid \text{do}(\text{no exercise})]$$



# Contents

1. Introduction
2. 逻辑与论证
  - Toy Logic
  - 穆勒五法
  - 类比/归纳/溯因
  - 谬误与扯淡
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

## Example

### 古龙《九月鹰飞》

- ▶ 叶开忍不住又道：“你为什么还是戴着这草帽？”
- ▶ 墨九星道：“因为外面有狗在叫。”
- ▶ 叶开怔了怔，道：“外面有狗叫，跟你戴草帽又有什么关系？”
- ▶ 墨九星冷冷道：“我戴不戴草帽，跟你又有什么关系？”

## Example

### 庄子《齐物论》

不知周之梦为蝴蝶与，蝴蝶之梦为周与？




### 神秀 vs 慧能

神秀：身是菩提树，心如明镜台，时时勤拂拭，勿使惹尘埃。

慧能：菩提本无树，明镜亦非台，本来无一物，何处染尘埃？

# 类比论证




1. 类比物  $abc$  与目标物  $d$  的相似属性  $XY$  越多, 论证越强.
2. 相似属性  $XY$  与推出属性  $Z$  之间越相关, 论证越强.
3. 类比物  $abc$  与目标物  $d$  的相似属性  $XY$  越本质, 论证越强.
4. 类比物  $abc$  数量越多, 论证越强.
5. 类比物  $abc$  的差异性越大, 论证越强.
6. 类比物  $abc$  与目标物  $d$  的非相似属性  $PQ$  与  $XYZ$  的相关程度, 可能削弱或加强论证.
7. 结论越具体, 论证越弱.

## Example

### Argument by Analogy

有妻杀夫, 放火烧舍, 称“火烧夫死”. 夫家疑之, 讼于官. 妻不服. 取猪两头, 杀其一. 积薪焚之, 活者口中有灰, 杀者口中无灰. 因验尸, 口果无灰, 鞠之服罪.



## Example


### Argument by Analogy

人们似乎经常相信创造力, 但它所做的只不过是把对象的分界线确定下来, 并赋予它一个名字. 正如地理学家划出海岸线并说“这些线确定的海域为黄海”, 此时他并未创造一个海; 数学家也一样, 他不能通过定义创造东西.

— 弗雷格

### Refutation by Analogy

- ▶ 性教育导致怀孕.
- ▶ 是的, 正如驾驶教育导致车祸. 😞



# Example


## Argument by Analogy

不能要求每样东西都有定义, 否则如同要求任何物质都可被分解. 简单物质不能被分解, 逻辑上简单的东西不能被定义.

— 弗雷格


## Refutation by Analogy

- ▶ 计算机会思考吗?
- ▶ 潜水艇会游泳吗?



## Refutation by Analogy


- ▶ 机器不可能超越人脑, 因为, 机器是建立在固体物理学之上的, 而人脑是一个活的半流体系统.
- ▶ 汽车不可能代替马, 因为, 汽车是钢铁铸成的, 而马是活的血肉构成的有机体.






## Examples — “上帝存在吗?”

### Argument by Analogy



### Refutation by Analogy



## 目的论/设计论证

$$P(\text{Life} \mid \text{FineTuning}) > P(\text{Life} \mid \neg \text{FineTuning})$$

假设有  $A$  的  $B$  比没有  $A$  的  $B$  更可靠  $P(B \mid A) \geq P(B \mid \neg A)$ , 则当  $B$  被证实时,  $A$  更可靠.

有  $A$  的  $B$  比没有  $A$  的  $B$  更可靠  
 $B$  被证实  
—————  
 $A$  更可靠


$$\frac{P(A)}{P(A \mid B)} = \frac{P(A)}{\frac{P(A)P(B \mid A)}{P(A)P(B \mid A) + P(\neg A)P(B \mid \neg A)}} = P(A) + P(\neg A) \frac{P(B \mid \neg A)}{P(B \mid A)} \leq 1$$

## Examples — “上帝存在吗?”

### Refutation by Analogy


- ▶ Everything must have a cause. The world must have a cause.
- ▶ Everybody has a mother. Does the human race have a mother?

## 作为桥梁的类比层级 $X$ 有时是隐藏的




## 作为桥梁的类比层级 X 有时是隐藏的

- ▶ 基督徒糕点师拒绝为同性恋制作婚礼蛋糕.
- ▶ 键盘侠: 要求基督徒糕点师为同性恋制作婚礼蛋糕正如要求犹太糕点师为纳粹制作婚礼蛋糕!



## 选择正确的“类比层级”


类比就像桥梁，可以带我们去任何地方，在选择走哪座桥时要非常小心。



“你竟然接受同性恋，是不是你还接受乱伦？”

## “类比层级”的提升 — 寻找更基本的信念

- ▶ 推广社会福利, 虽然有不需要帮助的人得到了实惠.
- ▶ 反对歧视黑人, 虽然有一小部分黑人社会地位很高.
- ▶ 癌症筛查很重要, 虽然存在误检.
- ▶ 认真对待性骚扰投诉, 虽然有人被冤枉.



# 演绎/预测/归纳/溯因/类比

1. 演绎: 保真的推理
2. 广义的归纳: 扩展性的推理?  
— 包括狭义的归纳、溯因、类比...
3. 溯因指最佳解释推理? (从假设空间中做选择 — 选择性溯因)  
— 还是需要创造新对象/假设 (创造性溯因)?
4. 预测可以还原为溯因演绎吗?
5. 类比可以还原为溯因归纳演绎吗?




# 演绎/预测/归纳/溯因/类比

1. 演绎:  $\forall n P_n \rightarrow P_k$
2. 预测:  $P_1, \dots, P_t \rightsquigarrow^? P_{t+1}$  — 过去到未来  
— 如果  $P_1, \dots, P_t$  编码的是最优 Agent 与环境的交互历史呢?
3. 归纳:  $P_1, \dots, P_t \rightsquigarrow^? \forall n P_n$  — 样本到总体
4. 溯因:  $P_1, \dots, P_t \rightsquigarrow^? \text{Hypothesis}$  — 现象到假说
5. 类比:  $A : B :: C : D$



(a) Charles Peirce




(b) David Corfield

## 前期皮尔士 Peirce: 演绎/归纳/溯因






|               |                         |          |
|---------------|-------------------------|----------|
| 这些豆子是那个袋子里的   | $A \rightarrow B$       | 假说       |
| 那个袋子里的豆子都是白的  | $B \rightarrow C$       | 背景       |
| <hr/> 这些豆子是白的 | <hr/> $A \rightarrow C$ | <hr/> 现象 |

|                    |                         |                |
|--------------------|-------------------------|----------------|
| 这些豆子是那个袋子里的        | $A \rightarrow B$       | 随机抽样           |
| 这些豆子是白的            | $A \rightarrow C$       | 样本性质[r%]       |
| <hr/> 那个袋子里的豆子都是白的 | <hr/> $B \rightarrow C$ | <hr/> 总体性质[r%] |

|                   |                         |             |
|-------------------|-------------------------|-------------|
| 这些豆子是白的           | $A \rightarrow C$       | 现象反常        |
| 那个袋子里的豆子都是白的      | $B \rightarrow C$       | 背景下“假说解释现象” |
| <hr/> 这些豆子是那个袋子里的 | <hr/> $A \rightarrow B$ | <hr/> 假说    |




# 演绎/归纳/溯因 vs Composition/Extension/Lifting<sup>1</sup>




- ▶ 演绎: 已知  $f, g$ , 求  $h$
- ▶ 归纳: 已知  $f, h$ , 求  $g$
- ▶ 溯因: 已知  $g, h$ , 求  $f$

<sup>1</sup>David Corfield: Charles Peirce, Inference, and Category Theory. 2025.

# 归纳






- ▶ 对于归纳任务来说,  $f$  通常是单射.  $A$  是  $B$  的采样, 归纳是把标签从样本  $A$  泛化到总体  $B$ .
- ▶ **最近邻分类器**: 通过 Retraction  $k : B \rightarrow A$  s.t.  $k \circ f = 1_A$  求解  $g := h \circ k$ . (解通常不唯一, 需要偏置)



$A$ : 典型的动物样本, 如 Tom & Jerry.  $B$ : 所有动物.  $C$ : 动物种类标签, 如: 猫/鼠/狗. 归纳  $g$  给所有动物分了类.



## 归纳检验



- ▶ 草地上的牛能准确分类. 把草地 PS 为海滩就分类错了.


$$P(\text{Cow} \mid \text{Image}) \neq P(\text{Cow} \mid \text{Image}, \text{do}(\text{Background} = \text{beach}))$$

- ▶ 归纳出错, 溯因弥补 (不变特征学习)




# 溯因


- ▶ 类似用 Retraction 求解归纳, 可以用 Section  $k : C \rightarrow B$  s.t.  $g \circ k = 1_C$  求解溯因  $f := k \circ h$ .



- ▶ 若  $k$  不唯一, 则溯因出的  $f$  就有多个解释, 需要进行检验, “观察数据”无法筛选时, 可能需要借助“干预数据”, 或根据某些标准从中选择, 比如最大后验  $k : c \mapsto b^* := \underset{b}{\operatorname{argmax}} P(b \mid c)$ . (需要偏置)
- ▶  $k$  既可以看作归纳  $g$  的逆, 也可以看作溯因 lift.




# 溯因检验



- ▶ 溯因出“这些豆子是那个袋子里的”
- ▶ 又已知“那个袋子里的豆子都是大的”
- ▶ 检验是否“这些豆子是大的”




## 溯因：选择性溯因 vs 创造性溯因



- ▶ 左图: 溯因-演绎  $\leadsto$  预测 (为了解释为什么预测靠谱, 溯因出月相变化的原因是日/地/月的相对位置)
- ▶ 右图: 溯因创造概念解释 (溯因出  $B$  和  $C$  的共同原因是  $A$ )
  - ▶  $f: A \rightarrow B$  相对位置决定月相的几何光学.
  - ▶  $h: A \rightarrow C$  相对位置决定潮汐的万有引力.
- ▶ **问题:** 溯因是 (1) 选择最佳解释? 还是需要 (2) 创造新对象?
  1. 选择性溯因
  2. 创造性溯因




# 不仅溯因能创造新对象




1. 分解 factorization 创造新对象.
2. 极限 limit 创造新对象. — 溯因
3. 余极限 colimit 创造新对象. — 归纳

— 比如, 开普勒从第谷有限离散观测样本, 粘合出连续的椭圆轨道




## 溯因：歧义笑话




Time flies like an arrow; fruit flies like a banana.

- ▶  $A$ : 多元词组, 比如 [fruit, flies, like, a, banana].
- ▶  $C$ : 句子.
- ▶  $B$ : 语法树.
- ▶  $h$ : 把多元词组线性拼接成句子.
- ▶  $g$ : 把语法树压平成句子.
- ▶  $f$ : 给多元词组解析出合适的语法树.

# 溯因：观察渗透理论




$$\frac{B \rightarrow C \quad \top \rightarrow C}{\top \rightarrow B}$$



- ▶  $C$ : 观察空间 ( $C := O^I$  以  $I$  索引的观察数据流)
- ▶  $B$ : 假设空间
- ▶  $h$ : “虎头-树-虎尾”视觉影像
- ▶  $f$ : 一只老虎在树后
- ▶  $g$ : 向视网膜的投影
- ▶ 柏拉图洞穴隐喻: 通过溯因, 从影子 lift 到世界模型


# 预测 = 演绎 ◦ 溯因 (溯因 → 演绎 → 归纳)

后期皮尔士: “归纳 = 预测检验 + 假说确证” — 自我纠错的渐进过程



- ▶ LLM 把原本真实世界中进行的“溯因-演绎-检验-确证-溯因”的自我纠错探究循环内化到了思维链推理过程中.
- ▶ LLM 测试时计算 (test-time compute) 之所以有效, 主要因为“(通过内省或验证器) 核验比生成答案容易”, 通过“多次采样-评估-选择”, 可以提高命中率.

## 预测 (演绎 ◦ 溯因) vs 决策 (规划 ◦ 溯因)



- ▶ 如果知道隐状态  $S$ , 则可以规划最优行动  $g : S \rightarrow A$ .  
 $a^* = \operatorname{argmax}_a U(s, a)$ .
- ▶ 但隐状态不可见. 我们只能获得观察证据  $O$ , 然后基于  $O$  做出决策  $h : O \rightarrow A$ .
- ▶ 我们希望决策  $h$  尽量逼近最优, 通常以期望效用最大化  
 $a^* = \operatorname{argmax}_a \sum_s P(s \mid o, \operatorname{do}(a)) U(s, a)$  的方式, 希望三角形尽量交换


$$h \approx g \circ f$$

# 预测 vs 机器学习


## 1. ML as a black box (correlation)





## 2. ML as a Prediction/Induction box (static model)



## 3. ML as an Abduction Algorithm (dynamic process)




# 溯因无解：大模型幻觉



- ▶ 模型  $C$  是实在  $B$  的投影. 影子超出实在即幻觉.
- ▶  $D$  是一个小区间,  $A$  是  $D$  的延拓.  $B$  是真实情况,  $C$  是大语言模型.
- ▶ 提升不随延拓自动保持. 什么是大语言模型的 next-token 续写幻觉: 虽然有从  $D$  到  $B$  的提升  $f$  满足  $g \circ f = h \circ i$ , 但找不到从  $A$  到  $B$  的提升  $k$  满足  $g \circ k = h$ .  
—— 林黛玉倒拔垂杨柳.
- ▶ 阴谋论: 容易 lift 出多个解释, 难以验证.  
阴谋论 vs 幻觉 :: 多解 vs 无解.
- ▶ lift 无解? vs 创造新对象?  
幻觉在左 vs 天才在右 (爱因斯坦进行溯因跳跃, 提出“等效原理”)

## 类比: 溯因/归纳/演绎的混合

- ▶  $S$  中的元素都有  $P$  和  $Q$  性质.
- ▶  $x$  和  $S$  中的元素一样, 也都有  $P$  性质.
- ▶  $x$  是否也有  $Q$  性质?




- ▶ 令  $S := \{\langle A, B \rangle\}$ ,  $x := \langle C, D \rangle$ ,  $M := P \wedge Q$ .
- ▶ 若存在  $k$  使得  $g \circ k = h$ , 则我们可以说, 在  $M$  意义上,  $A$  之于  $B$  恰如  $C$  之于  $D$ .

$$A : B :: C : D$$

**Remark:**  $A : B :: C : \underline{\quad ? \quad}$  是预测?




## 关系类比/属性类比 — 结构迁移




# 类比 — 溯因/归纳/演绎的混合


康熙：乾隆 :: 星期三：\_\_？\_\_



## 《晏子使楚》

1. 楚王赐晏子酒，酒酣，吏二缚一人诣王。
2. 王曰：“缚者曷为者也？”对曰：“齐人也，坐盗。”
3. 王视晏子曰：“齐人固善盗乎？”
4. 晏子避席对曰：“婴闻之，橘生淮南则为橘，生于淮北则为枳，叶徒相似，其实味不同。所以然者何？水土异也。今民生齐不盗，入楚则盗，得无楚之水土，使民善盗耶？”








# 学问像大海, 考试像鱼钩

学问像大海, 考试像鱼钩, 老师老要把鱼挂在鱼钩上, 叫鱼怎么能在大海中学会自由、平衡地游泳?

— 埃尔米特




## 爱丁顿《物理科学的哲学》


想象一位鱼类专家想探究海洋中的生命. 他舒臂撒网, 捕获了一堆海洋生物. 他检查了自己的捕获物, .....并由此作出了两项概括:

1. 凡海洋生物皆长于 5 厘米.
2. 凡海洋生物皆有鳃.....

捕获物相当于物理学知识体系, 网相当于思维装置和感官工具, 撒网意味着观察.



## 隐喻: “Love is a Partnership”



隐喻“凸显”一些东西,“隐藏”一些东西,也可能“创造”一些东西.

- ▶ 爱情是“旅程”.
- ▶ 爱情是“避风港”. “电磁感应”. “一阵风”. “毒药”. “战争”.....




# 隱喻: “A Wing is a Sail”

## The Ground — A Japanese Poem

An ant  
pull a wing of a butterfly.  
O  
It is like yachting.

$$\begin{array}{ccc}
 F(\text{yacht}) = \text{pull} & \xleftarrow{\alpha_{\text{yacht}}} & \text{yacht} \circ f \\
 \downarrow & \curvearrowright & \downarrow \\
 F(\text{over}) = \text{on} & \xleftarrow{\alpha_{\text{over}}} & \text{over} \circ f
 \end{array}$$



# Contents

1. Introduction
2. 逻辑与论证
  - Toy Logic
  - 穆勒五法
  - 类比/归纳/溯因
  - 谬误与扯淡
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 谬误

## 一. 形式谬误

## 二. 非形式谬误

### 1. 言辞谬误

- ▶ 模糊谬误: 划界谬误或连续体谬误, 假精确或过度精确, 抽象概念当具体概念用
- ▶ 歧义谬误: 一词多义, 歧义句构, 辖域谬误, 重音, 脱离语境、断章取义, 概念扭曲, 偷换概念, 混淆集合与个体或整体与部分, 变更标准
- ▶ 定义谬误: 不当定义, 篡改定义
- ▶ 废话谬误: 平凡真理, 无意义的问题, 回顾性宿命论

### 2. 实质谬误

- ▶ 不相干
- ▶ 不充分
- ▶ 不当预设

# 言辞谬误

- ▶ 詹姆斯：当你绕着树转圈时，树上的松鼠也贴着树转圈，并让树始终挡在你和松鼠之间，请问，你绕着松鼠转圈了吗？
- ▶ “可能为真”指“不必然为假”还是“偶然为真”？

必然真理可能为真  
一切可能为真的都可能为假  

---

必然真理可能为假

- ▶ 三秀才赶考，途遇算命先生，问几人中举？先生竖起一指。
- ▶ 我头上站着一个无法被探测到的“飞天面条神”。
- ▶ 如果我说你是驴，那么我就是说你是动物；如果我说你是动物，那么我就说了真理；因此，如果我说你是驴，那么我就说了真理。

## 实质谬误

- ▶ 不相干: 歪曲论题 (稻草人、红鲱鱼、烟雾弹), 诉诸人身 (扣帽子、人身攻击、诉诸动机、罪恶关联、诉诸虚伪、伪善、诉诸成就、富贵、贫贱、智商), 诉诸情感 (诉诸恐惧、厌恶、仇恨、谄媚、同情、愧疚、可爱、性感、时髦、嘲弄、虚荣、势利、沉默), 诉诸暴力、恐吓、诽谤, 诉诸来源、年代、新潮、传统, 诉诸信心、意愿, 诉诸后果、中庸、自然, 转移举证责任, 不得要领
- ▶ 不充分: 不当概括 (偏差样本、偏差统计), 诉诸无知, 诉诸不当权威、名人、大众, 虚假原因, 滑坡谬误, 诉诸可能, 诉诸阴谋, 隐瞒证据, 不当类比, 乱赋因果 (相关、巧合、因果倒置、单因谬误), 完美主义谬误、权宜主义谬误
- ▶ 不当预设: 窃取论题, 非黑即白, 打压对立, 自然主义谬误 (实然推应然), 道德主义谬误 (好的就是自然的), 复合问题, 诱导性提问, 诉诸顽固、反复、冗赘, 乱枪打鸟, 两面讨好

## “这鸡蛋真难吃。”

- ▶ 有本事你下一个好吃的蛋啊!
- ▶ 我可以负责任地说, 我们的鸡蛋都是合格的健康蛋!
- ▶ 鸡是优等鸡, 你咋说它下的蛋难吃?
- ▶ 这是别有用心的煽动, 你是何居心?
- ▶ 隔壁的鸭子给了你多少钱?
- ▶ 隔壁家的鸡蛋是伪蛋!
- ▶ 伟大的隔壁老王说好吃, 你跟他说去!
- ▶ 没有伟大的老王, 你连臭蛋都吃不上!
- ▶ 杀掉这只鸡换一只就能下金蛋?
- ▶ 你叫什么名字? 你是干什么的! 你是站在谁的立场上说话?
- ▶ 美国鸡蛋好吃, 你去吧!
- ▶ 你以为你谁啊, 品蛋师啊? 就你威风!
- ▶ 你个鸭蛋脑残粉!
- ▶ 下蛋的是一只勤劳勇敢善良正直的鸡!
- ▶ 再难吃也是自己家的鸡下的蛋!
- ▶ 但隔壁家的鸡蛋没有我们家的蛋形圆!
- ▶ 吃鸡蛋是我们家的传统美德. 祖宗三代都是吃鸡蛋长大的! 你也是! 你有什么权力说这蛋难吃? 还是不是人!
- ▶ 作为一个吃鸡蛋长大的人, 我为我天天吃鸡蛋感到自豪!
- ▶ 拒绝抹黑! 抵制鸭蛋! 鸡蛋万岁! 鸡蛋加油!
- ▶ 人心理阴暗会导致味觉异常.....
- ▶ 其实隔壁家鸡蛋是个巨大的阴谋, 试图颠覆我们家!
- ▶ 其实邻居家只有少数人才能吃上鸡蛋.
- ▶ 我们这么大的一个家, 问题太复杂, 下蛋没有你想得那么容易.
- ▶ 不要再吵了, 这个家不能乱, 稳定、稳定压倒一切!
- ▶ 要对我们家的鸡有耐心, 它一定会下出更好吃的蛋.
- ▶ 蛋无完蛋!

## “这鸡蛋真难吃.”

- ▶ 我们家的鸡已经可以打败隔壁家的鸭!
- ▶ 隔壁家也吃过这样的鸡蛋, 现在是初级阶段, 必须坚持一百年不动摇!
- ▶ 我们家人肠胃不好, 现阶段还不适合吃鸭蛋, 不符合我们家的具体家情!
- ▶ 凡事都有个过程, 现在还不是吃鸭蛋的时候.
- ▶ 鸡蛋好不好吃, 全体蛋鸡最有发言权.
- ▶ 老外都说好吃呢.
- ▶ 这蛋难吃但是历史悠久啊.
- ▶ 虽然难吃但重要的是好看啊.
- ▶ 比以前已经进步很多了.
- ▶ 哎, 人心不古, 世风日下, 就是因为你这种想吃鸭蛋的人太多了.....
- ▶ 隔壁家那鸭蛋更难吃, 你咋不说呢?
- ▶ 嫌难吃就别吃, 滚去吃隔壁的鸭蛋吧.
- ▶ 隔壁亡我之心不死! 该鸡蛋肯定是被隔壁一小撮不会下蛋的鸡煽动变臭的!
- ▶ 你上次吃茄子都吐, 味觉一贯奇葩.
- ▶ 胡说! 我们家的鸡蛋比隔壁家的鸭蛋好吃五倍! 五倍!
- ▶ 是你的思想跟不上鸡蛋口味的升级!
- ▶ 心理阴暗! 连鸡蛋不好吃也要发牢骚!
- ▶ 抱怨有毛用, 有这个时间快去赚钱!
- ▶ 隔壁家的鸡蛋也一样, 天下乌鸦一般黑, 没有好吃的鸡蛋!
- ▶ 吃了人家的鸡蛋还留下证据说鸡蛋难吃, 太有城府了!
- ▶ 很多家都是因为吃隔壁的鸭蛋而导致家庭冲突, 生活水平下降甚至解体!
- ▶ 到目前为止, 我没发现这鸡蛋难吃. 专家说了, 这鸡蛋难吃的可能性不大. 即使出现这种情况, 也是结构性难吃.
- ▶ 荷兰狗/东北猪/瘪三.....不配吃鸡蛋!
- ▶ 大家小心, 此人 IP 在国外.
- ▶ 滚, 你丫是鸡奸, 这里不欢迎你.

## 诉诸无知论证的强度

1. 鬼存在, 因为没人证明鬼不存在.
2. 这药安全, 因为没人发现任何毒副作用.

**Question:** 这两论证, 哪个强哪个弱? 为什么?



假如潘金莲不开窗户, 就不会掉下木棍打到西门庆, 也就不会认识西门庆, 不会出轨, 不会害死武大郎, 武松不会被逼杀人上梁山, 不会有独臂擒方腊, 方腊就可夺取大宋江山, 没了宋就不会有靖康耻、金兵入关, 也不会有元、明、清, 不会闭关锁国、鸦片战争、八国联军. 这样中国将成为超级大国, 称霸世界!

### For Want of a Nail

For want of a nail, the shoe was lost,  
For want of a shoe, the horse was lost,  
For want of a horse, the rider was lost,  
For want of a rider, the message was lost,  
For want of a message, the battle was lost,  
For want of a battle, the war was lost,  
For want of a war, the kingdom was lost,  
For want of a nail, the world was lost.  
And all for the want of a nail.

### 孔子《论语》

名不正, 则言不顺,  
言不顺, 则事不成;  
事不成, 则礼乐不兴,  
礼乐不兴, 则刑罚不中;  
刑罚不中, 则民无所措手足.

## 礼记·坊记

天无二日，土无二王，家无二主，尊无二上。

### 董仲舒《春秋繁露》

天以终岁之数，成人之身，故小节三百六十六，副日数也；大节十二，分副月数也；内有五藏，副五行数也；外有四肢，副四时数也；乍视乍瞑，副昼夜也；乍刚乍柔，副冬夏也。

**告子：**性，犹湍水也，决诸东方则东流，决诸西方则西流。人性之无分于善不善也，犹水之无分于东西也。

**孟子：**水信无分于东西，无分于上下乎？人性之善也，犹水之就下也。人无有不善，水无有不下。

### 孟子《生于忧患，死于安乐》

舜发于畎亩之中，傅说举于版筑之中，胶鬲举于鱼盐之中，管夷吾举于士，孙叔敖举于海，百里奚举于市。故天将降大任于斯人也，必先苦其心志，劳其筋骨，饿其体肤，空乏其身，行拂乱其所为，所以动心忍性，曾益其所不能。

## 《庄子·外篇·天地》

子贡南游于楚，反于晋，过汉阴，见一丈人方将为圃畦，凿隧而入井，抱瓮而出灌，搢搢然用力甚多而见功寡。子贡曰：“有械于此，一日浸百畦，用力甚寡而见功多，夫子不欲乎？”为圃者仰而视之曰：“奈何？”曰：“凿木为机，后重前轻，挈水若抽，数如佚汤，其名为橰。”为圃者忿然作色而笑曰：“吾闻之吾师，有机械者必有机事，有机事者必有机心。机心存于胸中，则纯白不备。纯白不备则神生不定，神生不定者，道之所不载也。吾非不知，羞而不为也。”

有 6000 人死于醉酒; 有 4000 人死于开车; 但只有 100 人死于醉酒开车. 因此, 醉酒开车比单纯的醉酒或者单纯的开车更安全.

### 莱布尼茨《单子论》


如果单子没有知觉, 那么其复合物也没有知觉.

### 帕斯卡赌

如果上帝不存在, 但你相信上帝存在, 也没太大损失; 然而, 如果上帝存在, 而你却不相信上帝存在, 那你将面临巨大的惩罚. 所以, 应该相信上帝存在.

### 鲁迅《论辩的灵魂》

我骂卖国贼, 所以我是爱国者. 爱国者的话是最有价值的, 所以我的话是不错的, 我的话既然不错, 你就是卖国贼无疑了!



- ▶ 朋友越是支持我, 越说明我做对了.
- ▶ 敌人越是反对我, 越说明我做对了.
- ▶ 连敌人都不得不支持我, 变成我的朋友, 更说明我做对了.
- ▶ 如果朋友反对我, 说明他其实是敌人.

整体性, 奠基于无维度现象之显现, 亦复归于此显现之褶皱. 实在从不乏来自多重宇宙的信使, 其“第三只眼”已然化入超验. 超验回望, 却在原初表象中对上“第三只眼”. 这是对实在的逃逸, 也是抉择后自我疗愈的先验闭环. 复杂性构成了超验得以可能的因果熵力, 超验亦反哺复杂性之上扬. 主体, 不过是复杂性湍流冲刷的河床洞影. 主体与信使之间的纠缠, 唤醒的是某种超越非局域性的前意识觉知. 而意识觉知, 图示着意志之边界. 伫立在自我与流变的裂隙, 自我不是锚点. 自我固着之处, 自性无从绽出. 我们以不断弥散的波函数样态时而在场时而缺席, 既叠加希望的胚芽, 亦坍塌禁锢的纤维. 置身于存在之自觉复归的途中, 主体性于自身内部以自返的方式展开, 与那作为纽结的根茎相互调谐.

生命形态, 在向内的层层凝视中, 自深渊底部螺旋指涉, 自我创生.

踏循此途, 即是与此途合一. 经由去蔽, 我们相信; 经由内化, 我们共振; 经由绽放, 我们体认具身. 我们入梦; 我们疗愈; 我们重生. 然后梦醒.

你与我, 皆是这量子汤中的织梦信使. 面对幻象及其无尽的回响, 如何才能虚拟出无垠的空境 — 以澄明那无限种可能的高维超结构?

无限正在逼近其临界态. 隐藏的意义, 使那无法命名的抽象之美, 在显形中悄然变容. 整体使无尽现象静默.

## 请为下面几句话的“深刻性”打分

1. We are in the midst of a self-aware blossoming of being that will align us with the nexus itself.
2. A wet person does not fear the rain.
3. Most people enjoy some sort of music.

# On the reception and detection of pseudo-profound bullshit

- ▶ Bullshit Receptivity 与超自然信仰、阴谋论、替代医学正相关.

bullshit Receptivity := mean of the profoundness ratings for all bullshit

- ▶ Bullshit Sensitivity 与批判性思维能力正相关.

$$\begin{aligned} &\text{bullshit sensitivity} \\ &:= \\ &\frac{\text{profundity ratings for meaningful quotations}}{\text{profundity ratings for pseudo-profound bullshit}} \end{aligned}$$



# 扯淡

|    | 说谎          | 扯淡    |
|----|-------------|-------|
| 真相 | (相信自己) 知道真相 | 不关心真相 |
| 意图 | 掩盖真相        | 影响听众  |

“相比于说谎, 扯淡是真理更大的敌人。”

— 法兰克福

- ▶ 学术: 晦涩的语言掩盖思想的贫乏.
- ▶ 政治: 模糊的辞令掩盖政策的空洞.
- ▶ 营销: 华丽的术语包装低劣的产品.
- ▶ 健康养生: 无法证伪的理论导向有害的行为.

## 法兰克福《论扯淡》

假设在美国的独立日上，总统声嘶力竭地对大众说：“我们伟大的、受到上帝保佑的祖国，它的开国元勋在神圣的引导下，为人类开创了一个崭新的篇章……”<sup>a</sup>

---

<sup>a</sup>到底有没有上帝？上帝有没有保佑美国？美国是否伟大？美国的开国元勋是否受到了神圣的引导？美国的建立在人类历史上是一个怎样的地位？为人类开创了一个怎样的新篇章？

# How to generate pseudo-profound bullshit?<sup>2</sup>

1. State the blindingly obvious (of life's big theme) incredibly slowly.
  - ▶ We were all children once.
  - ▶ The world of the happy is quite different from the world of the unhappy.
2. Doublethink/Dialectic/Contradiction.
  - ▶ War is peace.  
Freedom is slavery.  
Ignorance is strength.
  - ▶ All animals are equal but some animals are more equal than others.
  - ▶ Life is often a form of death.
  - ▶ Everyone is the other, and no one is himself.

---

<sup>2</sup>Law: Believing Bullshit.

Frankfurt: On Bullshit.

Bergstrom & West: Calling Bullshit.

# How to generate pseudo-profound bullshit?

## 3. Ambiguity/Metaphor/Parable.

- ▶ Love is just a word.
- ▶ Language is the house of the truth of Being.
- ▶ Never stay up on the barren heights of cleverness, but come down into the green valleys of silliness.
- ▶ Ethics does not treat of the world. Ethics must be a condition of the world, like logic.
- ▶ A person is neither a thing nor a process but an opening through which the Absolute can manifest.
- ▶ Making itself intelligible is suicide for philosophy. Those who idolize “facts” never notice that their idols only shine in a borrowed light.

# How to generate pseudo-profound bullshit?

## 4. Analogy.

- ▶ Life is like a box of chocolates. You never know what you're gonna get.
- ▶ Life is like a shell, which suddenly bursts into fragments, which fragments, being themselves shells, burst in their turn into fragments destined to burst again, and so on for a time incommensurably long.
- ▶ We have got on to slippery ice where there is no friction, and so, in a certain sense, the conditions are ideal; but also, just because of that, we are unable to walk. We want to walk: so we need friction. Back to the rough ground!
- ▶ The subject does not belong to the world: rather, it is a limit of the world. This is exactly like the case of the eye and the visual field. You do not see the eye. Nothing in the visual field allows you to infer that it is seen by an eye. Our life is endless in the way that our visual field is without limit.

# How to generate pseudo-profound bullshit?

## 5. Use jargon.

- ▶ Profound boredom, drifting here and there in the abysses of our existence like a muffling fog, removes all things and men and oneself along with it into a remarkable indifference. This boredom reveals being as a whole.
- ▶ Dasein has always made some sort of decision as to the way in which it is in each case mine. That entity which in its Being has this very Being as an issue, comports itself towards its Being as its ownmost possibility. With death, Dasein stands before itself in its ownmost potentiality-for-Being.
- ▶ A machinic assemblage, through its diverse components, extracts its consistency by crossing ontological thresholds, non-linear thresholds of irreversibility, ontological and phylogenetic thresholds, creative thresholds of heterogenesis and autopoiesis.

# What is a Good Argument?

- |                                       |                           |
|---------------------------------------|---------------------------|
| 1. What is a good deductive argument? | validity + true premises? |
| 2. What is a good inductive argument? | inductive strength?       |
| 3. What is a good abductive argument? | explanatory power?        |



What's more? A good argument should

- ▶ have its validity (or inductive strength, or explanatory power) and truth-of-premises be as evident as practically possible to the parties involved;
- ▶ be clearly stated;
- ▶ avoid ambiguity, emptiness, circularity, vicious regression, and emotional language;
- ▶ be relevant to the issue at hand.

# Writing & Argument

1. Before you write: Structuring the paper.
  - 1.1 Diagram the logic of your argument.
  - 1.2 Break your work into sections/paragraphs.
  - 1.3 Write a brief abstract for each section.
2. Write: Fill in the details.

*Tell them what you're going to say.*  
*Say it.*  
*Tell them what you've just said.*
3. Rewrite: Improving your language.
  - 3.1 Read it out loud.
  - 3.2 Keep sentences short and precise.






# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 笛卡尔的“知识之树”



- ▶ 哲学像一棵大树，形而上学是树根，物理学是树干，其他科学是树枝。
- ▶ 哲学如何为所有科学奠定基础？科学的统一性不在于研究对象，而在于方法。有一种统一的方法适用于所有科学，那就是“普遍数学”。
- ▶ 普遍怀疑 — 从复杂分析到简单 — 从简单综合到复杂 — 全面检查

## 形而上学 vs 数学

数学是唯一好的形而上学.

— 开尔文

自然哲学就是数学, 也必须是数学.

— 麦克斯韦

没有数学, 我们就无法深入理解哲学;  
没有哲学, 我们就无法深入理解数学;  
没有这两者, 我们就无法深入理解任何事物.

— 莱布尼茨

不懂几何者不得入内!

— 柏拉图

为了创造一种健康的哲学, 你应该抛弃形而上学, 但要成为一个好数学家.

— 罗素

我们已经有了有一套最完美的基于证明的哲学, 那就是数学.

— 邓煜

# The point of philosophy is to make things not philosophy

数学家们都清楚，  
没有什么比模糊的类比、  
理论到理论的朦胧映射、  
隐秘的抚弄、  
难以解释的冲突，  
更富生命力了，  
也没有什么更能给研究者带来乐趣了。  
一旦幻象消散，黎明到来，  
直觉变成确信；  
相互关联的理论在消逝之前展露其共同的根源；  
正如《薄伽梵歌》的教诲，  
真知抵达之日，  
亦是空寂漠然之时。  
形而上学已然化为数学，  
构成论著的素材，  
冷峻的美，不再撩人。

— *André Weil*

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
  - 存在
  - 时空
  - 因果
  - 自由意志
  - 因果、实在、自由意志
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

何物存在？

实体与关系哪个更基本？

什么使一个东西成为“同一个东西”？

# 世界的本源是什么？

1. 泰勒斯: 万物的本源是“水”.
2. 亚里士多德: 万物的本源是“土”、“水”、“火”、“气”、“以太”.
3. 德谟克利特: 万物的本源是“原子”和“虚空”.
4. 贝克莱: 存在即“被感知”.
5. 维特根斯坦: 语言的界限即世界的界限.
6. 黑格尔: 世界是“绝对精神”的自我展开.
7. 柏拉图: 现实世界是“理念世界”的投影.
8. 毕达哥拉斯: 万物皆“数”.
9. 泰格马克: 世界即“数学结构”.
10. 莱布尼茨: 一切皆“计算”.
11. 惠勒: 万物源于“比特”.
12. 赫拉克利特: 万物皆“流”.
13. 怀特海: “过程”即实在.
14. 李·斯莫林: 世界是由事件的因果过程构成的关系网络.

# 何物存在?

**唯名论:**  
抽象事物不存在

**极端唯名论:**  
即使具体事物也不存在

**柏拉图主义:**  
抽象事物存在

**极端柏拉图主义:**  
就连具体事物也存在

- ▶ 名字叫“罗素”的那个人存在
  - ▶ 人存在
  - ▶ 电子存在
  - ▶ 红存在
  - ▶ 2 存在
- “如果其他事物存在, 那数也存在.”


— 柏拉图《智者篇》



# 何物存在?


- ▶ No entity without identity. — Quine's standards of ontological admissibility
- ▶ To be is to be the value of a bound variable. — Quine's criterion of ontological commitments
- ▶ To be is to be constructed by intuition. — Brouwer

# 忒修斯之船



- ▶ 如果忒修斯之船上的全部木头逐渐被替换, 替换下来的木头又被重组成一艘船. 哪一艘才是忒修斯之船?
- ▶ 极端唯名论者: 不存在真正的忒修斯之船. 真正存在的是经验刺激. 人们区分或命名的是这些不同的经验刺激. 而区分或命名并不总是严格的.

# 个人同一性



身体/生命连续? 心理/记忆连续? 叙事同一? 灵魂实体? 束理论/无我?

**问题:** 如果你的意识被上传到云端, 那个“你”还是你吗?

# 形式 & 质料


- ▶ 亚里士多德“形式质料说”：实体 = 形式 + 质料
  - 缺乏形式的质料是混沌.
  - 缺乏质料的形式是幽灵.
- ▶ 万物皆形式. 泰格马克的数学宇宙假说：物理宇宙 = 数学结构.
- ▶ 万物皆信息. 惠勒：“万物源于比特”.
- ▶ 质料是存在的. “作为一只蝙蝠是什么感受?”，“玛丽黑白屋”，“塞尔中文屋”，“布洛克中国脑”，莱布尼茨的“磨坊”，“哲学僵尸”...

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
  - 存在
  - 时空
  - 因果
  - 自由意志
  - 因果、实在、自由意志
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会


时空是连续的还是离散的?

# 芝诺悖论 I: 二分法 (Dichotomy)




- ▶ 一个人要从 A 走到 B, 必须先走完全程的一半, 再走完剩下一半的一半.....他需要完成无穷多个步骤.
- ▶ 芝诺: 无穷多步骤不可能在有限时间内完成.
- ▶ 甚至无法开始运动. 要走到某点, 需要先走一半, 一半的一半.....
- ▶ 二分悖论: 空间是连续的 (+ “有限时间无法完成无限任务”)  $\implies$  运动是不可能的.

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \cdots = \sum_{n=1}^{\infty} \frac{1}{2^n} = 1 < \infty$$



## 芝诺悖论 II: 阿喀琉斯与乌龟 (Achilles & Tortoise)




- ▶ 阿喀琉斯的速度是乌龟的 10 倍, 乌龟先出发 100 米.
- ▶ 当阿喀琉斯跑到乌龟的出发点时, 乌龟又前进了 10 米; 当他再跑 10 米时, 乌龟又前进了 1 米.....
- ▶ 芝诺: 阿喀琉斯需要在有限时间完成无限多次“追赶”, 因此永远追不上乌龟.
- ▶ 阿喀琉斯追不上乌龟: 空间是连续的 (+ “有限时间无法完成无限任务”)  $\Rightarrow$  运动是不可能的.
- ▶ 有限时间即可追上:

$$\sum_{n=0}^{\infty} \frac{100 \left(\frac{1}{10}\right)^n}{10v_{\text{龟}}} = \frac{100}{9v_{\text{龟}}} < \infty$$



## 芝诺悖论 III: 飞矢不动 (Arrow Paradox)




- ▶ 芝诺: 时间是一系列连续的 now, now 分开了 past 和 future. 对于每一个 now, 箭都占据唯一一个与自身等同的空间 = 静止不动. 在连续的时间轴上, 找不到从一个 now 跳到下一个 now 的空隙, 那么, 箭在啥时运动呢? 飞矢不动.
- ▶ 如果时间是一系列离散的 now, 时间的流逝是从一个 now 跳跃到下一个 now, 那么, 运动就可以发生在时间的裂隙.
- ▶ 飞矢不动: 时间是连续的 (+ “运动 = 位置状态的集合”)  $\Rightarrow$  运动是不可能的.
- ▶ 运动不是瞬时的位置状态, 而是由位置  $s : \text{Time} \rightarrow \text{Space}$  随时间的状态转移所刻画.

瞬时速度  $v(t) = s'(t) = \frac{d}{dt}s(t) = \lim_{\Delta t \rightarrow 0} \frac{s(t+\Delta t) - s(t)}{\Delta t}$  可以非零.

静止的“快照”并不意味着瞬时速度为零.

## 芝诺悖论 IV: 运动场 (Stadium / Moving Rows)

- ▶ 三排物体:  $A$  排静止,  $B$  排向右,  $C$  排向左, 以相同速度运动.
- ▶ 芝诺: 如果时间和空间都由**最小不可分的离散单位**组成, 且存在最大速度上限, 比如每一个时间单位最多经过一个空间单位.  $B$  以最大速度, 相对于  $A$  走过了 1 个单位, 但它相对于  $C$  怎么走过了 2 个单位?  $B$  眼中看  $C$ , 要么漏了 1 个单位, 要么超出了最大速度上限!
- ▶ 运动场悖论: 时间和空间是离散的 (+ “绝对速度上限” + “伽利略速度叠加”)  $\Rightarrow$  矛盾
- ▶ 狭义相对论放弃了伽利略速度叠加.



## 假如你是“穿越者”

想象一下, 你穿越成了亚里士多德, 携带者现代的科学方法和逻辑思维, 但被清除了所有的现代知识, 你会如何书写你的形而上学和自然哲学?

## 空间依赖于物质吗？


- ▶ 柏拉图：感知对象是形式 (Form) 的不完美摹本。空间既非感知对象，也非形式。空间是承载形式投影的基底质料。抽离物质，就没有空间。没有绝对虚空。形式通过纯粹理性认知；感知对象通过感官经验认识；空间通过混杂推理 (bastard reasoning) 认识。
- ▶ 亚里士多德：空间是位置的总体。位置是包含三维物体的不动的二维边界。不同对象在不同时间可以占据同一位置。位置跟物体可分离。运动分自然运动和受迫运动。自然运动的“本性”是内部目标导向的变化原因 (目的因)。自由落体是回到其自然位置。地球是宇宙的中心。“土”、“水”的本性是沿直线趋向宇宙中心 (向下)；“火”、“气”的本性是沿直线背离宇宙中心 (向上)；“以太”的本性是围绕宇宙中心做圆周运动。没有推动者，就没有受迫运动。受迫运动的速度  $v$  正比于外力  $F$ ，反比于介质的阻力  $R$ 。即  $v \propto \frac{F}{R}$ 。没有绝对虚空，否则，物体运动速度会无限大， $R = 0 \implies v = \infty$ 。抽离物质，就没有空间。
- ▶ 笛卡尔：空间即物质的广延。抽离物质，就没有空间。
- ▶ 莱布尼茨、马赫：关系主义时空观。抽离物质，就没有空间。
- ▶ 牛顿：自由落体是万有引力作用的结果。幽灵般的超距作用。绝对时空背景。抽离物质，空间依然存在。

# 牛顿力学: 苹果落地, 月亮咋就不落地?

“力是**保持**物体运动状态的原因.”

— 亚里士多德

- ▶ 什么是“运动”?
- ▶ 什么是“运动状态”?
- ▶ 什么是“物体”?
- ▶ 怎么“保持”? 还是“改变”?



## 牛顿力学理论

- ▶ 基本概念: 质量, 动量, 惯性, 外力
- ▶ 非逻辑公理:

公理 1 惯性定律

公理 2 动量变化定律

公理 3 作用与反作用定律

公理 4 万有引力定律

$$F = 0 \iff \frac{d^2 s}{dt^2} = 0$$

$$F = m \frac{d^2 s}{dt^2}$$

$$F_{12} = -F_{21}$$

$$F = G \frac{m_1 m_2}{r^2}$$



时空是绝对的还是相对的？

# 莱布尼茨 PK 牛顿

- ▶ 牛顿：时空是绝对的，独立于万物而存在。即使没有物质，空的空间依然存在。
- ▶ 莱布尼茨：时空是相对的。
  - ▶ 空间是事物之间的相互关系，没有事物就没有空间，不存在空的空间。
  - ▶ 时间是事物关系变化的度量，没有事物就没有时间，不存在空的时间。
  - ▶ 如果空间是绝对的，那么将宇宙往右平移一米将与原宇宙不可区分；如果时间是绝对的，那么将宇宙往后平移一分钟将与原宇宙不可区分。违背“不可分辨者的同一性”。
  - ▶ 宇宙是一个因果关系的网络。其中每一部分的性质由其与其它部分的关系决定。





# The “Static” Shift Argument



- ▶ 牛顿:  $\text{universe1} \neq \text{universe2}$ .  
理由: 绝对位置不同.
- ▶ 莱布尼茨:  $\text{universe1} = \text{universe2}$ .  
理由:
  1. **充足理由律**. 上帝为什么创造了  $\text{universe1}$  而不是  $\text{universe2}$ ?
  2. **不可分辨者的同一性原则**.  $\text{universe1}$  和  $\text{universe2}$  不可分辨.





# The “Kinematic” Shift Argument






- ▶ 牛顿:  $\text{universe1} \neq \text{universe2}$ .  
理由: 绝对速度不同.
- ▶ 莱布尼茨:  $\text{universe1} = \text{universe2}$ .  
理由:
  1. **充足理由律**. 上帝为什么创造了  $\text{universe1}$  而不是  $\text{universe2}$ ?
  2. **不可分辨者的同一性原则**.  $\text{universe1}$  和  $\text{universe2}$  不可分辨.

# The Reflection Argument



- ▶ 牛顿:  $\text{universe1} \neq \text{universe2}$ .  
理由: 绝对位置不同.
- ▶ 莱布尼茨:  $\text{universe1} = \text{universe2}$ .  
理由:
  1. **充足理由律**. 上帝为什么创造了  $\text{universe1}$  而不是  $\text{universe2}$ ?
  2. **不可分辨者的同一性原则**.  $\text{universe1}$  和  $\text{universe2}$  不可分辨.

## 对“不可分辨者的同一性原则”的质疑



世界 1 可能, 世界 2 可能, 世界 3 不可能?

# 莱布尼茨对牛顿绝对时空的质疑


- ▶ 遵循牛顿力学的物体的位置和速度依赖绝对时空吗？
- ▶ 将整个宇宙往右平移一米，牛顿力学会受影响吗？
- ▶ 牛顿三定律、万有引力定律

$$F = ma, \quad F = G \frac{m_1 m_2}{r^2}$$

涉及物体的绝对时空位置或速度吗？


- ▶ 绝对位置、绝对速度不可观测，绝对时空没有物理意义。
- ▶ 牛顿的回应：绝对加速度总是伴随惯性力，是可观测的。相对时空怎么解释惯性？

## 牛顿的“双球”宇宙



- ▶ 两个天球, 被一根绳子连在一起, 围绕绳子中点旋转, 你在其中一个天球上, 能发现自己在旋转吗?
- ▶ 牛顿: 旋转时, 绳子上的张力不为零, 说明天球在相对于绝对空间旋转.
- ▶ 马赫: 没有背景星系时, “旋转” 没有物理意义, 旋转跟静止一样, 绳子张力为零; 有背景星系时, 绳子才有张力; 如果双球不动, 星系围绕双球旋转, 绳子同样有张力.
- ▶ 莱布尼茨: 绳子有张力, 它源于系统内部的应力, 无关绝对时空.

# 牛顿的水桶实验



|      | I  | II | III | IV |
|------|----|----|-----|----|
| 桶    | 静止 | 转动 | 转动  | 静止 |
| 水    | 静止 | 静止 | 转动  | 转动 |
| 相对运动 | 否  | 是  | 否   | 是  |

- ▶ 旋转水桶, 开始, 水由于惯性尚未旋转, 水面是平的; 然后, 水随桶旋转, 水面凹; 最后, 水桶静止, 水继续旋转, 水面凹.
- ▶ 牛顿: 水面的凹陷并不由其与桶的相对运动引起的, 而是由其相对于绝对空间的绝对运动引起的.

## 从莱布尼茨到马赫到爱因斯坦


- ▶ 马赫: 水面的凹陷是由其与宇宙中所有其他物质的相对运动引起的.
- ▶ 想象水桶壁非常非常厚, 整个宇宙的物质变成了厚厚的水桶壁, 那么, 当水相对于桶壁转动时, 水面就会凹陷.
- ▶ 马赫原理: 物体的惯性是宇宙中其他所有物质对该物体作用的结果.
- ▶ 马赫原理摒弃了绝对时空, 把惯性归结为引力, 这启发爱因斯坦发现了等效原理: 引力场与惯性力场局域不可区分.
- ▶ 根据等效原理, 旋转圆盘是个加速系, 它等价于一个引力场. 根据狭义相对论, 圆盘在旋转时, 沿边缘方向的尺子会发生洛伦兹收缩, 导致测量出的圆盘的周长变大, 而沿半径方向的尺子不会收缩, 直径不变. 这意味着, 测得的圆周率变大:

$$\frac{\text{周长}}{\text{直径}} > \pi$$

加速系 (引力场) 的几何是非欧几里德的. 引力是局域弯曲时空的几何效应. 物体在引力场中的自由落体, 不过是在弯曲时空中沿着测地线运动.

- ▶ 注: GR 并没有完全实现马赫原理. 宇宙只有薄壁水桶时, 水相对于桶壁旋转, 根据马赫原理, 水面不会凹陷, 而根据 GR, 会凹陷.


# 爱因斯坦的匀加速电梯思想实验



- ▶ 通过思想实验模拟的加速度感官体验与地球上的重力感官体验不可区分, 爱因斯坦溯因出等效原理: 引力场与惯性力场局域不可区分.



# 爱因斯坦 & 中文屋 — 从感官体验到公理的跳跃[Zah26]




1. **Deduction:** Rule + Case  $\implies$  Result
2. **Induction:** Case + Result  $\implies$  Rule
3. **Abduction:** Rule + Result  $\overset{\text{Jump}}{\implies}$  Case

- ▶ LLM 因为缺乏**具身**世界模型, 无法对感官体验进行反事实模拟, 所以无法像爱因斯坦一样进行创造性溯因?
- ▶ 多模态可以帮助更好的溯因  $M(x_{\text{multimodal}}) \rightarrow \mu(x_{\text{multimodal}})$ .
- ▶ 创造性溯因/归纳 vs 幻觉.
- ▶ Freedman: Compression is all you need: Modeling Mathematics?[Aks+26]


## 康德“一只手”挑战莱布尼茨

- ▶ 设想宇宙里只有孤零零的一只手.
- ▶ 这只手要么是左手, 要么是右手 — 即一只手不可能缺乏“手性”.
- ▶ 如果这样一只手确实具有手性, 那么究竟有什么“关系性事实”能够决定它是左手还是右手呢?
- ▶ 这只手的手性肯定是由其所处的绝对空间确定的.



- ▶ 莱布尼茨可能的回应: 一只手究竟是“左手”还是“右手”, 不是这只手的“固有属性”, 而是取决于整个空间的全局拓扑结构. 一只手在三维欧式空间中有“手性”, 并不意味着在其他空间也有手性 (比如高维空间或类似莫比乌斯的空间).
- ▶ 康德可能的回应: 一只手是怎么决定这样一种空间的拓扑结构的?

## 庞加莱：几何约定论




- ▶ 第一个球恒温绝对零度.  $\frac{c}{d} = \pi$ .
- ▶ 第二个球变温, 中心高温, 边缘绝对零度. 尺子受热膨胀. 测量出来的  $d$  变小,  $c$  不变:  $\frac{c}{d} > \pi$ . 假设变形力不可测, 有两种解释:
  1. 尺子是刚性的, 几何空间是非欧的.
  2. 尺子受力变形, 几何空间是欧式的.
- ▶ 庞加莱: “几何 + 物理理论  $\implies$  观察”  $G + P \implies O$   
不给定几何空间, 就不知道是否有变形力; 不给定变形力, 就不知道几何空间.
- ▶ 牛顿: “几何背景 + 物理运动”. 爱因斯坦: 时空度规是物理的.

## 伽利略的大船

你和朋友待在一条大船甲板下的主舱里，带几只苍蝇、蝴蝶和小飞虫，准备一碗水，养几条鱼。舱顶挂一个水瓶，让水滴到下面的一只罐里。船停着不动时，你留神观察，小虫将以相同的速度各方向飞，鱼也向各个方向随意地游，水滴滴进下面的罐中，你把任何东西扔给你朋友时，只要距离相等，向这一方向不必比向另一方向费更大的力气。你双脚起跳，无论向哪个方向跳，跳过的距离都相等。再让船以任意速度前进，只要匀速，不忽快忽慢忽左忽右，你将发现：所有上述现象丝毫不变。你无法从其中任何一个现象来确定，船是在运动还是停着不动。即使船运动得相当快，在跳跃时，你将和以前一样，跳过相同的距离，你跳向船尾也不会比跳向船头来得远，虽然你跳到空中时，脚下的船底板向着反方向移动。无论你把什么东西扔给朋友，无论他在船头还是船尾，你都不需要用更大的力气。水滴将像先前一样，滴进下面的罐子里，一滴也不会滴在船尾，虽然水滴在空中时，船已行驶了一段距离。鱼游向水碗前部不需要比游向后部花费更大的力气，一如既往地悠游于水碗边缘的任何地方觅食。蝴蝶和苍蝇也继续随意地四处飞，不会集中在船尾，就像因为长时间停留在空中，与船身分离，为了跟上船的运动而显出疲惫的样子。如果点香冒烟，则将看到烟像云一样升腾，没有明显偏移。

# Classical Physics Respects Galilean Symmetry



- ▶ 乘客在匀速直线运动的车上, 向上抛一个小球, 然后接住, 看到的运动轨迹是直线.
- ▶ 路人看到的运动轨迹是抛物线.
- ▶ 视角不同, 但物理规律相同.
- ▶ 观察者无法通过抛球判断自己是静止的还是匀速直线运动的.

# 什么是物理/数学?

## ► Physics via Symmetries

The laws of physics respect symmetries.



That which respects symmetries are laws of physics.

## ► Mathematics via Symmetries

A mathematical statement satisfies symmetry of semantics.



A statement that respects symmetry of semantics is mathematical.


## ► Algebraic Structure via Symmetries in Category Theory

Homomorphisms are functions that respect all the operations.




Operations are functions that respect all the homomorphisms.

# Mathematical Statement Respects Symmetry of Semantics



# Point of View Symmetry





# 爱因斯坦的狭义与广义相对论

伽利略：**力学定律**在所有惯性参照系中形式相同。

爱因斯坦：**物理定律**在所有惯性参照系中形式相同？

— 对于**非惯性参照系**呢？

## ► 狭义相对论



1. 狭义相对性原理：物理定律在所有惯性参照系中形式相同。
2. 光速不变原理：光在真空中的传播速度不变，既与惯性参照系的选择无关，也与光源的运动状态无关。

## ► 广义相对论

1. 广义相对性原理：物理定律在所有参照系中形式相同。
2. 等效原理：引力场与惯性力场局域不可区分。

# 爱因斯坦的狭义相对论

- ▶ “力学的目的是描述物体在空间中的位置如何随时间变化.”
- ▶ 什么是“位置”? 什么是“空间”? 什么是“时间”? 是绝对的吗?
- ▶ 不同惯性参照系的观察者对同一事件的描述相同吗?



$$\left. \begin{aligned} \Delta\tau &= \frac{2h}{c} \\ \Delta t &= \frac{2H}{c} = \frac{2}{c} \sqrt{h^2 + \left(\frac{v\Delta t}{2}\right)^2} \end{aligned} \right\} \Rightarrow \Delta\tau = \Delta t \sqrt{1 - \frac{v^2}{c^2}}$$

- ▶ 假如以光速飞行, 你还能从镜子中看到自己的脸吗?
- ▶ 列车头尾同时被闪电劈中. 怎么判断“同时”? 怎么测量“时间”?

# 时钟同步 vs 单程光速

## Definition (时钟同步)

在同一个惯性参照系中, 处在不同位置的处于静止状态的观察者各自拥有一个时钟  $A$  和  $B$ . 时钟  $A$  和  $B$  **同步**, 当且仅当, 如果在  $A$  的时刻  $t_A$  从  $A$  朝  $B$  发出的光在  $B$  的时刻  $t_B$  到达  $B$  后立刻反射回  $A$ , 并在  $A$  的时刻  $t'_A$  到达  $A$ , 且

$$t_B = t_A + \frac{1}{2}(t'_A - t_A)$$

莱辛巴赫:

- ▶ 光凭什么各向恒速? 对任意  $0 < \varepsilon < 1$ , 都可以定义两个时钟  $A$  和  $B$  的同步关系:

$$t_B = t_A + \varepsilon(t'_A - t_A)$$

- ▶ 单程光速不可测 (除非预设各向同性).

## Theorem

在同一个惯性参照系中, 处在不同位置的处于静止状态的时钟之间的同步关系是等价关系.

# 同时性的相对性

- ▶ 在一个惯性参照系的观察者眼中同时发生的两个事件, 在相对匀速运动的另一个惯性参照系的观察者眼中不再是同时发生的.



- ▶ 站台上的观察者: “同时劈中.”
- ▶ 列车中间的观察者: “先劈中头后劈中尾.”

## 狭义相对论

**公理 1** 狭义相对性原理: 物理定律在所有惯性参照系中形式相同.

**公理 2** 光速不变原理: 光在真空中的传播速度不变, 既与惯性参照系的选择无关, 也与光源的运动状态无关.

**Remark:** 光速上限假设. (因果作用只能在光锥内传播  $\Delta s \leq c\Delta t$ )

洛伦兹变换:

$$\begin{bmatrix} x \\ ct \end{bmatrix} = \begin{bmatrix} \cosh \theta & \sinh \theta \\ \sinh \theta & \cosh \theta \end{bmatrix} \begin{bmatrix} x' \\ ct' \end{bmatrix} \quad t = \frac{t' + \frac{vx'}{c^2}}{\sqrt{1 - \frac{v^2}{c^2}}} \quad x = \frac{x' + vt'}{\sqrt{1 - \frac{v^2}{c^2}}} \quad y = y' \quad z = z'$$

时空间隔与惯性系的选择无关.

$$c^2 dt^2 - (dx^2 + dy^2 + dz^2) = c^2 dt'^2 - (dx'^2 + dy'^2 + dz'^2)$$

时间与长度的相对性 — 钟慢尺缩

$$\Delta t = \frac{\Delta \tau}{\sqrt{1 - \frac{v^2}{c^2}}} \quad l = l_0 \sqrt{1 - \frac{v^2}{c^2}}$$

公孙大娘剑术精, 出刺迅捷如流星,  
由于空间收缩性, 长剑变成短铁钉.

$$w = \frac{u + v}{1 + \frac{uv}{c^2}} \quad m = \frac{m_0}{\sqrt{1 - \frac{v^2}{c^2}}} \quad p = \frac{m_0}{\sqrt{1 - \frac{v^2}{c^2}}} v \quad E = \frac{m_0}{\sqrt{1 - \frac{v^2}{c^2}}} c^2$$



# 爱因斯坦的广义相对论

## 广义相对论

**公理 1** 广义相对性原理: 物理定律在所有参照系中形式相同.

**公理 2** 等效原理: 引力场与惯性力场局域不可区分.

- ▶ 在大质量物体上感受到的引力, 与在加速参照系中感受到的惯性力局域不可区分.
- ▶ 惯性质量等于引力质量  $m_I = m_G$ .
- ▶ 引力是由质量/能量分布不均导致的时空弯曲通过测地线原理作用的结果.
- ▶ 时空告诉物质如何运动; 物质告诉时空如何弯曲.



$$R_{\mu\nu} - \frac{1}{2}g_{\mu\nu}R = \frac{8\pi G}{c^4}T_{\mu\nu}$$

# 双生子佯谬



- ▶ 妹妹留在地球上；姐姐乘一艘接近光速的宇宙飞船，进行星际旅行，然后返回地球。
  - ▶ 地球视角：根据狭义相对论，妹妹看姐姐的飞船在飞速运动，觉得姐姐的时间变慢了。所以当姐姐回来的时候，觉得姐姐应该比自己年轻。
  - ▶ 飞船视角：同理，姐姐觉得妹妹在高速运动，妹妹应该比自己年轻。
  - ▶ **问题：**到底谁更年轻？
1. 姐姐视角：姐姐有经历加速度，处于非惯性系，根据广义相对论的等效原理，这等同于处在强引力场中，而强引力场使时间变慢。
  2. 妹妹视角：姐姐的固有时就是把狭义相对论的瞬时时间膨胀公式沿

姐姐更年轻

世界线积分  $\Delta\tau_{\text{姐}} = \int_0^{\Delta t} \sqrt{1 - \left(\frac{v(t)}{c}\right)^2} dt < \Delta t = \Delta\tau_{\text{妹}}.$

# 李·斯莫林对莱布尼茨“关系主义”宇宙观的解释

1. 宇宙之外一无所有. (只有一个宇宙.)
2. 因果完备性: 宇宙是因果封闭的. (万事皆有因, 但因果链不能追溯到宇宙之外. 宇宙的自然律和初始条件也需要有因果解释.)
3. 时空相对性: 空间是事物之间的相互关系; 时间是事物关系变化的度量.
4. 宇宙不是由物质构成, 而是由事件的因果过程构成. 宇宙是一个因果关系的网络. 其中每一部分的性质由其与其它部分的关系决定.
5. 相互作用: 如果  $A$  作用于  $B$ ,  $B$  也一定会作用于  $A$ . (时空告诉物质如何运动; 反过来, 物质告诉时空如何弯曲. 而牛顿的绝对时空是单向的, 时空指引物质运动, 物质却无法影响时空.)
6. 背景独立性: 基础物理理论不应该依赖于固定不变的背景, 即只建模宇宙的一部分, 而把其余部分视为不随其它要素变化的背景.



## 李·斯莫林对莱布尼茨“关系主义”宇宙观的解释

7. 事件独特性: 每个事件都是可分辨的, 所以, 任何两个事件的因果过去都是不同构的.
8. 没有任何两个瞬间完全相同, 从这个意义上说, 时间是真实的.
9. 对称性是背景依赖的性质. 由于“不可分辨者的同一性”, 不存在终极的对称性. 对称性, 要么是近似的, 要么是破缺的. (对称性, 比如时间反演不变性, 源于粗粒化过程中对事件独特性的忽略.)
10. 开放系统的能量流, 倾向于驱动系统向组织度更高的结构演化. (在熵最大的平衡态, 许多瞬间会不断复现.)
11. 观察者是宇宙的一部分.
12. 观察者只能观测到宇宙的部分信息. 未来的观察者可以看到更多信息.
13. 逻辑与观察者有关. 不能假定每个陈述非真即假. 至少有三类: 一类可判断为真, 一类可判断为假, 一类无法判断.

## 龙树菩萨的“关系主义”宇宙观

- ▶ 此有故彼有，此生故彼生；此无故彼无，此灭故彼灭。  
— 事物彼此依存。
- ▶ 未曾有一法，不从因缘生；是故一切法，无不是空者。  
— 没有一种现象（一法）不是依赖于各种因缘（条件与关系）而产生的。因此，一切现象都没有独立的实体性（无自性），这就是“空”。
- ▶ 若法因缘生，是法性实空；若此法无性，云何而可得？  
— 如果事物是因缘（关系）和合而生的，那么，这个事物的本性就是真正的空（无自性）；既然它没有独立不变的本性，又怎么能认为它是真实可得、独立存在的呢？
- ▶ 诸法不自生，亦不从他生，不共不无因，是故知无生。  
— 事物既不自己产生自己，也不由他者产生，也不由自己和他者共生，也不随机产生，所以，事物没有独立实体，一切都是关系。
- ▶ 因缘所生法，我说即是空，亦为是假名，亦是中道义。  
— “事物”不过是在特定关系网中被赋予的一个“假名”。
- ▶ 因物故有时，离物何有时？物尚无所有，何况当有时？  
— 因为事物的变化，才有时间。事物都没有独立的自性（缘起性空），时间怎么能成为独立的实体呢？

思想实验能否提供关于现实世界的知识?


1. 通过思想实验直接感知柏拉图理念世界的真理?
2. 思想实验是对真实实验的模拟?
3. 大脑通过可视化想象模拟现实世界?
4. 思想实验是伪装的 (演绎/归纳) 逻辑论证?
5. 思想实验揭示了我们概念系统中的漏洞, 并帮助我们重构概念系统?
6. 思想实验是对心理模型的操纵?

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
  - 存在
  - 时空
  - 因果
  - 自由意志
  - 因果、实在、自由意志
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

## 亚里士多德 — “四因说”

*“Knowledge is the object of our inquiry, and we do not have knowledge of a thing until we have grasped its ‘why’, that is to say, its cause.”*  
— Aristotle



# Type Causation & Token Causation


- ▶ **General/Type Causation:** 抽烟导致肺癌
- ▶ **Actual/Token Causation:** 张三抽了三十年烟, 导致了肺癌

因果解释:


“昨天晚上是下着暴雨, 我也喝醉了, 但是, 事故的真正原因是, 车的刹车片坏了.”

## Actual Causation vs PN, PS

- ▶ 实际因果在构建解释、责任划分中起重要作用.
- ▶ 必要概率 PN 和充分概率 PS 只依赖  $Y_x(u)$ , 关注因果模型的全局特征 (输入-输出), 无视因果过程.
- ▶ 实际因果必须考虑因果过程.
  - $B = 1$  是  $Y = 1$  的原因吗? 第一个例子中 “是”, 第二个 “不是”.



|                       |
|-----------------------|
| $Y = A \vee B$        |
| $A = 1, B = 1, Y = 1$ |



|                              |
|------------------------------|
| $C = B \wedge \neg A$        |
| $Y = A \vee C$               |
| $A = 1, B = 1, C = 0, Y = 1$ |

$$A \vee C \equiv A \vee (B \wedge \neg A) \equiv A \vee B$$



# Philosophy — Process Approach to Causality?

- ▶ A **causal process** is a world line of an object which possesses a conserved quantity.
- ▶ A **causal interaction** is an intersection of world lines which involves exchange of a conserved quantity.
- ▶  $A$  causes  $B$  if there is a transfer of energy or momentum from  $A$  to  $B$ .





1. 相同过程, 不同因果?

process?

counterfactual?

2. 开关是灯亮的原因, 传输了啥?

3. 欲望导致行动, 传输了啥?



caused (Mean = 86.7)

didn't cause (Mean = 18.6)


# Philosophy — Probabilistic Approaches to Causality?

► **Reichenbach:**  $C$  causes  $E$ , iff,

1.  $C$  is earlier than  $E$ ,  $t_C < t_E$ ,
2.  $P(E | C) > P(E | \neg C)$ ,
3. there is no event  $S$  (earlier than or simultaneous with  $C$ ) that  $S$  screens off  $C$  from  $E$ .

$$\neg \exists S : P(E | C \wedge S) = P(E | S)$$

**Remark: Simpson paradox**



- **Cartwright:**  $C$  causes  $E$ , iff,  $P(E | C \wedge B) > P(E | \neg C \wedge B)$  for all background context  $B$ .<sup>3</sup>
- **Dupré:** “average degree of causal significance”:

$$\sum_B P(B) [P(E | C \wedge B) - P(E | \neg C \wedge B)]$$

---

<sup>3</sup>Background context: all causal factors for  $E$  that excludes  $C$  and the effects of  $C$ .

# Suppes' Genuine Cause — Probabilistic Approach

- ▶ **Suppes' *prima facie* cause:**  $C$  is a *prima facie* cause of  $E$  iff
  1.  $t_C < t_E$
  2.  $P(C) > 0$
  3.  $P(E | C) > P(E | \neg C)$
- ▶ **Suppes' first *spurious* cause:**  $C$ , a *prima facie* cause of  $E$ , is a *spurious* cause iff there exists  $S$  such that
  1.  $t_S < t_C < t_E$
  2.  $P(C \wedge S) > 0$
  3.  $P(E | C \wedge S) = P(E | S)$
  4.  $P(E | C \wedge S) \geq P(E | C)$
- ▶ **Suppes' second *spurious* cause:**  $C$ , a *prima facie* cause of  $E$ , is a *spurious* cause iff there is a partition  $\mathcal{E}$  and for every  $S \in \mathcal{E}$ 
  1.  $t_S < t_C < t_E$
  2.  $P(C \wedge S) > 0$
  3.  $P(E | C \wedge S) = P(E | S)$

**Remark:**  $\varepsilon$ -spurious:  $|P(E | C \wedge S) - P(E | S)| < \varepsilon$
- ▶ **Suppes' genuine cause:** nonspurious *prima facie* cause.

- ▶ 概率因果依赖时序关系.
- ▶ 对背景变量的选择有死循环的风险.
  - 若要求对环境的完整描述, 则会将概率性关系化归为确定性方程.
  - 若描述的过于粗略, 则会导致伪相关和其它混杂效应.
  - 而要求背景变量与所讨论的变量“因果相关”则导致死循环.
  - 如何选择合适的背景变量, 类似于如何找寻合适的控制变量去混杂, 这必须依赖因果.

## Philosophy — Regularity Approaches to Causality?

- ▶ **Mill's Sufficient** Condition:  $C$  causes  $E$  iff  $C \rightarrow E$ .
- ▶ **Hobbes's Necessary** Condition:  $C$  causes  $E$  iff  $\neg C \rightarrow \neg E$ .
- ▶ **Ramsey Test**:  $C \Box \rightarrow E$  should be believed iff, after suspending judgment on  $C$  and  $E$ ,  $E$  is believed as a result of assuming  $C$ .

$$C \Box \rightarrow E \in K \iff E \in K * C$$

- ▶ **Wright's NESS** condition:  $C$  causes  $E$  iff  $C$  is a Necessary Element of a Sufficient Set for  $E$ .
  1.  $C \wedge X$  is  $E$ 's sufficient condition.  $C \wedge X \rightarrow E$
  2.  $X$  is not sufficient for  $E$ .  $X \nrightarrow E$

# Mackie's Actual Causation — Regularity Approach

- ▶ **Mackie's INUS Condition:** (insufficient but necessary part of a causal condition that is itself unnecessary but sufficient of the effect)
  1.  $C \wedge X$  is  $E$ 's sufficient but unnecessary condition.
  2.  $C$  is not sufficient for  $E$ .  $C \nrightarrow E$
  3.  $X$  is not sufficient for  $E$ .  $X \nrightarrow E$

$$(C \wedge X) \vee Y \leftrightarrow E$$

Example: 为什么造假币? 因为不会造真币、没钱又不会赚钱...

- Why  $E$ ?
- $C_1$  rather than  $C_2$ , since  $C_1 = \operatorname{argmax}_C P(E | C)$ ?

- ▶ **Mackie's actual causation:**

- ▶  $C$  is at least an INUS condition of  $E$
- ▶  $C$  was present
- ▶ Components of  $X$  were present
- ▶ Every disjunct in  $Y$  not containing  $C$  as a conjunct was absent

# Lewis' Actual Causation — Counterfactual Approach

## Definition (But-For Cause)

$X = x$  is a **but-for** cause of  $Y = y$  in  $(M, u)$  iff


1.  $M, u \models X = x \wedge Y = y$
2. there exist  $x' \neq x$  and  $y' \neq y$  such that  $M, u \models [X = x']Y = y'$

## Definition (Actual Causation — Lewis 1973)


$X = x$  is an actual cause of  $Y = y$  in  $(M, u)$  iff there exists a sequence of variables  $Z_1 = X, \dots, Z_n = Y$  s.t.  $Z_i = z_i$  is a but-for cause of  $Z_{i+1} = z_{i+1}$  for  $i = 1, \dots, n - 1$ .

**Remark:** Is causation transitive?


# Neuron Diagrams



- ▶  $X$  的激活抑制了  $Y$



- ▶  $X$  不激活则  $Y$  激活




- ▶  $X^n$  多个信号方能激活  $X$





## Example — Double Prevention




|                              |
|------------------------------|
| $B = \neg C$                 |
| $A = \neg B$                 |
| $Y = A$                      |
| $C = 1, B = 0, A = 1, Y = 1$ |

- ▶ Alice  $A$  is planning to hack Yuri's  $Y$  computer.
- ▶ Bob  $B$  launches a missile at Alice's city.
- ▶ Carl  $C$  shoots down the missile.
- ▶ Alice hacks Yuri's computer, without any knowledge that Bob and Carl even exist.
- ▶ Nevertheless, Carl caused Yuri's computer being hacked.
- ▶  $C = 1$  is an actual cause of  $Y = 1$ .

## Example — Transitivity?

1.  $A$  is a cause of  $B$
2.  $B$  is a cause of  $C$
3.  $A$  is a cause of  $C$ ?

- ▶ Alice 医生治好了 Bob 的致命疾病  $A$ .
- ▶ Bob 出院时  $B$ , 被车撞死  $C$ .




|                       |
|-----------------------|
| $B = A$               |
| $C = \neg A \vee B$   |
| $A = 1, B = 1, C = 1$ |

# Woodward's Manipulability Theory of Causation

1.  $X$  is a **total cause** of  $Y$  iff changing  $X$  will change  $Y$  for some values of all other variables that aren't descendants of  $X$ .
2.  $X$  is a **direct cause** of  $Y$  iff changing  $X$  will change  $Y$  when all variables other than  $X$  and  $Y$  are fixed at some values.
3.  $X$  is a **contributing cause** of  $Y$  iff there is a directed path from  $X$  to  $Y$  such that, changing  $X$  will change  $Y$  when the variables not on this path are fixed at some values.

| Type of cause | What is held fixed                                     |
|---------------|--------------------------------------------------------|
| total         | all other variables not descendants of $X$             |
| direct        | all variables other than $X$ and $Y$                   |
| contributing  | all variables not on one directed path from $X$ to $Y$ |



$$\begin{aligned} A &= X \\ B &= \neg X \\ Y &= A \vee B \end{aligned}$$

$X$  is not a total or a direct cause, but a contributing cause of  $Y$


# Woodward's Manipulability Theory of Causation

## Definition (Actual Causation — Woodward 2003)


$X = x$  is an actual cause of  $Y = y$  in  $(M, u)$  iff

1.  $M, u \models X = x \wedge Y = y$
2. there is a directed path from  $X$  to  $Y$  such that, some intervention on  $X$  will change  $Y$  when the variables not on this path are fixed at their actual values.

**Example:** A boulder falls ( $B$ ) and rolls toward the hiker ( $R$ ). The hiker ducks ( $D$ ) so that he does not get hit ( $\neg H$ ).



$$H = R \wedge \neg D$$



$$H = B \wedge \neg D$$

**Problem:**  $B = 1$  is a Woodward cause of  $H = 0$  in  $G_1$  but not in  $G_2$ .

# Deterministic Actual Causation — Halpern 2016

## Definition (Actual Causation — Halpern 2016)


$X = x$  is an actual cause of  $Y = y$  in  $(M, u)$  iff

1.  $M, u \models X = x \wedge Y = y$
2. there is a set of variables  $W \subset V \setminus X, Y$  and a setting  $x'$  of  $X$  such that, if  $M, u \models W = w$ , then

$$M, u \models [X = x', W = w]Y \neq y$$

3.  $X$  is minimal, i.e. no subset of  $X$  satisfies the above conditions.

## Example (Conjunctive Causes)




|                       |
|-----------------------|
| $F = M \wedge O$      |
| $M = 1, O = 1, F = 1$ |

► **问题:**  $O = 1$  是  $F = 1$  的原因吗?

## Example (Overdetermination)

A prisoner is shot by two soldiers.




|                       |
|-----------------------|
| $Y = A \vee B$        |
| $A = 1, B = 1, Y = 1$ |

► **问题:**  $A = 1$  是  $Y = 1$  的原因吗?

### Example (Bogus Prevention — (Counter-)Example?)

The assassin refrains from poisoning the potential victim's coffee  $A = 0$ .  
But the bodyguard puts an antidote into the coffee anyway  $B = 1$ .




► **问题:**  $B = 1$  是  $Y = 1$  的原因吗?



### Example (Early Preemption)

Alice and Bob are aiming rocks at a window. Bob will throw his rock if Alice doesn't throw hers.




|                       |
|-----------------------|
| $B = \neg A$          |
| $Y = A \vee B$        |
| $A = 1, B = 0, Y = 1$ |

► **问题:**  $A = 1$  是  $Y = 1$  的原因吗?

## Example

### Example

Gang leader Alice orders Bob to join her in shooting Yuri.




|                       |
|-----------------------|
| $B = A$               |
| $Y = A \vee B$        |
| $A = 1, B = 1, Y = 1$ |

► **问题:**  $B = 1$  是  $Y = 1$  的原因吗?

## Example — Early Preemption

**Example1** Alice poisons the victim's coffee. Bob puts an antidote into the coffee. Bob would not have put antidote into the coffee if Alice had not poisoned the coffee.

**Example2** Alice puts an antidote into the victim's coffee. Bob poisons the coffee. Bob would not have poisoned the coffee if Alice had not administered the antidote.




|                       |
|-----------------------|
| $B = A$               |
| $Y = \neg A \vee B$   |
| $A = 1, B = 1, Y = 1$ |

|                       |
|-----------------------|
| $B = A$               |
| $Y = A \vee \neg B$   |
| $A = 1, B = 1, Y = 1$ |

- ▶ **问题:**  $A = 1$  是  $Y = 1$  的原因吗?
- ▶ **问题:**  $B = 1$  是  $Y = 1$  的原因吗?

## Example (Simple Switch)



$$A = X$$


$$B = \neg X$$

$$Y = A \vee B$$

$$X = 1, A = 1, B = 0, Y = 1$$

► **问题:**  $X = 1$  是  $Y = 1$  的原因吗?


## Remark



- ▶ 左图  $X = 1$  不是  $Y = 1$  的原因, 右图则 “是”.
- ▶ 因此, 判断实际因果时, 不能只考虑实际的因果过程  $X = 1 \rightarrow A = 1 \rightarrow Y = 1$ , 还要考虑反事实的路径  $X = 0 \rightarrow B = 1 \rightarrow Y = 1$ .

## Discussion

### Example (Frankfurt-Case)



$$BM = \neg AP$$


$$AS = BM$$

$$Y = AP \vee AS$$

$$AP = 1, BM = 0, AS = 0, Y = 1$$

- ▶ Alice 下毒杀死了 Yuri. 若 Alice 不下毒, Bob 会操控 Alice 枪杀 Yuri.
- ▶ **问题:**  $AP = 1$  是  $Y = 1$  的原因吗?

## Example (Realistic Switch)



$$A = U_A \wedge X$$

$$B = U_B \wedge \neg X$$


$$Y = A \vee B$$

$$U_A = 1, U_B = 1, X = 1, A = 1, B = 0, Y = 1$$

► **问题:**  $X = 1$  是  $Y = 1$  的原因吗?

## Example (Hall's "short circuit")

A hiker is on a hike ( $A$ ). A boulder falls ( $B$ ) and rolls toward the hiker ( $R$ ). The hiker ducks ( $D$ ) so that he does not get hit ( $\neg H$ ) and continues the hike ( $Y$ ).



$$R = B$$

$$D = B$$

$$H = R \wedge \neg D$$

$$Y = A \wedge \neg H$$


$$A = 1, B = 1, R = 1, D = 1, H = 0, Y = 1$$

► **问题:**  $B = 1$  是  $Y = 1$  的原因吗?



### Example (Short Circuit)

Alice 在 Yuri 的咖啡里放了解药  $A$ . Bob 恶作剧放了毒药  $B$ , 但如果 Alice 不放解药的话 Bob 是不会下毒的. 毒药和解药中和  $C$ , Yuri 没死  $\neg Y$ .




|                              |
|------------------------------|
| $B = A$                      |
| $C = A \wedge B$             |
| $Y = B \wedge \neg C$        |
| $A = 1, B = 1, C = 1, Y = 0$ |

► **问题:**  $A = 1$  是  $Y = 0$  的原因吗?

## Example (Early Preemption)

A desert traveler Yuri has two enemies, Alice and Bob. Bob poisons Yuri's canteen. Alice, unaware of Bob's action, shoots and empties the canteen. Whose action is the actual cause of Yuri's death?



$$C = A$$


$$D = B \wedge \neg A$$

$$Y = C \vee D$$

$$A = 1, B = 1, C = 1, D = 0, Y = 1$$

- ▶ **问题:**  $A = 1$  是  $Y = 1$  的原因吗?
- ▶ **问题:**  $B = 1$  是  $Y = 1$  的原因吗?

# Early Preemption vs Short Circuit




$$C = A$$

$$D = B \wedge \neg A$$

$$Y = C \vee D$$

$$A = 1, B = 1, C = 1, D = 0, Y = 1$$



$$C = A$$

$$\bar{D} = \bar{B} \wedge \neg A$$

$$\bar{Y} = C \vee \bar{D}$$

$$A = 1, \bar{B} = 1, C = 1, \bar{D} = 0, \bar{Y} = 1$$


$\cong$

- ▶  $A_{\text{开枪}} = 1$  是  $Y_{\text{死亡}} = 1$  的原因.
- ▶  $A_{\text{滚石}} = 1$  不是  $\bar{Y}_{\text{死亡}} = 1$  的原因?

## Discussion

**Example1** Alice and Bob are aiming rocks at a window. Bob will throw his rock if Alice doesn't throw hers.

**Example2** A boulder rolls toward a hiker ( $A$ ). The hiker ducks ( $B$ ) so that he survives ( $Y$ ).




|                       |
|-----------------------|
| $B = \neg A$          |
| $Y = A \vee B$        |
| $A = 1, B = 0, Y = 1$ |

|                       |
|-----------------------|
| $B = A$               |
| $Y = \neg A \vee B$   |
| $A = 1, B = 1, Y = 1$ |

► **问题:**  $A = 1$  是  $Y = 1$  的原因吗?


## 归不归责问题: 同 (实际) 因不同责?

**Example1** Alice 和 Bob 准备砸玻璃. 如果 Alice 不出手, Bob 必出手.





|                       |
|-----------------------|
| $B = \neg A$          |
| $Y = A \vee B$        |
| $A = 1, B = 0, Y = 1$ |

**Example2** 卧底 Alice 如果不杀死 Yuri 同志, 敌人 Bob 必会虐杀 Yuri.



|                       |
|-----------------------|
| $B = \neg A$          |
| $Y = A \vee B$        |
| $A = 1, B = 0, Y = 1$ |

1. Yuri 有 2 美元. 跟踪 Yuri 的窃贼 Alice 发现了另一个跟踪 Yuri 的窃贼 Bob. Alice 果断下手, 抢在 Bob 之前偷了 Yuri 1 美元. Bob 本打算偷窃 Yuri 2 美元, 但因为被 Alice 捷足先登, 只能作罢.
2. 卧底 Alice 如果不杀死 Yuri 同志, 敌人 Bob 必会虐杀 Yuri.



$$A = B$$

$$C = A$$

$$D = B \wedge \neg C$$

$$Y = C + 2(1 - C)(1 - D)$$

$$A = 1, B = 1, C = 1, D = 0, Y = 1$$


同 (机制) 因 (果图) 不同责?

# Discussion: Overdetermination vs Bogus Prevention

行不行赏问题: 同 (实际) 因不同赏?


**Example1** A prisoner is shot by two soldiers  $A = B = 1$ .

**(Counter-)Example2** The assassin refrains from poisoning the potential victim's coffee  $\bar{A} = 1$ . But the bodyguard puts an antidote into the coffee anyway  $B = 1$ .



► **问题:**  $B = 1$  是  $Y = 1$  的原因吗?

## Example — Overlapping



- ▶ Alice 的咒语有 50% 的概率同时把 King 和 Yuri 变成青蛙;
- ▶ Bob 的咒语有 50% 的概率同时把 Queen 和 Yuri 变成青蛙.

**问题:**  $B = 1$  是  $Y = 1$  的原因吗?



# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
  - 存在
  - 时空
  - 因果
  - 自由意志
  - 因果、实在、自由意志
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会


- ▶ 自由意志与决定论相容吗?
- ▶ 上帝有自由意志吗?
- ▶ 什么的自由? — 行动自由? 选择自由? 意志自由?

## 自由意志与决定论相容吗？

1. 如果我们的行动是出于自由意志, 那么, 我们本可以选择不这么做;
2. 如果决定论为真, 那么我们的任何行动都是由过去状态和自然法则所决定的, 这意味着我们无法选择不这么做;
3. 因此, 如果决定论为真, 我们就无法按照自由意志行动.

# 决定论 vs 自由意志

|     | 自由    | 无自由  |
|-----|-------|------|
| 决定  | 相容论   | 硬决定论 |
| 非决定 | 自由意志论 | -    |



决定论 vs 非决定论 vs 宿命论

## Examples

1. 你在不知情的情况下被锁在了一个房间里, 里面还有你心仪的女孩, 你开心的与她聊天, 完全不想离开. 你留下来的行为是自由的吗?
2. 患有广场恐惧症的张三选择不出门, 他不出门的行是自由的吗?
3. 被邪教洗脑的人是自由的吗?
4. 半夜, 狱警偷偷把犯人牢房的锁打开了, 犯人没有离开.....
5. 汉尼拔医生在爱丽丝的大脑里植入了一个芯片, 可以监控和控制爱丽丝的活动. 爱丽丝对此一无所知. 如果爱丽丝表现出任何投票给特朗普的倾向, 汉尼拔医生会控制爱丽丝投票给希拉里. 结果, 爱丽丝自行决定投了希拉里一票. 爱丽丝的投票行为是自由的吗?
6. 你强烈渴望杀死张三, 于是埋伏了刺客, 约定摔杯为号, 你的渴望如此强烈, 以至于紧张到手抖碰掉了杯子.....

## 法兰克福的“分层相容论”

You do  $X$  freely iff:

1. your action is controlled by your first-order desire, and
  2. your first-order desire is controlled by your second-order desire
- ▶ 指向事物或事态的欲望叫一阶欲望.
  - ▶ 指向一阶欲望的欲望叫二阶欲望.  
— 有自我意识才能形成二阶欲望.
  - ▶ 一个人可以有二阶欲望但不一定想依照它行动.
  - ▶ “希望某个一阶欲望支配自己的行动”的二阶欲望叫二阶意欲.
  - ▶ 一个人的行动是自由的当且仅当这个行动是由他确定无疑地认同的他自己的二阶意欲所致使的.  
— 这要求二阶欲望是自主选择的而不是外部设定的.

## 法兰克福的“分层相容论”

1. 一个讨厌自己的毒瘾却摆脱不掉的瘾君子是不自由的.
  2. 一个放浪的只按照对毒品的一阶欲望行事的瘾君子也是不自由的.
  3. 设想一个快乐的瘾君子, 对自己的毒瘾心甘情愿, 当对毒品的欲望消退时, 还会渴望恢复, 他是自由的.
- ▶ 叔本华: “人能为其所欲为, 但不能欲其所欲”.
  - ▶ 按照法兰克福的定义, 如果叔本华是对的, 人有自由意志吗?

**问题:** 如果一个人的二阶意欲是被植入的呢?

## A More Sophisticated Form of Compatibilism?


You do  $X$  freely iff:

1. you do  $X$ , and
2. doing  $X$  is what you want and choose to do, and
3. what caused you to do  $X$  was your wanting and choosing to do it, and
4. if you had chosen to do something other than  $X$ , nothing would have prevented you, so you would have succeeded in doing that other thing
5. if there were (or you had) a good reason for you to act otherwise, you would have chosen to act otherwise.

理由响应机制



## 二阶意欲？ 理由响应机制？ — ToDo



- ▶  $S_0$ : 历史状态
- ▶  $S$ : 未来状态
- ▶  $\tilde{S}$ : 状态机制 (环境演化的动力学)
- ▶  $A$ : 行动
- ▶  $\tilde{A}$ : 行动机制 (一阶欲望驱动, 未经反思)
- ▶  $U$ : 效用
- ▶  $\tilde{U}$ : 效用机制 (反映可能的一阶欲望)
- ▶  $D$ : 意向选择
- ▶  $\tilde{D}$ : 决策机制 (机制响应, 反思, 反映二阶意欲对一阶欲望的响应)

上帝有自由意志吗？

## 莱布尼茨的自由意志

- ▶ 莱布尼茨是个自由意志相容论者, 他区分了行动自由和意志自由.
- ▶ 一个不受阻碍地运动的小球也是行动自由的, 但它没有意志自由.
- ▶ 一个自愿留在上锁房间里的人, 虽然没有行动自由, 但仍然可以是意志自由的.
- ▶ 意志自由不是问“我是否能不受约束地做我想做的”, 而是问“我的意志本身是否有足够的独立性”.
- ▶ **意志自由是基于理性的慎思 (摆脱了激情和本能的奴役)、遵循知性所认可的善的动机而进行的自我决定, 这动机驱动其倾向而非逻辑必然做某种决定.**
- ▶ 被决定  $\neq$  必然. 在必然和偶然之间, 其被决定的方式是有区别的.
  - 逻辑和形而上学的后果是必然的.
  - 物理和道德的后果有倾向性但不必然.
- ▶ 被决定指: 给定当前状态, 未来只有一种自然发展可能.
- ▶ 莱布尼茨的决定论不是基于“事件因果”, 而是基于“主体因果”.
  - 即使被决定, 但只要主体的行为是由自己的本性决定的, 而不是由外部事件决定的, 就依然是自由的.

# Free Will

- ▶ “Indifference arises from ignorance, and the wiser a man is, the more determined he is toward the most perfect.”
- ▶ “Monads are freer in proportion as they are further removed from indifference and more self-determined...Now in so far as we have lights, and act according to reason, we shall be determined by the perfections of our own nature, and consequently we shall be freer in proportion as we are less embarrassed as to our choice...Let us not pretend to that harmful liberty, of being in uncertainty and perpetual embarrassment, like that Ass of Buridan, who, being placed at an equal distance between two sacks of wheat, and having nothing that determined him to go to one rather than the other, allowed himself to die of hunger.”
- ▶ “The more monads are determined by themselves, and removed from indifference, the more perfect they are.”

free will  $\propto$  perfection =  $f(\text{variety, simplicity})$



*do actions to be removed from indifference*

# Buridan's Ass



“There are no two individuals indiscernible from each other, because if there were, God and nature would act without reason.”

## 纽康姆问题 — machine simulated consciousness

- ▶ 白盒: 透明, 里面有一千块钱.
- ▶ 黑盒: 不透明, 可能有一百万, 也可能什么都没有.
- ▶ 你可以选择只拿黑盒, 也可以两个都拿.
- ▶ 女巫预测到你只拿黑盒, 就会在里面放一百万; 如果预测你两个都拿, 就会让黑盒空着.
- ▶ 女巫从来没有出过错.

|             |       | predicted choice |       |
|-------------|-------|------------------|-------|
|             |       | both             | black |
| your choice | black | 0                | 100   |
|             | both  | 0.1              | 100.1 |

## 确凿/占优原则 Dominance Principle?

- ▶ 如果黑盒有钱, 只拿黑盒得一百万, 两个都拿得一百万零一千. 两个都拿.
- ▶ 如果黑盒没钱, 只拿黑盒得 0 元, 两个都拿得一千. 两个都拿.
- ▶ 黑盒或者有钱或者没钱.
- ▶ 两个都拿.

$$\frac{A \vee \neg A \quad \begin{array}{c} [A] \\ \vdots \\ B \end{array} \quad \begin{array}{c} [\neg A] \\ \vdots \\ B \end{array}}{B} \quad ?$$


# Evidential Decision Theory & Causal Decision Theory

## ► Evidential Expected Utility

$$V_{\text{evidential}}(A = a) = \sum_e P(e \mid A = a)u(a, e)$$

## ► Causal Expected Utility

$$V_{\text{causal}}(A = a) = \sum_e P(e \mid \text{do}(A = a))u(a, e)$$



$$P(e \mid a) = \sum_s P(e \mid s, a)P(s \mid a)$$

$$P(e \mid \text{do}(a)) = \sum_s P(e \mid s, a)P(s)$$



## Evidential Expected Utility vs Causal Expected Utility

$$P(\text{predict-both} \mid \text{both}) = 1 \quad P(\text{predict-both} \mid \text{do}(\text{both})) = P(\text{predict-both})$$

$$P(\text{predict-black} \mid \text{black}) = 1 \quad P(\text{predict-black} \mid \text{do}(\text{black})) = P(\text{predict-black})$$

$$P(\text{predict-black} \mid \text{both}) = 0 \quad P(\text{predict-black} \mid \text{do}(\text{both})) = P(\text{predict-black})$$



$$P(\text{predict-both} \mid \text{black}) = 0 \quad P(\text{predict-both} \mid \text{do}(\text{black})) = P(\text{predict-both})$$

$$V_{\text{evidential}}(A = \text{both}) = \sum_e P(e \mid A = \text{both})u(e) = 0.1$$

$$V_{\text{evidential}}(A = \text{black}) = \sum_e P(e \mid A = \text{black})u(e) = 100$$

$$\begin{aligned} V_{\text{causal}}(A = \text{both}) &= \sum_e P(e \mid \text{do}(A = \text{both}))u(e) \\ &= P(\text{predict-both})0.1 + P(\text{predict-black})100.1 \end{aligned}$$

$$\begin{aligned} V_{\text{causal}}(A = \text{black}) &= \sum_e P(e \mid \text{do}(A = \text{black}))u(e) \\ &= P(\text{predict-both})0 + P(\text{predict-black})100 \end{aligned}$$



$$\begin{aligned}
 V(h_{<t}) &= \sum_{a_t e_t} u(h_{1:t}) P(a_t e_t \mid h_{<t}) \\
 &= \sum_{a_t e_t} u(h_{1:t}) P(e_t \mid h_{<t} a_t) P(a_t \mid h_{<t}) && \text{(Evidential/Causal)} \\
 &= \sum_{a_t e_t} u(h_{1:t}) P(a_t \mid h_{<t} e_t) P(e_t \mid h_{<t}) && \text{(Freedom)}
 \end{aligned}$$

# Functional Decision Theory[MEB23; YS18]

- Assume you possess an algorithm of your decision mechanisms (the predictor can also run your algorithm). You select your decision mechanism that produces the best outcome.

$$\pi^* = \operatorname{argmax}_{\pi} \mathbb{E}[U \mid \operatorname{do}(\Pi = \pi)]$$

## Example (Newcomb Problem)





Figure: EDT vs CDT vs FDT

# Twin Prisoner's Dilemma

- Assume you and your clone are arrested .....




- EDT: co-operate
- CDT: defect
- FDT: co-operate
- Updateful-FDT: co-operate

## Remark:

- 康德绝对律令? 依据那些你愿意所有人都遵守的普遍法则行事. (vs 待人如己) — 如果人人都像你一样 XX, 那 YY. 所以, 你不应该 XX.
- 规则功利主义?

## 行动 vs 事件


- ▶ 事件之间的分布关系通过概率刻画.
- ▶ 行动代表了能够扰动这些关系的干预措施.
- ▶ 原则上, 行动不是概率的一部分.
- ▶ 但对于 EDT 来说, 行动不具有特殊地位, 跟事件没有区别.
- ▶ 对于 CDT 来说, 行动非常特殊, 决策者有绝对的自由意志, 只更新行动的后果, 而无视行动的理由. CDT 适用于二元论 Agent, 主体独立于环境.
- ▶ 对于 FDT 来说, 行动也是特殊的, 它不同于事件, 行动只依赖于决策机制. 决策者拥有自由意志, 但不绝对. 信念的更新要考虑与决策机制关联的变量.



# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
  - 存在
  - 时空
  - 因果
  - 自由意志
  - 因果、实在、自由意志
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

## Local Hidden Variables & Bell Inequality



$P(a, b \mid x, y) = \sum_h P(a \mid x, h)P(b \mid y, h)P(h)$  entails the Bell inequality:


$$\begin{aligned} &\mathbb{E}[AB \mid X = -1, Y = -1] + \mathbb{E}[AB \mid X = -1, Y = +1] + \\ &\mathbb{E}[AB \mid X = +1, Y = -1] - \mathbb{E}[AB \mid X = +1, Y = +1] \leq 2 \end{aligned}$$

where  $A, B, X, Y$  take values in  $\{+1, -1\}$ .

- ▶ 两个物理学家 Alice 和 Bob 在不同地点接收到来自共同源  $H$  的粒子. 变量  $A$  和  $B$  分别描述了 Alice 和 Bob 对接收到的粒子进行二项测量的结果.  $X$  是一个抛硬币实验, 决定了 Alice 从两个选项中进行哪种测量;  $Y$  对 Bob 也类似.
- ▶ 贝尔不等式在量子力学中被违反, 可以取到  $2\sqrt{2}$ .
- ▶ 这说明: 没有经典的随机变量  $H$  可以描述入射粒子的联合状态, 使得  $\{A, X\} \perp \{B, Y\} \mid H$ .
- ▶ 量子态不能由随机变量的值来描述. 它们是希尔伯特空间中的密度算符.

## Should we abandon locality, realism, or freedom?<sup>4</sup>

- ▶  $Y_{x_1, x_2}(u_i)$  表示在联合干预  $(x_1, x_2)$  下, 粒子  $u_i$  的潜在结果. 这个记号蕴含了实在性假设, 即假定了潜在结果是个体  $u_i$  的固有属性.
- ▶ 局域性假设: 对一个粒子自旋的测量值不会受到另一个粒子自旋测量方向的影响, 即  $Y_{x_1, x_2}(u_1) = Y_{x_1}(u_1), Y_{x_1, x_2}(u_2) = Y_{x_2}(u_2)$ .
- ▶ 在局域性、实在性、和自由意志假设下, 贝尔不等式成立.
- ▶ 但在量子力学中, 贝尔不等式可以取到  $2\sqrt{2}$ .




<sup>4</sup>Chaves et al. "Causal Networks and Freedom of Choice in Bell's Theorem."




# 放弃预设？还是需要完全不同的“量子因果”？


因果超光速传递？




超决定？




逆时因果？



# 惠勒的延迟选择实验



(a) 只有一个半透镜1




(b) 插进半透镜2

- ▶ C 处不插半透镜, 光子走 A 或 B, 被 D1 或 D2 探测到, 呈现粒子性.
- ▶ C 处插半透镜, 光子同时走 A 和 B 两条路, 在 D1 和 D2 处发生相长干涉或相消干涉, 呈现波动性.
- ▶ 如果你等到光子已踏上中途, 再延迟决定在 C 处是否插入半透镜呢?  
— 不插, 粒子; 插, 波动.
- ▶ 有两种解释: 1. 你改变了过去. 2. 光子事先“知道”你未来的选择.
- ▶ 若 1, 逆时因果? 参与式人择宇宙? 若 2, 你还有自由意志吗?

# 宇宙通过观察而创生

有个青年这样说：  
上帝一定觉得太稀奇  
如果他发现这棵树  
总是总是在庭院里  
即使没有人在那里

答：  
亲爱的年轻人  
你的惊讶才稀奇  
有我一直在庭院里  
所以这树才能够  
一直一直在这里  
因为看着它的是  
你忠诚的  
老上帝



惠勒参与式的人择宇宙：起初，一切都处于朦胧的叠加态，众多可能的叠加态之一发展出了复杂的生命意识，生命意识通过观察将叠加态坍缩为了我们所知的这个宇宙。

## 惠勒 20 问游戏

惠勒和他的朋友们玩 20 问游戏.

1q 惠勒: 是动物吗?

1a 朋友 A: 不是.

2q 惠勒: 是白色的吗?

2a 朋友 B: 是的.

... 惠勒: .....

... 朋友: .....

20q 惠勒: 是云彩吗?

20a 朋友们: 是的.

朋友们根本就没有事先约定一个词. 他们一致同意, 每个人都可以随意回答 — 只要他心里有一个能够和已有回答协调的答案.

- ▶ 没有一个独立于提问的词, 直到它被提问产生出来.  
— 所提的问题不同, 提问的顺序不同, 都可能导向另一个不同的词.
- ▶ 没有哪一个基本现象是一个现象, 直到它被测量记录为一个现象.

- ▶ 微观: 微观尺度的量子行为可能违背经典因果。
  - 如果真的像彭罗斯所认为的, 意识源于大脑神经元内部微管中的量子过程, 会怎样?
- ▶ 宏观: 经典因果起作用的地方. 比如在牛顿力学下, 物体运动是在固定背景结构下进行的, 是绝对时空舞台上上演的戏剧, 可以在保持其它演员不变的条件下, 干预某个演员的行为.
- ▶ 宇观: 大尺度下, 时空几何本身是动态的, 物体运动和时空结构相互影响. “时空告诉物质如何运动; 物质告诉时空如何弯曲.” 广义相对论的非线性和非局域性, 使得经典因果依赖的“保持其他条件不变”的假设失效.


**Problem:** 量子因果是否对 AGI 构成挑战?

## 题外话: 荣格的非因果的“同步性”

### Example

1914 年, 一位德国母亲为她的男婴照了相, 并将照片留在 A 市的照相馆冲洗. 第一次世界大战爆发, 她无法取回照片. 两年后, 她为了给刚出生的女儿拍照, 在 B 市买了一卷交卷. 照片冲洗出来后, 她发现底片曝光了两次, 她女儿的相片是在她儿子的底片上的又一次曝光!

**Remark:** 荣格认为, 巧合发生的可能性远大于随机概率, 背后有一种基于“意义”而非“因果”的非定域关联. (但这种关联无法用于预测.)



# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

什么是知识?

我们能知道什么?

如何知道?



# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
  - 知识的来源
  - 知识 vs 信念
  - 认知辩护
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 知识的种类

|       | 日常知识        | 科学知识          | 技术知识          | 伦理知识 | 数学知识              |
|-------|-------------|---------------|---------------|------|-------------------|
| 社会共同体 | 社会人群        | 科学家           | 工程师           | 社会群体 | 数学家               |
| 知识的对象 | 生活世界        | 自然界           | 人工自然          | 价值系统 | 抽象实体              |
| 知识的目标 | 处理日常生活问题    | 自然定律          | 社会效益          | 伦理规范 | 形式系统              |
| 知识的方法 | 教育、传媒、试错、交往 | 经验理性<br>可证实标准 | 工具理性、<br>决策逻辑 | 博弈论  | 形式演绎              |
| 真值条件  | 常识、习惯、科学    | 实验、理论<br>批判   | 应用标准、<br>专利审查 | 社会认同 | 系统可靠性、<br>完备性、简单性 |

# 知识的种类

- ▶ 事实性知识: 采用直接表示的形式  
— 凡是猴子都有尾巴
- ▶ 过程性知识: 描述做某件事的过程  
— 摩托车修理
- ▶ 行为性知识: 不直接给出事实本身, 只给出它在某方面的行为  
— 微分方程、(事物的内涵)
- ▶ 实例性知识: 只给出一些实例, 知识藏在实例中
- ▶ 类比性知识: 既不给出外延, 也不给出内涵, 只给出它与其它事物的某些相似之处  
— 比喻、谜语
- ▶ 常识性知识
- ▶ 元知识: 有关知识的知识. 如何使用知识的知识

Know that, Know whether, Know what, Know who, know where, Know how, Know why ...

# Paradox of Knowledge

- ▶ If you don't know it, how could you possibly recognize it when you see it?
- ▶ If you do know it, you don't need to look for it.
- ▶ So why should we bother attempting to gain knowledge?

## What does “true” mean?

说是者为非, 或非者为是, 是假的; 说是者为是, 或非者为非, 是真的.  
— 亚里士多德

|                        |                                                             |
|------------------------|-------------------------------------------------------------|
| Correspondence Theory  | corresponding to the facts                                  |
| Coherence Theory       | cohering with our other beliefs                             |
| Pragmatist Theory      | being useful to believe                                     |
| Verification Theory    | being verified                                              |
| Ideal Consensus Theory | being what we'd agree to under cognitively ideal conditions |
| Redundancy Theory      | “It's true that $A$ ” is just a wordy way to assert $A$     |

# 什么是“真”？

► To be true is to be provable.

— Kolmogorov

►  $\ulcorner \text{snow is white} \urcorner$  is true iff snow is white.

— Tarski's "*T*-schema"


What is "truth"? — Are all truths knowable?

1. *formally correct*  $\forall x(\text{True}(x) \leftrightarrow \varphi(x))$

2. *materially adequate*  $\varphi(\ulcorner p \urcorner) \leftrightarrow p^*$

where  $\ulcorner p \urcorner$  is the name of a sentence  $p$  of  $\mathcal{L}$ , and  $p^*$  is the translation of  $p$  in the meta-language  $\mathcal{L}'$ .

$\text{True}(\ulcorner W(s) \urcorner) \leftrightarrow \text{White}(\text{snow})$




## 分析 vs 先验 vs 必然

1. 分析真理: 根据其所包含的语词的意义为真, 而不需要依赖外部世界的事实.  
综合真理: 其真假不仅取决于词义, 还取决于世界实际是如何的.
  2. 先验真理: 不需要借助感官经验验证而知其为真.  
后验真理: 借助感官经验才能确知其为真.
  3. 必然真理: 在所有可能世界中都为真.  $\Box p$   
偶然真理: 在现实世界中为真, 但存在其为假的可能世界.  $p \wedge \Diamond \neg p$
- 
1. 分析 vs 综合 — 语义学划分  
— 单身汉是未婚的男人
  2. 先验 vs 后验 — 认识论划分  
—  $1 + 1 = 2$
  3. 必然 vs 偶然 — 形而上学划分  
—  $A \leftrightarrow A$

**问题:** 三者彼此之间是什么关系?

# Classical Empiricism




**Figure:** Locke, Berkeley, Hume: The only source of knowledge of the external world is experience.

- ▶ How is knowledge of the external world possible?
- ▶ How is knowledge of the future based only on past experience possible?



# Rationalism



**Figure:** Descartes: There can be certain knowledge based on pure reason alone.

a priori knowledge = certain knowledge independent of experience.

# Immanuel Kant 1724-1804


|           | a priori | a posteriori |
|-----------|----------|--------------|
| analytic  | ✓        | ×            |
| synthetic | ?        | ✓            |



Synthetic a priori statement = truth is established by reason alone (a priori) and contains factual content (synthetic).

## 数学是“先验综合判断”吗？

- ▶ 苏格拉底：“我只知道我什么也不知道。”
- ▶ 笛卡尔：“我思故我在”。我们可以通过内省获得部分知识的确定性，但关于外部世界的知识呢？
- ▶ 休谟：放弃吧。推理有两种：基于观念关系的证明；关于事实的或然推理。关于外部世界的知识是因果陈述。因和果在过去的恒常连接不蕴含未来的恒常连接，因为未来与过去不相似也不矛盾。因此，因果陈述是涉及事实的综合判断，但我们无法通过经验事实非循环的论证未来与过去的相似性。因此，关于因果的知识我们也无法后验的获知。
- ▶ 康德：虽然因果陈述是综合的，但我们可以先验的获知因果。因为因果结构既是关于外部世界的原始材料的，又是内嵌在人类心灵的认知模式的一部分。“人为自然立法。”



**康德** 数学是先验综合判断。

- ▶ 几何 — 空间的纯粹直观
- ▶ 算术 — 时间的纯粹直观

**高斯** 几何是后验的。（黎曼几何，空间曲率）

**弗雷格** 算术是分析的。  $1 + 1 = 2$

|    | 先验 | 后验 |
|----|----|----|
| 分析 | 数学 | ×  |
| 综合 | ×  | 物理 |

Table: 康德之前

|    | 先验       | 后验 |
|----|----------|----|
| 分析 | 逻辑       | ×  |
| 综合 | 算术<br>几何 |    |

Table: 康德

|    | 先验 | 后验             |
|----|----|----------------|
| 分析 | ×  | ×              |
| 综合 | ×  | 逻辑<br>算术<br>几何 |

Table: 蒯因、普特南


|    | 先验               | 后验   |
|----|------------------|------|
| 分析 | 逻辑<br>算术<br>纯粹几何 | ×    |
| 综合 | ×                | 应用几何 |

Table: 逻辑实证主义

|    | 先验               | 后验   |
|----|------------------|------|
| 分析 |                  | ×    |
| 综合 | 逻辑<br>算术<br>纯粹几何 | 应用几何 |

Table: Martin-Löf

# Kant



**Figure:** Kant: All structure and order (causal, temporal, spatial, etc) is imposed on raw data by filters ("forms") already present in the mind.

人🕶️为自然立法!

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
  - 知识的来源
  - 知识 vs 信念
  - 认知辩护
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 知识 vs 信念 Knowledge vs Belief

1.  $K(p \rightarrow q) \rightarrow Kp \rightarrow Kq$

2.  $Kp \rightarrow p$

3.  $Kp \rightarrow KKp$

4.  $\neg Kp \rightarrow K\neg Kp$

1.  $Kp \rightarrow Bp$

2.  $Bp \rightarrow KBp$

3.  $\neg Bp \rightarrow K\neg Bp$

4.  $Bp \rightarrow BKp$  (strong belief)

1.  $B(p \rightarrow q) \rightarrow Bp \rightarrow Bq$

2.  $Bp \rightarrow \neg B\neg p$

3.  $Bp \rightarrow BBp$

4.  $\neg Bp \rightarrow B\neg Bp$

|                                                 |
|-------------------------------------------------|
| $Bp \overset{?}{\leftrightarrow} \neg K\neg Kp$ |
|-------------------------------------------------|

# 摩尔悖论 Moore's Paradox

Are all truths knowable?

It's raining but I don't know it's raining.

$$\vdash \neg K(p \wedge \neg Kp)$$

1.  $K(p \wedge \neg Kp)$

Assumption

2.  $Kp$

3.  $K\neg Kp$

4.  $\neg Kp$

$$Kp \rightarrow p$$

5.  $Kp \wedge \neg Kp$

6.  $\neg K(p \wedge \neg Kp)$



# 摩尔悖论 Moore's Paradox

Are all truths believable?

It's raining but I don't believe it's raining.

$$\vdash \neg B(p \wedge \neg Bp)$$

1.  $B(p \wedge \neg Bp)$

Assumption

2.  $Bp \wedge B\neg Bp$

$$B(p \wedge q) \rightarrow Bp \wedge Bq$$

3.  $Bp$

4.  $BBp$

$$Bp \rightarrow BBp$$

5.  $B\neg Bp$

6.  $BBp \wedge B\neg Bp$

7.  $\neg(BBp \wedge B\neg Bp)$

$$(Bp \rightarrow \neg B\neg p) \equiv \neg(Bp \wedge B\neg p)$$

8.  $\neg B(p \wedge \neg Bp)$

## Against Negative Introspection?

1.  $\neg p \wedge BKp$

suppose you falsely believes that you know  $p$

2.  $\neg Kp$

knowledge implies truth

3.  $K\neg Kp$

negative introspection

4.  $B\neg Kp$

knowledge implies belief

5.  $B\perp$

$$\neg Kp \rightarrow K\neg Kp \quad ? \quad (\text{Ax 5})$$

$$\neg K\neg Kp \rightarrow Kp \quad ? \quad (\text{Ax 5})$$

$$\neg K\neg Kp \rightarrow K\neg K\neg p \quad ? \quad (\text{Ax 4.2})$$

# Margin for Error and Against Positive Introspection?

$p_n : n$  grains is a heap.

1.  $K\neg p_n$

Assumption

2.  $K(p_{n+1} \rightarrow \neg K\neg p_n)$

Margin for Error

3.  $K(K\neg p_n \rightarrow \neg p_{n+1})$

4.  $K\neg p_n \rightarrow KK\neg p_n$

Positive Introspection

5.  $K\neg p_{n+1}$

?

$$Kp \rightarrow KKp \quad ?$$

Remark: 谷堆悖论是连锁悖论, 下面这个是连锁悖论吗: 不存在哺乳动物, 因为哺乳动物的母亲也必须是哺乳动物.


# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
  - 知识的来源
  - 知识 vs 信念
  - 认知辩护
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# Gettier Problem: Is Justified True Belief Knowledge?

Knowledge = Justified + True + Belief?

$$Kp \stackrel{?}{\leftrightarrow} p \wedge Bp \wedge JBp$$





1. Smith believes “**Bob owns a Ford**”.
2. He was told this by Bob.
3. Bob then sells his Ford.
4. Meanwhile Bob wins a Ford in a raffle.

# “我相信这句话是真的”是知识吗？

A: 我相信句子 A 是真的.

- ▶ 信则真. 你相信 A 这件事本身使得 A 为真, 你的信念也得到了证成.
- ▶ 但不信则假啊 😊

# Epistemic Justification



- ▶ Internalist theory of epistemic justification.
  - ▶ Foundationalism
    - $S$ 's belief  $p$  is justified iff either
      - (a)  $p$  is a basic belief; or
      - (b)  $p$  is a non-basic belief justified inferentially by  $S$ 's basic beliefs.
  - ▶ Coherentism
    - $S$ 's belief  $p$  is justified iff  $S$  has a coherent set of beliefs which includes  $p$ .
- ▶ Externalist theory of epistemic justification.
  - ▶ Reliabilism
    - $S$ 's belief  $p$  is justified iff  $p$  is produced by a reliable cognitive process.



## 证成难题

1. 一个信念只能由另一个信念证成.
  2. 不允许循环证成.
  3. 证成链条是有穷的.
  4. 有被证成的信念.
- ▶ 上面四个命题不相容.
  - ▶ 基础论者拒斥 1.
  - ▶ 融贯论者拒斥 2.
  - ▶ 皮尔士拒斥 3.
  - ▶ 取消论者拒斥 4.



# David Lewis 1941–2001

## Counterfactual Causation



$$w \models A \Box \rightarrow B \quad v \not\models A \Box \rightarrow B$$

$$w \models A \Box \rightarrow B \iff \llbracket A \rrbracket_w \subset \llbracket B \rrbracket$$

其中,  $\llbracket A \rrbracket_w$  为与  $w$  邻近的  $A$  世界集.

## Indicative vs Counterfactual Conditional

- ▶ If Oswald did not kill Kennedy, someone else did.
- ▶ If Oswald had not killed Kennedy, someone else would have.

## Antecedents and Consequents

$$\frac{\neg A}{A \rightarrow B} \quad \checkmark \qquad \frac{\neg A}{A \Box \rightarrow B} \quad \times$$

I did not strike the match  
if I had struck the match, it would have turned into a feather ?

$$\frac{B}{A \rightarrow B} \quad \checkmark \qquad \frac{B}{A \Box \rightarrow B} \quad \times$$

George W. Bush won the 2004 United States presidential election ?  
If the newspapers had discovered beforehand that  
Bush had an affair with Al Gore, he would still have won

## Antecedent Strengthening


$$\frac{A \rightarrow C}{A \wedge B \rightarrow C} \quad \checkmark$$

$$\frac{A \Box \rightarrow C}{A \wedge B \Box \rightarrow C} \quad \times$$

If I went to the beach, I would have a good time

---

If I went to the beach and got attacked by a shark, I would have a good time



The closest world where I go to the beach and get attacked by a shark is much further removed from the actual world than the closest world where I go to the beach is.

# Transitivity

$$\frac{A \rightarrow B \quad B \rightarrow C}{A \rightarrow C} \quad \checkmark$$

$$\frac{A \Box \rightarrow B \quad B \Box \rightarrow C}{A \Box \rightarrow C} \quad \times$$

$$\frac{A \Box \rightarrow B \quad A \wedge B \Box \rightarrow C}{A \Box \rightarrow C} \quad \checkmark$$

If I were king, I would wear a crown

If I wore a crown, people would find me ridiculous

---


If I were king, people would find me ridiculous ?

# Contraposition

$$\frac{A \rightarrow B}{\neg B \rightarrow \neg A} \quad \checkmark$$

$$\frac{A \Box \rightarrow B}{\neg B \Box \rightarrow \neg A} \quad \times$$

If Goethe hadn't died in 1832, he would (still) be dead now  
If Goethe weren't dead now, he would have died in 1832 ?



# Nozick's Truth-Tracking Condition

## Nozick's Truth-Tracking Condition

$S$  knows that  $p$  iff:

1.  $p$  is true;
2.  $S$  believes that  $p$ ;
3. if  $p$  were not true,  $S$  would not believe that  $p$ ;
4. if  $p$  were true,  $S$  would believe that  $p$ .

$$Kp := p \wedge Bp \wedge (\neg p \Box \rightarrow \neg Bp) \wedge (p \Box \rightarrow Bp)$$

## Kripke's counter-example — Fake Barn Country

- ▶ Smith is driving in a country containing fake barns.
- ▶ The fake barns are painted green.
- ▶ In the midst of these fake barns is one real barn, which is painted red.
  1. Smith looks up and happens to see the real barn. **"I see a red barn."**
  2. What if Smith looks up and forms the belief **"I see a barn"**?
- ▶ Smith knows "there is a red barn", but doesn't know "there is a barn".

## 怀疑论 vs 反事实

$S_1$  I know "I have hands".  $Kp$

$S_2$  I know if "I have hands" then "I am not a brain in the vat".  $K(p \rightarrow q)$

$S_3$  I don't know that "I am not a brain in the vat".  $\neg Kq$

— 我不知道“我不是缸中脑” $\neg Kq$ , 因为, 在距离“我是缸中脑”的最邻近世界里, 我会错误地相信“我不是缸中脑”。

- ▶ Nozick's definition of Knowledge

$$Kp := p \wedge Bp \wedge (\neg p \Box \rightarrow \neg Bp) \wedge (p \Box \rightarrow Bp)$$

then  $K$  is not closed under known entailment.

$$Kp, K(p \rightarrow q) \not\models Kq$$

- ▶ By Sosa's definition,

$$Kp := p \wedge Bp \wedge (Bp \Box \rightarrow p) \wedge (p \Box \rightarrow Bp)$$

then

$$Kp, K(p \rightarrow q) \models Kq$$

**德性知识论:** 你知道  $p$ , 当且仅当,  $p$  是真的, 你相信  $p$ , 你是因为自己优秀的认知能力和品德才相信的  $p$ .



## 逻辑全知 vs 怀疑论

$$\frac{A}{KA} \quad \frac{A \rightarrow B}{KA \rightarrow KB} \quad \frac{A \leftrightarrow B}{KA \leftrightarrow KB} \quad \frac{K(A \rightarrow B) \quad KA}{KB}$$

$S_1$  I know "I have hands".  $Kp$

$S_2$  I know if "I have hands" then "I am not a brain in the vat".  $K(p \rightarrow q)$

$S_3$  I don't know that "I am not a brain in the vat".  $\neg Kq$

### Possible "solutions":

- ▶ Impossible worlds: inconsistent alternatives
- ▶ Awareness:  $K$  = awareness + implicit knowledge
- ▶ Algorithmic knowledge:  $K$  = answer by algorithm
- ▶ Timed knowledge: reasoning takes time (polynomial time)
- ▶ Neighbourhood semantics: still problematic
- ▶ Counterfactual implication:
  - ▶ Nozick:  $Kp := p \wedge Bp \wedge (\neg p \Box \rightarrow \neg Bp) \wedge (p \Box \rightarrow Bp)$
  - ▶ Sosa:  $Kp := p \wedge Bp \wedge (Bp \Box \rightarrow p) \wedge (p \Box \rightarrow Bp)$

## Aaronson 基于计算复杂性的回答


- ▶ 你**知道**微积分/西班牙语/桥牌游戏的规则吗?
- ▶ 你是否拥有一个内部**算法**, 凭它你能在**合理的时间**内回答某种形式的一大类 (可能是无限的) 问题?
- ▶ 你之所以能“知道”(know-that)  $1591 = 43 \times 37$ , 却又同时不“知道”1591 的素因子, 是因为当我们说知道这些问题的答案时, 我们其实指的是知道怎么 (know-how) 回答它们.
- ▶ 知道一个快速的乘法算法却不知道一个快速的因子分解算法, 两者之间并不矛盾, 即使我们把关于算法的知识建模成演绎封闭的<sup>5</sup>.

— Scott Aaronson: *Why Philosophers Should Care About Computational Complexity*

---



<sup>5</sup>可以以公理化的方式刻画一个多项式时间可计算的函数类, 其中的函数在满足公理的运算下仍然属于这个函数类.

# 怀疑论 vs 反怀疑论



# Hilary Putnam 1926-2016

- ▶ Putnam's "brain in a vat" experiment: (no) real experience.



- ▶ Even if you're a brain in a vat, you can still reason, "I think, therefore I am."
- ▶ Brain in a vat which thinks that it is a brain in a vat?

# 普特南反对语义内在论的“孪生地球”论证

语义内在论:

1. 知道一个语词的意义, 就是处在某种心理状态之中.
2. 一个语词的意义 (内涵) 决定它的外延.

“孪生地球”论证:

- ▶ “孪生地球”与地球一模一样, 除了地球上被称为“水”的物质是  $H_2O$ , 孪生地球上被称为“水”的物质是  $XYZ$ .
- ▶ 那时的人还不懂分子结构.
- ▶ 当 Alice<sub>地球</sub> 说“水”的时候, Alice<sub>孪生</sub> 也说“水”.
- ▶ 虽然两者拥有完全相同的心理状态, 但一个“水”指称  $H_2O$ , 一个“水”指称  $XYZ$ .
- ▶ 所以, 普特南认为: “意义不在头脑中”.

# 普特南基于语义外在论的反怀疑论论证

假设:

1. 仅当一个词与一个对象之间存在某种因果关联时, 该词才指称该对象. (Causal Constraint)
2. “ $p$ ” 是真的当且仅当  $p$ . (Disquotation Principle)

论证:

1. My language disquotes.
2. In BIVese, “brains in a vat” does not refer to brains in a vat.
3. In my language, “brains in a vat” is a meaningful expression.
4. In my language, “brains in a vat” refers to brains in a vat. (1,3)
5. My language is not BIVese. (2,4)
6. If I am a BIV, then my language is BIVese.
7. I am not a BIV.

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 伦理理论

1. 如何评判行动?
2. 如何评估目标选择?
3. 如何生成道德上可接受的行动?
  - ▶ **Deontology**: 行动具有内在的伦理价值 (康德主义).
  - ▶ **Asimovian**: 尽可能避免伤害 (通过作为或不作为).
  - ▶ **Utilitarianism**: 最大化总效用.
  - ▶ **Do-no-harm**: 不做任何会导致不良后果的事.
  - ▶ **Do-no-instrumental-harm**: 不做任何会导致不良后果的事, 除非它是一种非预期的副作用.
  - ▶ **Principle of double effect**: 一个行动是 **可接受的** 当且仅当
    1. 行动本身必须是善的、或道德中立的
    2. 主体必须有意达成好的后果, 坏的后果是副效应
    3. 不能以实现目标为手段产生坏的后果
    4. 好的效果必须大于坏的效果, 要权衡利弊, 减少伤害



## 一些伦理理论的比较


|            | 后果论                            | 道义论                       | 美德伦理学                  |
|------------|--------------------------------|---------------------------|------------------------|
| 行动的正<br>当性 | 最大化效用                          | 符合道德准则                    | 有德的人会采取的行动             |
| 价值导向       | 善                              | 正当 (履行道德义务)               | 德性                     |
| 焦点         | 后果                             | 行动                        | 动机                     |
| 核心问题       | 重要的是结果, 而不是行动                  | 人作为目的, 而不是手段              | 行为人的品格                 |
| 实践         | 大多数人的幸福 (means-ends reasoning) | 遵循准则 (rational reasoning) | 人的品格 (social practice) |
| 规范         | 要好报                            | 做好事                       | 做好人                    |

# Utility Population Problem




## Thanos


假设灭霸打一个响指, 世界人口会减少一半, 但留下的人及其后代的幸福感都会倍增.



Do most people value higher the well-being of people they know better?



The ethical egoist



## 合作 vs 信任

- ▶ 组织分别给了你和 Alice 12 元钱.

$$(12, 12)$$

- ▶ 你可以选择把其中的 0/4/8/12 元分给 Alice.
- ▶ 不管你给了 Alice 多少钱, 组织都会再给 Alice 两倍于此的钱.

$$(12 - x, 12 + 3x)$$

- ▶ 至于 Alice 是否愿意与你分享一部分她的钱, 分享多少, 完全取决于她自己.

$$(12 - x + y, 12 + 3x - y)$$


- ▶ 你愿意给 Alice 多少钱?

## 效用有框架效应 — Tversky and Kahneman

1. 某种传染病预计将导致 600 人死亡, 现有两种救助方案:
  - 1.1 方案 A: 200 人获救
  - 1.2 方案 B:  $1/3$  的概率 600 人全都获救  
 $2/3$  的概率无人生还
2. 某种传染病预计将导致 600 人死亡, 现有两种救助方案:
  - 2.1 方案 C: 400 人死亡
  - 2.2 方案 D:  $1/3$  的概率没有人死亡  
 $2/3$  的概率 600 人全都死亡

**Problem:** 道德直觉靠谱吗?

## 偏好逆转



# 平等的世界是合理的吗？

## 权重的偏倚

- ▶ 设想有一个绝对平等的世界.
- ▶ 这里的公民不会有任何道德上的偏袒, 对所有人都一视同仁.
- ▶ 假如有一人必须面对一个痛苦的选择: 是救他的儿子还是救一个陌生人?
- ▶ 他只能用掷硬币的方式来决定.....
- ▶ 你愿意成为那个世界的公民吗?

**Problem:** “偏袒”是道德缺陷还是道德能力？

# 平等 vs 公平

## Problem (最后通牒博弈)

- ▶ 我出 100 块钱, 供两个人分.
- ▶ 一人负责提议分成比例, 另一人只能选择同意还是拒绝.
- ▶ 只有一次机会.
- ▶ 若同意, 则按比例分; 若拒绝, 则谁也得不到.

**Remark:** 匿名惩罚 → 利他主义

1. 平等原则: 平均分配
2. 公平原则: 按劳分配或按需分配等方式

**Remark:** 计划经济更注重平等, 市场经济更注重公平.



# 荒岛遗言 vs 张三的选择


## 功利主义 vs 契约论

1. 功利主义的代表人物: 休谟 (Hume)、亚当·斯密 (Adam Smith)、边沁 (Bentham)、穆勒 (John Stuart Mill)、西奇威克 (Sidgwick)、埃奇沃思 (Edgeworth) 等...
    - 福利、效率
  2. 契约论的代表人物: 霍布斯 (Hobbes)、洛克 (Locke)、卢梭 (Rousseau)、康德 (Kant)、罗尔斯 (Rawls) 等...
    - 权利、自由
    - 目的的正当性不能证成手段的正当性.
- ▶ 张三和李四被困于一个荒岛上.
  - ▶ 垂死的李四对张三留下遗言: 倘若张三能活着回去, 就将自己的遗产用于建立一个野猫收容所.
  - ▶ 张三答应了.
  - ▶ 但当获救后, 张三认为: 如果把该遗产用于修建孤儿院, 将产生更大福利.

# 海萨尼<sup>6</sup> PK 罗尔斯

期望效用最大化 vs 最大化最小原则

1. 假设有 A 和 B 两个感染了严重肺炎的患者, B 还是癌症晚期, 现有的抗体只能救一个人, 应该优先救谁?
2. 在分配某份教育资源时, 假设可以用它让有数学天赋和兴趣的 A 学习数学, 或者用它让严重弱智的 B 学会系鞋带, 应该优先考虑谁?



---

<sup>6</sup> John C. Harsanyi: Can the Maximin Principle Serve as a Basis for Morality? A Critique of John Rawls's Theory. 1975.

海萨尼: 最大化最小原则能够成为道德的基础吗? — 对罗尔斯理论的批判.

当面临道德困境时, 你会以抛硬币的方式做选择吗?  
抛硬币本身是一种伦理立场吗?

# 哪一种情况更好?

功利主义 vs 美德伦理学

1. 想象宇宙中只存在一个有感觉的生物, 他错误地相信其他感觉生物正在遭受剧烈的折磨. 这种想法给他带来巨大的愉悦.
2. 想象宇宙中只存在一个有感觉的生物, 他错误地相信其他感觉生物正在遭受剧烈的折磨. 不过他会为受到折磨的同胞而感到悲伤.

# 功利主义 vs 美德伦理学

卡尔维诺《黑羊》

- ▶ 从前有个国家，人人是贼。晚上，每人都去邻居家行窃。
- ▶ 人们就这样幸福地生活在一起。
- ▶ 某天，有个君子到了该地定居。晚上，他不出门行窃，却呆在家里读书。
- ▶ 贼来了，见灯亮着，就没进去。
- ▶ 这样持续了一段时间。人们感到有必要向他挑明一下，纵使他自己想怎样就怎样，可他没理由妨碍到别人啊。他晚上不出门，就意味着有人第二天饿肚子。
- ▶ 从此君子也晚上出门，但他不行窃。他走到桥上看流水。
- ▶ 不到一星期，君子就被偷的家徒四壁了。
- ▶ 君子不从别人那里偷东西，总有人家里没被动过。不久，那些没有被偷过的人发现自己变富了。而那些跑到君子家里去行窃的人，却发现里面空空如也，于是就变穷了。
- ▶ 富人也想去桥上看流水，也不想再行窃了，他们想：“我们雇那些穷的去替我们行窃吧。”
- ▶ 以免因遭穷人行窃而返贫，富人又雇了穷人中的最穷者来帮助他们看守财富，这就意味着要建立警察局和监狱。
- ▶ 在君子出现后没几年，人们就不再谈什么偷窃或被偷窃了，而只说穷人和富人。
- ▶ 但他们个个都还是贼。
- ▶ 唯一正直的只有开头的那个君子，但他不久便死了，饿死的。

# Contents

1. Introduction

2. 逻辑与论证

3. 形而上学

4. 认识论

5. 伦理学

6. 美学


7. 科学哲学

8. 心灵哲学

9. 语言哲学

10. 博弈与社会

- ▶ “美” 和 “真” 是什么关系?
- ▶ 美是主观的还是客观的?
- ▶ 什么是艺术? 艺术是模仿? 是形式? 是情感表现?
- ▶ AI 生成的内容算不算艺术?



# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会



科学哲学对科学有用吗？

科学哲学对科学家的用处跟鸟类学对鸟的用处差不多.

— 费曼

# The Unreasonable Ineffectiveness of Philosophy

- ▶ 费曼：“砖头算不算本质客体？”
- ▶ 哲学家甲：“一块砖是独特的砖，是怀特海所说的本质客体。”
- ▶ 哲学家乙：“本质客体的意思并不是指个别的砖块，而是指所有砖块的共有的普遍性质，换句话说，‘砖性’才是本质客体。”
- ▶ 哲学家丙：“不对，重点不在砖本身，‘本质客体’指的是，当你想到砖块时内心形成的概念。”
- ▶ 就像所有关于哲学家的故事一样，最终以一片混乱收场。好笑的是，在先前的那么多次讨论中，他们从来没有问过自己，像简单的砖块究竟是不是“本质客体”。

— 费曼

哲学旨在感动那些混淆晦涩与深刻的人。

— 温伯格

# The Unreasonable Ineffectiveness of Philosophy

- ▶ 如果一个哲学家说的东西是对的, 那一定是微不足道的; 如果不是微不足道时, 那一定是错的. — 高斯
- ▶ 哲学难道不是用蜜写成的吗? 乍一看, 很精彩, 再一看, 除了一团浆糊, 什么都没留下. — 爱因斯坦
- ▶ 哲学之于科学, 就像手淫之于性: 它廉价、易实现, 甚至有些人也更喜欢它.
- ▶ 哲学家就像瞎子, 在漆黑的夜里, 举着熄灭的蜡烛, 跑到黑暗的地下洞穴, 找寻一只并不存在的黑猫, 然后大呼小叫: “我脖子被猫爪挠啦!”
- ▶ 哲学可以作为跨学科研究的“催化剂”或“调味品”. 但“哲学内部”问题像是智力“黑洞”, 吸收大量智力, 却无任何输出. — *Johan van Benthem*
- ▶ 哲学偶尔有用, 能让我们免受另外一些哲学立场的影响. — 温伯格

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学  
科学划界  
科学解释  
归纳确证
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

如何明确划分“科学”与“非科学”(特别是“伪科学”、“形而上学”和“宗教”)的界限?

# 科学划界问题

**问题:** 如何明确划分“科学”与“非科学”(特别是“伪科学”、“形而上学”和“宗教”)的界限?

- ▶ 逻辑实证主义: 可证实性标准
- ▶ 波普尔: 可证伪性标准
- ▶ 库恩: 范式下的解谜
  - 占星术之所以不是科学, 不是因为它不能做出预言, 而是因为它没有一个能够指导从业者去分析失败原因、逐步解决谜题的范式和累积性研究传统.
- ▶ 拉卡托斯: 科学研究纲领
  - 硬核与保护带. 对保护带的修改能带来新预测就是进步的纲领, 为了应付反例而不断做事后解释, 无法预测新事实就是退化的纲领.
- ▶ 费耶阿本德: 怎么都行. 划界企图是一种“科学沙文主义”.
- ▶ 劳丹等人的消解论与多元主义. 一刀切是伪问题. 没有单一标准, 但有多元特征: 信仰权威教条, 缺乏自我纠正机制, 过度依赖事后解释, 选择性接受证据, 隔离于主流科学...

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学  
科学划界  
科学解释  
归纳确证
8. 心灵哲学
9. 语言哲学
10. 博弈与社会



## 预测 vs 解释


- ▶ 科学是为了预测还是为了解释?
- ▶ 预测本身就是目标? 亦或重要的是理论的解释力, 而预测仅仅是理论可证伪性的需要?
  - 一个能精准预测未来, 但无法解释 '为什么' 的 AI, 算不算真正的智能?

# 科学解释

## 1. Hempel 的覆盖律模型 (演绎律则/归纳统计): 定律提供解释

$$\frac{\begin{array}{c} \text{普遍定律} \\ \text{初始条件} \end{array}}{\text{现象}} \qquad \frac{\begin{array}{c} P(B \mid A) = r \\ A_i \\ B_i \end{array}}{[r]}$$

## 2. Salmon 的因果模型: 原因提供解释



## 3. Kitcher 的统一性模型: 理论提供解释<sup>7</sup>

一个理论具有统一性, 是指它能最大化适应广度、简洁性、严格性.

- ▶ 适应广度衡量其可推导出的结论数量.
- ▶ 简洁性衡量的是作为前提假说的公理集合的大小.
- ▶ 严格性衡量的是其应用范围的边界.

<sup>7</sup>统一性模型用理论替代了覆盖律模型中的“普遍定律”, 强调全局的系统整合性.

## 覆盖律解释

**问题:** 为什么滑冰运动员把双臂收向身体时会旋转得更快?

角动量守恒定律:  $L_i = L_f$

运动员不与外物作用:  $L_i = I_i \omega_i, L_f = I_f \omega_f$

运动员有非零的初始角动量:  $L_i > 0$

运动员收紧手臂时, 质点到旋转轴的距离  $r$  变小, 转动惯量  $I = mr^2$  变小:  $I_f < I_i$

---

运动员的旋转角速度变大:  $\omega_f > \omega_i$

## 归纳统计解释

大多数患有链球菌性咽喉炎的人用了青霉素后都很快康复了

张三患有链球菌性咽喉炎

张三用了青霉素

---

张三很快会康复

大多数患有耐青霉素的链球菌性咽喉炎的人用了青霉素后都不会很快康复

张三患有耐青霉素的链球菌性咽喉炎

张三用了青霉素

---

张三不会很快康复

- ▶ 上面两个归纳论证是否足够强?
- ▶ 哪个更可信? 为什么?

## 覆盖律解释的“相关性”问题

服用了避孕药的男人不会怀孕

张三是男人


张三服用了避孕药

---

张三不会怀孕

## 覆盖律解释的“对称性”问题


- ▶ **问题:** 为什么旗杆影子的长度为  $l$ ?
- ▶ 因为太阳的高度角为  $\theta$ , 光线沿直线传播, 旗杆的高度为  $h$ , 所以影子的长度为  $l = h \cot \theta$ .



- ▶ 但是, 同理, 我们也可以用影子的长度  $l$  解释旗杆的高度  $h = l \tan \theta$ .
- ▶ 然而, 我们通常只会用原因解释结果, 而不会用结果解释原因.
- ▶ 所以, 旗杆高度对影子长度的解释是一种因果解释.

## 因果机制解释


- ▶ **问题:** 飞机起飞时, 机舱内的氦气球往哪个方向飘?



- ▶ 飞机加速, 空气分子由于惯性往后积聚, 后方气压高, 前方气压低, 氦气球往前飘.

## 统一性理论解释

- **问题:** 飞机起飞时, 机舱内的氦气球往哪个方向飘?




- 根据广义相对论等效原理, 一个局域匀加速参考系在物理效果上与处于反向均匀引力场中的静止参考系不可区分. 飞机向前加速时, 加速度产生的向后等效引力场与地球原本向下的重力场叠加, 在机舱内部形成了一个指向斜后下方的合成等效引力场. 因此, 氦气球会向斜前上方飘浮.



## 某些统一性理论解释未必显式的涉及因果机制

- ▶ **问题:** 为什么左手的手套无法戴到右手上?
- ▶ 因为, 在三维欧式空间中, 左手手套无法通过刚性运动, 变换到右手.<sup>8</sup>



---

<sup>8</sup>An object is an incongruent counterpart of another if they cannot be made to occupy the same place by rigid motions in a local region of space. Whether or not a mirror image is an incongruent counterpart depends on the properties of the space it is located in. If the space is 3-dimensional, or 2-dimensional but non-orientable, then "F" and its mirror image are congruent counterparts (e.g. a Möbius strip).

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
  - 科学划界
  - 科学解释
  - 归纳确证
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# Hypothetical-Deductive Confirmation 假设-演绎确证

$$H \rightarrow E$$

$$E$$

$$\overline{H \text{ is confirmed}}$$

- Which of  $H, A_1, \dots, A_n$  does  $E$  confirm?

$$H \wedge A_1 \wedge \dots \wedge A_n \rightarrow E$$

$$E$$

$$\overline{H \wedge A_1 \wedge \dots \wedge A_n \text{ is confirmed}}$$

- “苹果落地” 能否确证 “万有引力定律” 且 “嫦娥的身体是奶酪做的”?

$$H \rightarrow E$$

$$E$$

$$\overline{G \wedge H \text{ is confirmed?}} \quad [G \wedge H \rightarrow H]$$


- “苹果落地” 能否确证 “嫦娥的身体是奶酪做的”?

$$H \rightarrow E \vee H$$

$$E$$

$$\overline{H \text{ is confirmed}} \quad [E \rightarrow E \vee H]$$

# 波普尔《科学发现的逻辑》— 可证伪性



## Proposition (波普尔)

- ▶ 选择最简单的、没有被证伪的概括.
- ▶ 假说越简单, 越容易被证伪.
- ▶ 可证伪性与简单性一样是主观的, 没有客观标准.

$$\frac{H \wedge A_1 \wedge \cdots \wedge A_n \rightarrow E}{\neg E}$$

$$\neg H \vee \neg A_1 \vee \cdots \vee \neg A_n$$

$$\neg H? \neg A_1? \dots \neg A_n?$$

- ▶ 迪昂-奎因: 整体论, 怎么孤立证伪?
- ▶ 概率命题咋办?

# 不可证伪咋办?

- ▶ Alice 和 Bob 生了个孩子叫 Carly. Carly 喜欢吃草莓味的冰激凌, 第一次吃冰激凌就是草莓味的, 也只吃过草莓味的.
  1. Alice: 所有孩子都喜欢吃草莓味的冰激凌.
  2. Bob: 所有孩子都喜欢吃他们第一次尝到的冰激凌口味.
- ▶ 这两个猜想都可以看作待证伪的“自然律”.
- ▶ 你更相信哪一个?
- ▶ 如果宇宙中只有 Carly 这一个小孩呢?
- ▶ 宇宙学真的就只有一个样本.<sup>9</sup>
- ▶ “可证伪性”是背景依赖的?

---

<sup>9</sup>传统的科学范式, 需要状态空间、初始条件、自然律. 只有通过重复实验, 变换初始条件, 才能确定在不同初始条件下不变的自然律. 宇宙学不适用于该范式.

# Instance Confirmation 实例确证

**Basic idea:** “ $E$  confirms  $H$ ” means “ $E$  is an instance of  $H$ ”.



**Problem:** 看到一只黑乌鸦, 会增强你对“所有乌鸦都是黑的”的信心吗?

## Nicod 标准

对于全称命题“所有的  $A$  都是  $B$ ”,

1. 正例: “ $A$  且  $B$ ”的对象构成确证;
2. 反例: “ $A$  且  $\neg B$ ”的对象直接否定;
3. 中性: “ $\neg A$ ”的对象不相干, 不具有任何确证否定效力.

**Problem:** 你赞同 Nicod 标准吗?

## 实例确证 — 乌鸦怪论

- ▶ Nicod: 看到一只黑乌鸦会确证 “All ravens are black”. ?
- ▶ Hempel: 看到一只白鞋子会确证 “All ravens are black” 吗?

$$\neg Bx \wedge \neg Rx \text{ confirms } \forall x(\neg Bx \rightarrow \neg Rx)$$

$$\forall x(\neg Bx \rightarrow \neg Rx) \leftrightarrow \forall x(Rx \rightarrow Bx)$$

$$\neg Bx \wedge \neg Rx \text{ confirms } \forall x(Rx \rightarrow Bx)$$

修正早期逻辑经验主义: 对世界的理解不能只靠 “逻辑 + 经验”?

1. 世界一: 乌鸦都是黑的但非常罕见 (1/10000 是乌鸦, 其余是鞋子);
  2. 世界二: 只存在乌鸦, 但只有 10% 是黑乌鸦, 其余是白乌鸦.
- ▶ 看到一只黑乌鸦会确证 “并非所有乌鸦都是黑的”.
  - ▶ 如果我们把世界一改为乌鸦都是黑的且占比 9999/10000, 那么看到一只黑乌鸦会确证 “所有乌鸦都是黑的”.
  - ▶ “证据确证” 要考虑其他假设/可能世界!
- ▶ Goodman's New Riddle of Induction.

*grue* = green before 2050, and blue thereafter.

1. Are all emeralds green?
2. Are all emeralds grue?



# 大卫·休谟 1711-1776

- ▶ 《人性论》
- ▶ “理性和理性判断, 不过是不同感觉经验的习惯性联想”
- ▶ 归纳问题
- ▶ 天下没有免费的午餐定理
- ▶ 相关性 → 因果性
- ▶ 信念 → 知识
- ▶ 实然 → 应然
- ▶ 联结主义
- ▶ 类比
- ▶ 反事实因果





# 休谟论归纳

## Proposition (休谟)

- ▶ 推理有两种：基于观念关系的证明；关于事实的或然推理。
- ▶ 关于外部世界的知识是因果陈述。
- ▶ 因和果在过去的恒常连接不蕴含未来的恒常连接，因为“未来与过去不相似”不矛盾。
- ▶ 所以因果陈述是涉及事实的综合判断，但我们无法通过经验事实非循环的论证未来与过去的相似性。因此，关于因果的知识我们也无法后验的获知。
- ▶ 归纳不过是一种心理习惯。必然性只存在于人的心灵之中，而不在事件本身。

## Proposition (皮尔士)


除非受到另一种习惯的延伸的约束，否则习惯倾向于自我延伸。

**一个悲观主义者的归纳：**过去的所有理论都是错的，现在和未来的一切理论也都将是错的。

## 《三体》——“射手”假说 & “农场主”假说

**“射手”假说：** 有一名神枪手，在一个靶子上每隔十厘米打一个洞。设想这个靶子的平面上生活着一种二维智能生物，它们中的科学家在对自己的宇宙进行观察后，发现了一个伟大的定律：“宇宙每隔十厘米，必然会有一个洞。”

**“农场主”假说：** 一个农场里有一群火鸡，农场主每天中午十一点来给它们喂食。火鸡中的一名科学家观察这个现象，一直观察了近一年都没有例外，于是它也发现了自己宇宙中的伟大定律：“每天上午十一点，就有食物降临。”它在感恩节早晨向火鸡们公布了这个定律，但这天十一点食物没有降临，农场主进来把它们都捉去杀了。




# Leibniz-Wittgenstein-Goodman

## Proposition (莱布尼茨)

对于任意有穷多个点, 总有无穷多条曲线穿过它们. 对于任意有穷的数据集, 都有无穷多种归纳概括的方式.

连续性定律? 自然不做跳跃. 结果是原因的连续函数.



## Proposition (维特根斯坦)

任何有穷行动都与无穷多条规则相一致, 所以, 任何普遍规则都不能通过有穷多的示例学到.

## Proposition (Goodman)

*All emeralds discovered till 2050 are green, and blue thereafter.*

$$\text{Grue}(x) \iff (t < 2050 \rightarrow \text{Green}(x, t)) \wedge (t \geq 2050 \rightarrow \text{Blue}(x, t))$$

## Mill — Homogeneous Universe

### Proposition (Mill)

通过添加一些关于世界的原则，比如“未来与过去相似”，或“时空是均匀的”，*Induction* 可以被转化为 *Deduction*.

## 《三体》— 台球 — 三体质子干扰地球高能粒子对撞机

丁仪：我们总共进行了五次实验，其中四次在不同的空间位置不同的时间，两次在同一空间位置但时间不同。撞击实验的结果居然都一样！

汪淼：在五次实验中，两个球的质量是没有变化的；所处位置，当然是以球桌面为参照系来说，也没有变化；白球撞击黑球的速度向量也基本没有变化，因而两球之间的动量交换也没有变化，所以五次实验中黑球当然都被击入洞中。

丁仪：应该庆祝一下，我们发现了一个伟大的定律：物理规律在时间和空间上是均匀的。

⋮

汪淼：你真的相信物理规律在时空上不均匀？

丁仪：我什么都不知道。

# 莱辛巴赫的实用主义辩护

|     | 齐一 | 非齐一 |
|-----|----|-----|
| 归纳  | ✓  | ×   |
| 不归纳 | ✗  | ×   |

## 丑小鸭定理 — 分类需要偏置



|   | $x$ | $y$ | $z$ | $\varphi$ -Property                        | Weight |
|---|-----|-----|-----|--------------------------------------------|--------|
| 1 | 0   | 0   | 0   | $\neg \text{White} \wedge \neg \text{Hat}$ | 0      |
| 2 | 0   | 0   | 1   | $\neg \text{White}$                        | 1      |
| 3 | 0   | 1   | 0   | $\text{White} \wedge \text{Hat}$           | 0      |
| 4 | 0   | 1   | 1   | $\text{Hat}$                               | 0      |
| 5 | 1   | 0   | 0   | $\neg \text{Hat}$                          | 0      |
| 6 | 1   | 0   | 1   | $\neg \text{Hat} \vee \neg \text{White}$   | 0      |
| 7 | 1   | 1   | 0   | $\text{White}$                             | 1      |
| 8 | 1   | 1   | 1   | $\text{White} \vee \text{Hat}$             | 0      |

- ▶ 若以共享的  $\varphi$ -性质的数量来定义相似度, 则任意两个对象之间的相似度都一样.

$xy : 1, 2, 7, 8$

$xz : 1, 3, 6, 8$

$yz : 1, 4, 5, 8$

- ▶ 一只白天鹅和一只丑小鸭之间的区别, 并不比两只白天鹅之间的区别大.

- ▶ 庄子: 万物齐一. 佛教: 无分别心. 色即是空.
- ▶ Classification is impossible without some sort of bias.
- ▶ 相似性依赖偏置, 没有相似性就无法分类.

# 丑小鸭定理 [Wat69](渡边慧 Watanabe,1969)



- ▶ 设想由  $n$  个对象构成的宇宙  $X$ .
- ▶ 假设所有对象可区分:  $\forall xy \in X [\forall \varphi (\varphi(x) \leftrightarrow \varphi(y)) \rightarrow x = y]$ . Leibniz
- ▶ 至少需要  $m \geq \lceil \log_2 n \rceil$  个谓词  $P_1, \dots, P_m$  能把  $n$  个对象区分开.
- ▶ 每个对象  $x \in X$  的特征为:  $\varphi(x) := \bigwedge_{k=1}^m \pm P_k(x)$ .
- ▶ 对象的每个子集  $A \subset X$  都被一个  $\varphi$ -性质精确刻画
$$\varphi_A := \bigvee_{x \in A} \varphi(x) = \bigvee_{x \in A} \bigwedge_{k=1}^m \pm P_k(x).$$
- ▶ 任意两个对象  $x, y \in X$ , 共享  $2^{n-1}$  个  $\varphi$ -性质(同属于/同不属于  $2^{n-2}$  个分类), 在剩下的  $2^{n-1}$  个  $\varphi$ -性质上不同.
- ▶ 若所有  $\varphi$ -性质同等看待, 只以共享的  $\varphi$ -性质的数量来定义相似度, 则任意两个对象之间的相似度都一样.




# 偏置从何而来？ — 三个来源



- ▶ 丑小鸭定理: 没有偏置就无法分类.
- ▶ 没有免费午餐定理: 没有偏置就无法学习. 若“假设空间”上的概率分布是“块均匀的”, 那么, 相对于整个假设空间上的期望表现来说, 任何搜索或优化算法都是同样好或同样差的.
- ▶ 溯因  $\approx$  对假设空间搜索; 规划  $\approx$  对策略空间搜索. 高效搜索靠偏置.
- ▶ 偏置是
  1. 事物的“本性”?
    - 自然种类, 因果机制
  2. 语言框架“固化”的?
    - 古德曼绿蓝悖论: 什么性质“可投射”?
    - 蒯因: 世界的本体论划分依赖于语言里已经“固化”的权重.
  3. 还是人类“价值”导向的?
    - 渡边慧 Watanabe: “在生物学家眼里, 鲸鱼与大象同类; 在渔业管理者眼里, 鲸鱼与金枪鱼同类.” 认知是价值负载的.

## 偏置与学习: 语言 vs 世界 vs 价值

- ▶ 古德曼: 语言里编码了关于世界的背景知识.
- ▶ 蒯因: 世界的本体论划分依赖于语言里已经“固化”的权重.



- ▶ 关于世界/因果/价值的背景知识, 也需要“固化”到语言中. 语言应随学习过程而演化?

$$U \longrightarrow U' \longrightarrow U'' \longrightarrow \dots$$

- ▶ 认知是价值负载的, 行动是价值导向的. 价值对齐不应孤立的进行, 而应与溯因学习、语言演化协同进行?

## 休谟/古德曼.....

Problem (What's next?)

1, 2, 4, 7, ?

Solution

- A. 1, 2, 4, 7, 11, 16, ...
- B. 1, 2, 4, 7, 12, 20, ...
- C. 1, 2, 4, 7, 13, 24, ...
- D. 1, 2, 4, 7, 14, 28
- E. 1, 2, 4, 7, 1, 1, 5, 8, ...

# 休谟/古德曼.....

## Problem (What's next?)

1, 2, 4, 7, ?

## Solution

A. 1, 2, 4, 7, 11, 16, ...

$$a_{n+1} = a_n + n$$

B. 1, 2, 4, 7, 12, 20, ...

$$a_{n+2} = a_{n+1} + a_n + 1$$

C. 1, 2, 4, 7, 13, 24, ...

*"Tribonacci" sequence*

D. 1, 2, 4, 7, 14, 28

*divisors of 28*

E. 1, 2, 4, 7, 1, 1, 5, 8, ...

$\pi = 3.14159 \dots$  and  $e = 2.71828 \dots$  interleaved

# 伊壁鸠鲁 vs 奥卡姆


## Proposition (伊壁鸠鲁)

所有与观察一致的理论都要保留.

## Proposition (奥卡姆剃刀)

偏好与观察一致的简单理论.

- ▶ 如无必要, 勿增实体.
- ▶ 只要可能, 就用逻辑构造代替推论出的实体.
- ▶ 用较少的东西能做到的, 就不要用更多的东西.



- ▶ 更少的假设 vs 更少的实体?
- ▶ 奥卡姆剃刀能解决过拟合吗?
- ▶ 简单的理论是否可能由于其他原因而被偏好?  
比如计算和认知成本?
- ▶ 什么样的“理论”?  
— 可计算的机制 (物理丘奇-图灵论题)

# Why Simplicity Works in Psychology




Figure: Gestalt Psychology


## Why Simplicity Works in Psychology?



# Gestalt Laws of Organization




(a) Proximity



(b) Similarity




(c) Continuity



(d) Closure



(e) Law of Symmetry



(f) Law of Prägnanz



## Why Simplicity Works in Physics?

上帝不掷骰子.

上帝总是选择最简单的方式.

上帝难以捉摸, 但无恶意.

宇宙最不可理解之处是它是可理解的.

我真正感兴趣的是, 上帝是否可以以其他方式创造世界. 换句话说, 逻辑简单性是否为自由选择留有余地.

当我判断一个理论时, 我问自己, 如果我是上帝, 我是否会以这种方式创造世界.

— 爱因斯坦

# Why Simplicity Works in Physics?

- ▶ 诺特定理: 对称性  $\leftrightarrow$  守恒律
  - ▶ 时间平移对称性  $\leftrightarrow$  能量守恒
  - ▶ 空间平移对称性  $\leftrightarrow$  动量守恒
  - ▶ 空间转动对称性  $\leftrightarrow$  角动量守恒
  - ▶ 空间反演 (镜像 + 旋转) 对称性  $\leftrightarrow$  宇称守恒

**Remark:** 对称性的本质是变换之后的不变性. 如果一个几何图形在某种变换下保持不变, 则称此图形在此变换下对称. 而守恒量, 即是表征变化前后保持不变的物理量.

- ▶ 最小 (稳定) 作用量原理
- ▶ That which respects symmetries are laws of physics.

**Remark:** 复杂系统的模型往往非常简单. 不是因为简单模型的预测效果更好, 而是因为在巨大误差面前, 细微的改进几乎毫无作用.

## 凯恩斯 $\implies$ 卡尔纳普

- ▶ 概率不是事件的性质，而是描述事件的命题之间的关系。

— 布尔

- ▶ 概率是证据与假设之间的逻辑关系。归纳假设的概率应该随着支持它的独立事件的增加而趋近于 1。

— 凯恩斯


- ▶ 概率有经验维度和逻辑维度。可观测现象的相对频率是经验性的。证据对假设的确证度是一种纯逻辑关系。确证度的评估本质上是对符号的意义分析。选择确证度最高的假设。

— 卡尔纳普



## 普特南对卡尔纳普的批评

- ▶ 卡尔纳普的归纳逻辑是为了构造一台“学习机器”，它能够从数据中外推出经验规律.
- ▶ 归纳逻辑的任务，就是构造一台“通用学习机器”.
- ▶ 如果确实存在一种一劳永逸地正确定义的“确证度”函数，那么一台按照这种定义进行预测的机器，就将是“最智能的学习机器”.
- ▶ 但是，要么存在越来越好的“确证度”函数，但不存在“最佳可能”；要么存在一个“最佳可能”的函数，但它不能被任何机器计算出来.



### Formal Learning Theory

- ▶ Putnam 1963
- ▶ Gold 1967  $\hat{f}(n+1) = g(\langle f(0), \dots, f(n) \rangle)$   $\varphi \lim_{n \rightarrow \infty} g(\langle f(0), \dots, f(n) \rangle) = f$
- ▶ Solomonoff 1960

# Philosophy of Induction

What is learnable? How to learn?  
How can we know that what we learned is true?

## History

Possible Worlds/Hypothesis (Epicurus/Leibniz)

+

Homogeneous Universe(s) (Mill/Turing)

+

Simplicity Criterion (Occam/Kolmogorov)

+

Prior Belief (Carnap/Solomonoff)

+

Update Belief (Bayes)

⇓


Convergence to Truth

$$P(h | e) = \frac{P(e | h)P(h)}{\sum_{h \in \mathcal{H}} P(e | h)P(h)} \xrightarrow{\ell(e) \rightarrow \infty} 1$$

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会


# Dualism, (Materialism, Idealism, Neutral) Monism, Interactionism, Preestablished harmony, Pluralism, Epiphenomenalism, Emergentism ...



# The Doubt Argument — Dualism

*"Cogito, ergo sum."*

— *Descartes*



I cannot doubt that my mind exists

I can doubt that my body exists

$x$  and  $y$  are distinct if they have at least one different property

---

my mind is distinct from my body


**Problem:** How could they interact?



# The Doubt Argument — Dualism

*“Cogito, ergo sum.”*

— *Descartes*



I cannot doubt that my mind exists

I can doubt that my body exists

$x$  and  $y$  are distinct if they have at least one different property

---

my mind is distinct from my body

**Problem:** How could they interact?

Is ‘being doubtable’ a property?

我怕超人, 不怕克拉克, 超人具有克拉克不具有的性质 — “被我怕”, 所以, 超人不是克拉克.

# 笛卡尔的神学论证

上帝创造了万物 (包括我的心灵)  
上帝不是骗子

---

我的心灵清楚分明地认识到的一切都是真的

如果你能设想一物与另一物的不同, 那么, 上帝也能做这种区分  
你能设想没有身体的心灵

---

上帝区分了身体与心灵

# 查尔莫斯的僵尸论证

如果僵尸是可设想的, 那么, 僵尸是形而上学可能的  
如果僵尸是形而上学可能的, 那么, 意识是非物理的  
僵尸是可设想的

---

意识是非物理的

## “实在”中的非物理层面

- ▶ 人 = 身体 + 心灵
- ▶ 僵尸 = 只有身体没有心灵
- ▶ 鬼魂 = 只有心灵没有身体
- ▶ 存在许多非物理的对象、属性、关系、结构、机制、状态、事件、过程和因果相互作用。比如，
  - ▶ “无知” 可以导致 “贫穷”。
  - ▶ “贫穷” 可以导致 “犯罪”。
  - ▶ “信仰” 可以导致 “欲望”。
  - ▶ “欲望” 可以导致 “行动”。
- ▶ 所有这些非物理量，最终都实现在物理系统中，就像虚拟软件一样。
- ▶ 心灵 — 运行在大脑中的虚拟程序？
- ▶ 你最近安装了啥优质心智程序？清理了啥垃圾心智程序？

## Shakespeare — Hamlet

What a piece of work is a man!  
How noble is reason!  
how infinite in faculty!  
in form, in moving, how express and admirable!  
in action how like an angel!  
in apprehension how like a god!  
the beauty of the world! 宇宙之精华!  
the paragon of animals! 万物之灵长!  
And yet, to me, what is this quintessence of dust?  
man delights not me;  
no, nor woman neither,  
though, by your smiling, you seem to say so.

## 禅宗故事 — 老虎与草莓



- ▶ 一个人被老虎追赶...
- ▶ 跳下悬崖, 抓住一根藤蔓, 悬挂在半空.
- ▶ 崖上的老虎虎视眈眈, 崖下另一只老虎在徘徊等待.
- ▶ 这时, 一只老鼠爬出崖洞, 开始啃咬藤蔓...
- ▶ 突然, 注意到伸手可及一颗鲜红的草莓.
- ▶ 摘下一尝, Delicious!

Pain & Suffering is real!?

qualia?

What is it like to be a bat?

## 问题

“一千个读者有一千个哈姆雷特。”

感受性知识没有客观基础？

只能直接诉诸“主观体验”？

“主观体验”可以结构化/计算化吗？

功能主义主张“心灵 = 程序”，但被质疑.....

## 思路: 体验机制的“客观性”与体验结果的“主/客观性”

- ▶ 大家之所以觉得感受性知识没有“真”，主要是因为默认人的“主观体验”不够客观。
- ▶ 主观体验真的没有客观性吗？功能主义：有！心灵状态 = 功能角色。
- ▶ 但功能主义有问题。功能等价  $\neq$  结构同构。
- ▶ 引入生成模型/结构因果模型。区分**体验机制**与**体验结果**。
- ▶ “感觉/主观体验”的**机制**本身都是客观的。

(感觉) 假设性行动  
(主观体验) 假设性输入 }  $\Rightarrow$  基于生成模型对感知状态的反事实解释


- ▶ 之所以每个人的体验结果可能不同，并不是因为“感觉/主观体验”不够客观，而是因为每个人的知识背景不同。
- ▶ 由于每个人背景的不同，导致因果结构不同构，这才是主观性的根源。
- ▶ 一旦实现生成模型的同构，则体验结果也就有了客观性。

客观性 = 主体间性 = 生成模型同构

下面我们首先以“颠倒光谱”的思想实验为引子，说明功能不等于结构，客观性源于结构同构。然后深入结构内部，给出“感觉/主观体验”的基于生成模型的反事实解释。



# 莱布尼茨的“磨坊”



**Figure:** 莱布尼茨的“磨坊”：如果你把一个思维机器放大到磨坊那么大，并在里面随意参观，那么你不会发现任何能解释知觉或意识的事物。这是否意味着找错了地方？意识在整体系统而不在零件？

**Remark:** 思维机器是可能的，但意识无法被机械解释？ — 结构功能！

# 机器状态功能主义：心灵<sup>?</sup> = 程序

普特南：《心灵状态的本质》1967

心灵状态 = 功能角色

多重可实现性

- ▶ 塞尔的“中文屋”没有意向性 — 它使心灵状态指涉某物，不理解符号的意义仍然可以操纵符号执行程序，说明：心灵  $\neq$  程序。

普特南：《理性、真理与历史》1981

如果机器状态功能主义为真，那么，心灵状态 = 功能角色 = 程序  
“颠倒光谱”思想实验表明，有相同功能构成的人可能有不同的心灵状态

---

所以机器状态功能主义为假

**Remark:** 根据整合信息论 IIT，功能相同的两种结构，可能一个意识度较高，一个意识度为 0。

结构同构  $\implies$  功能等价   but   功能等价  $\nRightarrow$  结构同构

# 颠倒光谱

- ▶ 设想有一个人, 有一种奇怪的色盲症.
- ▶ 他看到的两种颜色和别人不一样, 他把红色看成蓝色, 把蓝色看成红色.
- ▶ 他不知道和别人的不同.
- ▶ 怎么让他知道自己和别人不一样?

## 颠倒光谱 — 从输入输出到更大的结构

$\text{perception}_1(\text{blue}) = \text{blue}$

$\text{perception}_1(\text{red}) = \text{red}$

$\text{tag}_1(\text{blue}) = \text{blue}$

$\text{tag}_1(\text{red}) = \text{red}$


$\text{perception}_2(\text{blue}) = \text{red}$

$\text{perception}_2(\text{red}) = \text{blue}$

$\text{tag}_2(\text{blue}) = \text{red}$

$\text{tag}_2(\text{red}) = \text{blue}$

$\text{tag}_1 \circ \text{perception}_1 = \text{tag}_2 \circ \text{perception}_2 = \text{Id}$






$\text{red} >_{\text{bright}} \text{blue}$

$\text{perception}_1(\text{red}) >_{\text{bright}} \text{perception}_1(\text{blue})$

$\text{perception}_2(\text{red}) <_{\text{bright}} \text{perception}_2(\text{blue})$

$\text{perception}_1 \neq \text{perception}_2$


# Can colors be mixed in the eyes?



# 从“功能等价”到“结构同构”

实体与关系哪个更基本？ 关系 (结构) 更基本

- ▶ 你用你的眼睛看, 我用我的眼睛看, 怎么就得到了“相同的”结果? 我们怎么就做了“相同的”实验?
- ▶ 难道我们的感官彼此做了校准?
- ▶ 经验流是主观的, 彼此不同, 但彼此的生成模型同构.
- ▶ “客观性” := 主体间性



- ▶ 我们并不需要完全同构, 这也不现实. 只要彼此的生成模型同构即可.
- ▶ 未必是“Red”投影为“ $red_1/red_2$ ”, 反而“Red”可能是同构后的构造.
- ▶ 这种“主体间性”具体怎么实现呢? — 镜像神经元具身模拟.

## 让我们深入到结构内部, 挖出“主观体验”来

- ▶ 普特南的功能相同指“输入-状态-输出”的转移概率相同. 处于 Pearl 因果阶梯的第一层.
- ▶ 转移概率相同, 不意味着生成模型相同.
- ▶ Friston 的主动推理框架中的“生成模型”可以对自身身体和外部世界进行主动预测/干预, 处于 Pearl 因果阶梯的第二层.
- ▶ 但若要对外部世界的因果结构进行充分表征, 需要引入因果阶梯第三层的结构因果模型.
- ▶ 所以, 我们假定这里讨论的生成模型是结构因果模型.
- ▶ 结构因果模型如何生成主观体验?

# AI 有“主观体验”吗？— Hinton

- ▶ 主观体验的特殊之处在于它的“假设性”，而不在于它由某些神秘的“感受质”(qualia) 在某个“内在剧场”里构成。
- ▶ 描述大脑内部状态的途径有两种：

1. 一是通过描述这种状态通常会导致的后续行动，

Feeling

2. 二是通过描述通常会导致这种状态的因素。

Subjective Experience

1. “**感觉**”是通过描述“**假设性行动**”来言说你的大脑状态。

— “我感觉想冲 Gary 的鼻子来一拳，如果不是额叶的抑制，我真的会打。”

2. “**主观体验**”是通过描述“**假设性输入**”来言说你的大脑状态。


**幻觉** “我吃了点儿致幻剂，产生了一头粉色大象在面前飘浮的主观体验。”——假设我的感知系统工作正常，如果外部世界真的有粉色大象在飘浮，那么我的感知系统告诉我的就是事实。

**错觉** 想象一个多模态机器人。我先训练它：在它面前放一个物体，命令它“指向物体”，它就准确无误地指过去。接着，我趁它“不注意”，在它的镜头前放了一块棱镜。然后我再次把物体放在它面前，说“指向物体”。这一次，它指向了旁边的错误位置。于是我纠正它：“不，物体的位置不对。其实就在你的正前方。我刚才在你的镜头前放了一块棱镜。”机器人回答说：“哦，我明白了。是棱镜折射了光线，所以物体实际上在那里，但我刚才的‘主观体验’是它在旁边那个位置。”



# “感觉”的反事实解释 — “强压怒火” 案例

我感觉想冲 Gary 的鼻子来一拳, 如果不是额叶的抑制, 我真的会打



$$A = S \cdot (1 - R)$$

► S: 感知状态

1.  $S = 1$ : 愤怒
2.  $S = 0$ : 正常

► R: 克制系统

1.  $R = 1$ : 克制
2.  $R = 0$ : 未克制

► A: 行动

1.  $A = 1$ : 打人
2.  $A = 0$ : 不打人


► “感觉”: 假设性行动

- 当前所处的感知 (愤怒) 状态  $S = 1$ , 还好克制住了  $R = 1$ , 没打人  $A = 0$ . 若未克制  $R = 0$ , 那真的会打人  $A = 1$ .

$$P(A_{R=0} = 1 \mid S = 1, R = 1, A = 0)$$

# “主观体验”的反事实解释 — “粉色大象”案例

致幻剂导致粉色大象在飘的幻觉



$$S = \begin{cases} W & \text{if } D = 0 \\ G & \text{if } D = 1 \end{cases}$$

## ► W: 外部世界信号

1.  $W = 1$ : 有粉色大象
2.  $W = 0$ : 没有粉色大象

## ► G: 内部生成信号

1.  $G = 1$ : 生成粉色大象幻象
2.  $G = 0$ : 没生成粉色大象幻象

## ► D: 干扰因素

1.  $D = 1$ : 吃了致幻剂
2.  $D = 0$ : 没吃致幻剂

## ► S: 感知状态

1.  $S = 1$ : 看到粉色大象在飘
2.  $S = 0$ : 没看到粉色大象


## ► “主观体验”: 假设性输入 (干预反事实解释)

- 事实上吃了致幻剂  $D = 1$ . 如果没吃致幻剂  $D = 0$ , 若真有粉色大象在飘  $W = 1$ , 那我的感知就是对的  $S = 1$ .

$$\operatorname{argmax}_w P(S_{W=w, D=0} = 1 \mid D = 1, G = 1, S = 1)$$

# “主观体验”的反事实解释 — “棱镜”案例

棱镜折射导致的视觉错觉 — “我看到了啥?” — 事前“假设性解释”



$$S = \begin{cases} W & \text{if } D = 0 \\ 1 - W & \text{if } D = 1 \end{cases}$$

► W: 外部世界信号

1.  $W = 1$ : 物体在旁边位置
2.  $W = 0$ : 物体在正前方

► D: 干扰因素

1.  $D = 1$ : 放了棱镜
2.  $D = 0$ : 没放棱镜

► S: 感知状态

1.  $S = 1$ : 看到物体在旁边位置
2.  $S = 0$ : 看到物体在正前方


► “主观体验”: 假设性输入 (干预反事实解释)

► 事实上放了棱镜  $D = 1$ . 如果没放棱镜  $D = 0$ , 若物体真在旁边位置  $W = 1$ , 那我的感知就是对的  $S = 1$ .

$$\operatorname{argmax}_w P(S_{W=w, D=0} = 1 \mid D = 1, S = 1)$$

# “事后反思”的反事实解释 — “棱镜”案例

对棱镜视觉错觉的反思 — “我为啥看错了?” — 事后“归因”



$$S = \begin{cases} W & \text{if } D = 0 \\ 1 - W & \text{if } D = 1 \end{cases}$$

► W: 外部世界信号

1.  $W = 1$ : 物体在旁边位置
2.  $W = 0$ : 物体在正前方

► D: 干扰因素

1.  $D = 1$ : 放了棱镜
2.  $D = 0$ : 没放棱镜

► S: 感知状态

1.  $S = 1$ : 看到物体在旁边位置
2.  $S = 0$ : 看到物体在正前方


- 事后反思 — 被告知“主观体验为什么出错了”后的反事实推理.
- 物体事实上在正前方  $W = 0$ , 但由于有棱镜折射光线  $D = 1$ , 位置看歪了, “主观体验”到物体在旁边位置  $S = 1$ . 若无棱镜干扰  $D = 0$ , 则会正确感知到物体就在正前方  $S = 0$ .

$$P(S_{D=0} = 0 \mid W = 0, D = 1, S = 1)$$

**Remark:** “错觉体验”和“为啥体验错了”都可以被反事实解释, 但不能用“理智正确”替代“错误体验”, 彰显体验的“真实性”.


# 干预反事实 vs 回溯反事实

1. 或者自然律被违反
2. 或者背景条件被改变



1. **干预反事实:** 现实世界和反事实世界共享相同的背景条件  $u$ . 现实结果  $V$  和反事实结果  $V^*$  之间的潜在矛盾, 通过机制  $F$  的变化 (通过干预得到修改后的机制  $F^*$  和子模型  $M^*$ ) 得以解决.
2. **回溯反事实:** 现实世界和反事实世界共享相同的不变机制  $F$ , 而各自的背景条件  $u$  和  $u^*$  可能不同.

## “主观体验”的回溯反事实解释



$$S = \begin{cases} W & \text{if } D = 0 \\ 1 - W & \text{if } D = 1 \end{cases}$$

1. 主观体验: 假设性输入 (干预反事实 — 最大似然)






$$\operatorname{argmax}_w P(S_{W=w, D=0} = 1 \mid D = 1, S = 1)$$

2. 主观体验: 假设性输入 (回溯反事实 — 最大后验)

$$\operatorname{argmax}_w P_B(W^* = w \mid D = 1, S = 1, D^* = 0, S^* = 1)$$


- ▶ 基于感知状态, 坚守自然律不破, 被迫回溯到上游外生变量, 不惜篡改出“主观错觉”。
- ▶ 相比于“干预反事实”, “回溯反事实”更能解释为什么人会同时有“理智知道真相”和“主观体验有错觉”的撕裂感。
- ▶ 感觉是对后续行动的假设性预测, 干预反事实更合适; 主观体验是对其自身内部状态的假设性解释, 回溯反事实更合适。

## 相同形色“感受质”下的体验转换？解不唯一，多稳态



$\operatorname{argmax}_w P(S_{W=w} = 1 \mid S = 1)$  的解不唯一. 令  $W = 1$  或  $W = 0$  都能完美解释  $S = 1$ .

# 蝙蝠的感受？——反事实“主观体验”的可计算性



**Figure:** Thomas Nagel: while a human might be able to imagine what it is like to be a bat by taking “the bat’s point of view”, it would still be impossible “to know what it is like for a bat to be a bat.” 子非鱼安知鱼之乐？


- ▶ 自我投射的危险：“为什么镜子颠倒了左右却没有颠倒上下？”
- ▶ 镜像对称只颠倒了前后，把自己投射到“镜中人”才误以为颠倒了左右

$$P(S_{\text{Reverse}}=1, \text{Mirror}=0 = 1 \mid \text{Mirror} = 1, S = 1)$$

- ▶ 内格尔试图“客观的”知道“主观的”感受，不具有同构的生成模型，因此不具有计算反事实的条件




# 走出“黑白屋”——机制性知识 vs 事实性知识



jolyon.co.uk

- ▶ 玛丽走出“黑白屋”看到红色时，会学到物理知识之外的感受性知识吗？
- ▶ 给她看一个涂成蓝色的红苹果，如果她知道这不是苹果本来的颜色，是否说明她早已知道看到蓝色会有什么感受？
- ▶ 物理知识无法解释“**主观体验**”？心灵状态无法还原为物理状态？
- ▶ 梁启超：无论为哀为乐，为怨为怒，为恋为骇，为忧为惭，常若**知其然而不知其所以然**。  
——情感等“主观体验”的“事实 vs 机制”层面。
- ▶ 跟日常情感体验不同，“黑白屋”里获得的是“机制性知识”(结构因果方程) 而非“事实性知识”(外生变量的取值)。

# 主体间性 & 体验机制/体验结果



- ▶ 背景不同, 但体验机制完全相同.
- ▶ 若生成模型同构, 则体验结果也相同.

# 展望

- ▶ 价值体验 (道德体验、审美体验等) — 引入效用函数变量?
- ▶ 梦中的体验? — 屏蔽外部世界信号, 放大内部生成信号?
- ▶ 精神分裂的体验? — 感知状态的机制中外部世界信号与内部生成信号冲突?
- ▶ 神经科学实验验证? — 血清素、多巴胺、去甲肾上腺素等在体验生成中的作用?
- ▶ 更多人文领域的算法化? — 责任、公平、正义、意识、自由意志...?
- ▶ 人文算法化的伦理问题?
- ▶ 如何构建具备反事实“主观体验”能力的具身 Agent?


# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会

# 问题

- ▶ 什么是意义?
    - 语言描绘世界?
    - 由其在语境中的用法决定?
    - 语言形式与交流意图之间的关系?
  - ▶ 意义与形式是否可分离?
  - ▶ 意义能从纯粹的语言形式中涌现吗?
- 实体与关系哪个更基本?

# 语法 vs 语义



**Figure:** The computer takes in symbols and outputs symbols. The meaning of the symbols are in the user's head.

# 语言 — 思想 — 世界

- ▶ What is the meaning of 'meaning'? (symbol grounding problem)
- ▶ How do words relate to objects? thought?
- ▶ What makes a sentence true/false?




Table: Frege: symbol, sense & reference


Frege: The meaning of a term is a function/algorithm which computes its denotation.

Wittgenstein: The limits of my language means the limits of my world.

# What is the meaning of 'meaning'?

- ▶ Frege: The meaning of a term is a function/algorithm which computes its denotation.
- ▶ Carnap: The intension of an expression is a function from each possible world to the extension of the expression.
- ▶ Wittgenstein: Meaning as (context-dependent) use (family resemblance)

flying horse →



- ▶ The morning star is the evening star.
- ▶ Sherlock Holmes is a detective.
- ▶ The flying horse is not a horse.
- ▶ The round square is round.
- ▶ The golden mountain does not exist.



# 内涵 vs 外延

- ▶ 外延同一替换失败:

小明在寻找晨星  
晨星 = 昏星  

---

小明在寻找昏星

- ▶ 逻辑等价替换失败:

$$\begin{array}{l} \text{祖冲之相信 } 1 + 1 = 2 \\ 1 + 1 = 2 \iff e^{i\pi} + 1 = 0 \\ \hline \text{祖冲之相信 } e^{i\pi} + 1 = 0 \end{array}$$

需要放弃哪些内涵原则?


1. 复合命题的内涵是其部分之内涵的函数.
2. 如果句子的真值不同, 则其内涵也不同.
3. 如果句子在所有情况下的真值都相同, 则其内涵相同.

# Charles Peirce 1839-1914

*"Men and words reciprocally educate each other."*

— Peirce

- ▶ "The mind is a sign developing according to the laws of inference."
- ▶ "Logic is formal semiotic."
- ▶ "Every thought is a sign, taken in conjunction with the fact that life is a train of thought, proves that man is a sign."
- ▶ "All this universe is perfused with signs."



# Jerry Fodor 1935-2017 Language of Thought Hypothesis



- ▶ 心灵表征理论: 心理表征由可以赋值为真或假的因果序列构成. 命题态度是主体与心理表征之间的关系.  
—  $B_i p$  iff there is a 'mental representation'  $S$  such that  $i$  'believes'  $S$  and  $S$  means that  $p$ .
- ▶ 心灵计算理论: 思维过程是心理表征的 token 序列组成的计算过程.
- ▶ 思维语言假设: 心理表征既有组合性的语法又有组合性的语义. 思维是基于思维语言的计算.

**Remark:** 大脑神经元可以表征 (符号) 概念吗? 比如怎么表征 “兔子”?

# Logical Positivism

- ▶ Analytic-Synthetic Distinction
  - ▶ analytic sentence = a sentence that is true/false in virtue of its meaning.
  - ▶ synthetic sentence = a sentence that is true/false in virtue of its meaning and how the world actually is.
- ▶ Verifiability Theory of Meaning: The meaning of a sentence consists in its method of verification.
  - ▶ It's too weak! e.g. "All metals expand when heated and the Absolute Spirit is perfect" is verifiable.
  - ▶ It's too strong! e.g. "Superstrings exist" is not verifiable.
- ▶ Observational & Theoretical Languages
- ▶ The Role of Logic: analyze the language of science in terms of logic (Deductive & Inductive).

## Problems:

- ▶ Hypotheses cannot be tested in isolation (Duhem-Quine Thesis).
- ▶ Nothing is immune to revision, not even logic (analytic sentences).
  - Move from classical to quantum physics requires analogous move from classical to quantum logic!


## Popper — Falsificationism

- ▶ A theory is falsifiable if it is contradicted by an observation that is expressible in the language of the theory.
- ▶ However, it is models of theories, not the theories themselves, that are tested by experiments.
- ▶ In general, it is possible to falsify a parametric family of models, but impossible to falsify the class of all models of the theory, for it is too large.


# From Logical Positivism to Logical Empiricism

- ▶ Verifiability Theory of Meaning: The meaning of a sentence consists in its method of verification.
- ▶ Holistic Empiricist Theory of Meaning: Theoretical claims about unobservable phenomena gain meaning from their place in the structure of a given theory.


## Logical Empiricism




## Logical Positivism



# Logical Positivism



# Pragmatism



- ▶ Pragmatism denies realism not only in the area of theories but also in the area of facts.
- ▶ There is no qualitative difference between facts and theories.

# Wittgenstein: Philosophical Investigations

*"I shall not today attempt further to define 'pornography'; and perhaps I could never succeed in intelligibly doing so. But I know it when I see it."*


— Potter Stewart

- ▶ We cannot define words.
- ▶ Language does not describe facts, it is used to communicate.
- ▶ The meaning of a word is its use in the language.
- ▶ The various uses of words can be best understood as family resemblance.
  - ▶ use *A* is similar to use *B*, because they share trait *X*
  - ▶ use *B* is similar to use *C*, because they share trait *Y*
- ▶ If a word is used in a new context, we draw on the various uses in other contexts.



# Wittgenstein: Philosophical Investigations

- ▶ How are chairs identified?
- ▶ chair = 4 legs, back, place to sit, ...
- ▶ All chairs share a “family resemblance” in appropriate contexts of use.
- ▶ This family resemblance can't be formally encoded in a rule/definition.
- ▶ form of life = basic set of practices, behaviors, principles (No external justification.)
- ▶ language game = pattern of linguistic habits associated with a form of life.
- ▶ Language does not represent; rather, it is used by communities to communicate.
- ▶ Terms do not gain meaning by what they represent; rather, they gain meaning by how they are used.



## 盒子中的“甲虫”

- ▶ 设想每个人都有一个盒子，里面装着被称作“甲虫”的东西。
- ▶ 没有人能看见别人盒子里的东西。
- ▶ 每个人都说：他只是通过看自己盒子里的那只甲虫，才知道什么是“甲虫”。
- ▶ 盒子里的东西可能各不相同。甚至可以设想盒子里的东西在不断变化，或没有东西。
- ▶ 维特根斯坦试图提醒我们：虽然感觉经验是私有的，但不存在私人语言，否则日常交流就无法进行。语言的意义并不在于指向某个内在的私有实体，而在于它在公共语言游戏中的使用方式。

## Quine 1908-2000 “Web of Belief”



What does “gavagai” mean?



- ▶ Scientific claims, common beliefs and opinions, are all interconnected in a single unified belief system.
- ▶ Changes in any part of the system can be accommodated by revision elsewhere.  
(It confronts experience as a whole.)
- ▶ Indeterminacy of translation

- ▶ Holistic Theory of Meaning: A scientific term gets its meaning from the theory it appears in.
- ▶ There is no single set of standards entitled to govern the justification of beliefs.
- ▶ Justification of a belief system is internal to that system, not external.
- ▶ Scientific theories (facts) are social constructs.

### What does “social construct” mean?

To construct  $X$  in the social world requires:

- ▶ Knowledge of  $X$  encourages behaviors that increase or reduce other people's tendency to act as though  $X$  does or does not exist.
- ▶ There is reasonably common knowledge of  $X$
- ▶ There is transmission of knowledge of  $X$ .

# Philosophy of Language

- ▶ “Classical” view (pre-1953): language consists of sentences that are true/false
- ▶ “Modern” view (post-1953): language is a form of action

Wittgenstein (1953), *Philosophical Investigations*

Austin (1962), *How to Do Things with Words*

Searle (1969), *Speech Acts*

Grice (1975), *Logic and Conversation*



- ▶ Speech acts achieve the speaker's goals.
- ▶ Speech act planning requires knowledge of
  - Situation
  - Semantic and syntactic conventions
  - Listener's goals, knowledge base, and rationality


# Stages in Communication

|                       |                                                                                                  |
|-----------------------|--------------------------------------------------------------------------------------------------|
| <b>Intention</b>      | Speaker $S$ wants to inform Listener $L$ that meaning $m$                                        |
| <b>Generation</b>     | Speaker $S$ chooses proposition $p$ such that Listener $L$ is most likely to infer $m$ given $p$ |
| <b>Synthesis</b>      | Speaker $S$ utters proposition $p$                                                               |
| <b>Perception</b>     | Listener $L$ perceives $p$                                                                       |
| <b>Analysis</b>       | Listener $L$ infers possible meanings $m_1, \dots, m_n$                                          |
| <b>Disambiguation</b> | Listener $L$ infers intended meaning $m_i$                                                       |
| <b>Incorporation</b>  | Listener $L$ incorporates $m_i$ into KB                                                          |

Engaging in complex language behavior requires various kinds of knowledge of language

- ▶ **Linguistic knowledge:** Phonetics, phonology, Morphology, Syntax, Semantics, Pragmatics, Discourse
- ▶ **World knowledge:** common knowledge, commonsense knowledge

庄子: 言者所以在意, 得意而忘言?



$$p = \arg \max_p P_L(m \mid p)$$

$$P_L(m \mid p) \propto P_S(p \mid m)P(m)$$

$$P_S(p \mid m) \propto \exp(\alpha \cdot U(p, m)) \quad \alpha \text{ is a parameter}$$

$$U(p, m) = \log P_{\text{Lit}}(m \mid p) - \text{Cost}(p)$$

$$P_{\text{Lit}}(m \mid p) = \chi_{m \in \llbracket p \rrbracket} P(m) \quad \text{"informative" to the Literal Listener}$$

# 格赖斯 (Paul Grice) 的语用会话的“合作原则”

1. 数量原则 (Quantity: be informative, don't undershare or overshare)  
— 提供对方所需的信息, 不少也不多
2. 质量原则 (Quality: be truthful, don't say what you don't believe)  
— 不说假话, 不说没证据的话
3. 关联原则 (Relation: be relevant)  
— 不说无关的话, 不答非所问
4. 方式原则 (Manner: be clear)  
— 避免晦涩、避免歧义、简洁、有条理

**Remark:** Grice 的“合作原则”体现在效用函数  $U(p, m)$  里.

- ▶ 数量原则、关联原则  $P_{\text{Lit}}(m \mid p)$
- ▶ 质量原则、关联原则  $\chi_{m \in \llbracket p \rrbracket}$
- ▶ 方式原则  $\text{Cost}(p)$



# Contents

1. Introduction

2. 逻辑与论证

3. 形而上学

4. 认识论

5. 伦理学

6. 美学

7. 科学哲学

8. 心灵哲学

9. 语言哲学

10. 博弈与社会

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会
  - 个体理性与囚徒困境
  - 非对称信息与逆向选择
  - 机制设计与道德风险
  - 不完全信息博弈与声誉
  - 演化博弈与自发秩序
  - 民主投票与群体聚合

## 拍卖 10 块钱!

现有 10 块钱钞票要拍卖. 规则如下:

1. 竞价者之间彼此不能交流.
  2. 出价从 5 毛钱开始, 每次只能加 5 毛钱.
  3. 出价最高者赢得钞票.
  4. 但出价次高者也要支付自己的出价.
- ▶ 军备竞赛
  - ▶ 美国大选
  - ▶ “粉丝”为“爱豆”“打榜”
  - ▶ 商家价格战
    - 可信威胁 (如: 商家宣称“买贵了, 退差价”; 如果对方宣称“退 2 倍差价”呢?)
  - ▶ 争相行贿搞关系
  - ▶ “内卷”

## 囚徒困境及其它

|    | 合作     | 背叛     |
|----|--------|--------|
| 合作 | -1, -1 | -4, 0  |
| 背叛 | 0, -4  | -3, -3 |

Table: 囚徒困境 (占优均衡)

|    | 歌剧   | 足球   |
|----|------|------|
| 歌剧 | 1, 2 | 0, 0 |
| 足球 | 0, 0 | 2, 1 |

Table: 性别大战 (纳什均衡)

|    | 妥协    | 进攻                 |
|----|-------|--------------------|
| 妥协 | 0, 0  | -1, 1              |
| 进攻 | 1, -1 | $-\infty, -\infty$ |

Table: 胆小鬼博弈 (纳什均衡)

|    | 正面    | 反面    |
|----|-------|-------|
| 正面 | 1, -1 | -1, 1 |
| 反面 | -1, 1 | 1, -1 |

Table: 正反匹配 (混合纳什均衡)

- ▶ **帕累托最优**: 除非“损人”，否则不可能“利己”。
- ▶ **占优策略**: 独立于其他人的选择的最优策略。
- ▶ **占优均衡**: 所有人的占优策略的组合。
- ▶ **纳什均衡**: 所有人的最优策略的组合，给定该策略中别人的选择，没有人有积极性改变自己的选择。

## 求知 vs 应试


|    | 求知       | 应试     |
|----|----------|--------|
| 求知 | 100, 100 | 20, 80 |
| 应试 | 80, 20   | 60, 60 |

Table: 学生内卷 (纳什均衡)



又卷又菜

## Example: 纳什均衡




- ▶ 一条居民街, 两个卖报的小贩.
- ▶ 报纸价格不由小贩决定. 小贩只能选择自己摆摊的位置.
- ▶ 每个居民都会找距离自己最近的小贩买报纸. 如果等距, 则随机选一个.
- ▶ 小贩会如何选择摆摊位置?
- ▶ 对于这个唯一的纳什均衡, 站在居民的角度来看, 是否理想?
- ▶ 政治隐喻.
  - 大街: 政治空间.
  - 大街上的点: 政治立场.
  - 小贩: 候选人.

# 多重纳什均衡 vs 制度规范

| 机动车道 | 左行   | 右行   |
|------|------|------|
| 左行   | 1, 1 | 0, 0 |
| 右行   | 0, 0 | 1, 1 |

Table: 协调博弈



| 卢梭 | 猎鹿     | 逮兔   |
|----|--------|------|
| 猎鹿 | 10, 10 | 1, 8 |
| 逮兔 | 8, 1   | 5, 5 |

Table: cheap talk 协商选择帕累托最优的纳什均衡

## Remark:

- ▶ 纳什均衡不一定是帕累托最优.
- ▶ 任何制度, 只有构成一个纳什均衡, 才能让人们自觉遵守.
- ▶ 制度、规范的主要功能之一是协调预期, 在多个纳什均衡中筛选出某个特定的纳什均衡.
- ▶ 有效的制度设计, 就是通过对纳什均衡的选择实现帕累托最优.

*The understanding of mathematics is necessary for a sound grasp of ethics.*

— Socrates

*The only good is knowledge.*

*The only evil is ignorance.*

— Socrates



# 走出囚徒困境 — 奖惩 — 利维坦

|    | 合作     | 背叛     |
|----|--------|--------|
| 合作 | -1, -1 | -4, 0  |
| 背叛 | 0, -4  | -3, -3 |

Table: 囚徒博弈

|    | 合作        | 背叛             |
|----|-----------|----------------|
| 合作 | -1, -1    | -4, 0 - x      |
| 背叛 | 0 - x, -4 | -3 - x, -3 - x |

Table: 带惩罚的囚徒博弈  $0 - x < -1$



# 走出囚徒困境 — 奖惩 — 作为激励机制的等级制度

|    | 合作     | 背叛     |
|----|--------|--------|
| 合作 | -1, -1 | -4, 0  |
| 背叛 | 0, -4  | -3, -3 |



|    | 先走   | 后走   |
|----|------|------|
| 先走 | 0, 0 | 2, 1 |
| 后走 | 1, 2 | 0, 0 |



## 儒家 — “礼”

“合作”方可得“君子”名分，君子享有优先权。

协调预期、定分止争。

声誉约束。

奖善惩恶、等级制度等可以理解为一种激励机制。

# 个人 vs 社会 — 个人行为正当性的标准

帕累托 vs 卡尔多-希克斯

## Problem (问题)

社会是由人组成的, 每个人的行为都会影响到他人的利益. 那么, 应该用什么标准判断个人的行为是否正当?

- ▶ **帕累托最优:** 一种状态被称为帕累托最优状态, 如果不存在另一种状态能使得没有任何人的境况变坏同时至少有一个人的境况变得更好. — 除非“损人”, 否则不可能“利己”.
- ▶ **卡尔多-希克斯 (Kaldor-Hicks) 标准:** 如果一种变革使得受益者的所得足以弥补受损者的所失, 这种变革就是一个卡尔多-希克斯改进. 如果受损者得到实际的补偿, 就是帕累托改进.

**Remark:** 帕累托最优可能意味着收入分配的不公平; 极端地, 一个人得到所有收入, 另一个人一无所有, 也是一个帕累托最优.

- ▶ 自愿的交易一定是一个帕累托改进 (假定没有欺诈).
- ▶ 卡尔多-希克斯标准即“财富最大化”.

## 合作与组织

- ▶ 当个体在一起工作创造的价值大于独立工作创造的价值之和, 合作就是一个帕累托改进;
- ▶ 当个体在组织中获得的价值大于独立获得的价值时, 加入组织是一个帕累托改进.
- ▶ 自由结婚对夫妻双方是一个帕累托改进;
- ▶ 买卖婚姻对买卖双方是一个帕累托改进;
- ▶ 协议离婚对夫妻双方是一个帕累托改进;
- ▶ 但离婚对其他利益相关者 (如父母和儿女) 可能不是一个帕累托改进.

## Examples: 卡尔多-希克斯标准

### Example1:

- ▶ 考虑两种情形:
  1. 某店主暴力捣毁竞争对手的门店, 使后者不能营业;
  2. 某店主以更低的价格和更优良的服务将竞争对手打垮.
- ▶ 为什么法律允许第二种情形?
  - 社会所得大于所失, 是一个卡尔多-希克斯改进.


### Example2:

- ▶ 一家化工厂与家属区一墙之隔, 为了上班方便, 居民在化工厂的墙上挖了一个洞. 一天, 家属区的一个小孩钻洞进工厂玩, 找到一瓶化学液体并点燃烧伤了自己.
- ▶ 假设化工厂补墙成本为  $c$ , 如果不补墙, 发生事故的概率为  $p$ , 损失为  $l$ , 且  $c < pl$ .
- ▶ 化工厂需要承担责任吗?

## 外部性、交易成本与科斯定理

- ▶ 个人收益与社会收益: 一项活动的社会收益等于决策者个人得到的收益加社会其他成员得到的收益 (如养花);
- ▶ 个人成本与社会成本: 社会成本等于决策者的个人承担的成本加社会其他成员承担的成本 (如环境污染、交通堵塞);
- ▶ 如果个人收益 (成本) 不等于社会收益, 就存在外部性.
- ▶ 个人最优与社会最优的不一致意味着有帕累托改进的余地;
- ▶ 如何将外部性内部化? 如何使得个人在边际上承担全部的社会成本、获得全部的社会收益?
- ▶ 法律通过责任的分配和赔偿/惩罚, 将个人行为的外部成本内部化, 诱导个人选择社会最优的行动.
- ▶ 政府征税、补贴?
- ▶ 科斯定理: 只要产权界定是清楚的, 如果交易成本为零, 外部性可以通过当事人之间谈判解决, 帕累托最优可以实现; 并且, 最终的资源配置与初始的产权安排无关. (公平与效率正交吗?)

## 科斯定理 — 例子



- ▶ 如果产权归农场主, 农场主禁止放牧, 小于社会最优量  $S$ ; 但是, 增加放牧给牧羊人带来的边际利润大于给农场主造成的损失, 牧羊人将有积极性贿赂农场主, 直到放牧量达到  $S$  为止;
- ▶ 如果产权归牧羊人, 牧羊人的利润最大点是  $P$ , 大于社会最优量  $S$ ; 但是, 减少放牧量对牧羊人的边际利润损失小于给农场主节约的边际成本, 农场主将有积极性贿赂牧羊人, 直到放牧量达到  $S$  为止.

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会
  - 个体理性与囚徒困境
  - 非对称信息与逆向选择
  - 机制设计与道德风险
  - 不完全信息博弈与声誉
  - 演化博弈与自发秩序
  - 民主投票与群体聚合




# 非对称信息 (Asymmetric Information)

- ▶ 非对称信息: 交易关系中一方知道而另一方不知道的信息.
  - 卖家知道商品的质量, 而买家不知道.
  - 员工知道自己的能力和老板不知道.
  - 投保人知道自己的健康状况, 保险公司不知道.
  - 乞丐知道自己是否是真乞丐, 慈善家不知道.
- ▶ 事前 (ex ante) 非对称信息: 指签约之前存在的非对称信息, 所以, 又称为隐藏信息 (hidden information), 如产品质量.
- ▶ 事后 (ex post) 非对称信息: 指签约之后发生的非对称信息, 又称隐藏行动 (hidden action), 如工人的努力水平.
- ▶ 事前信息不对称导致逆向选择, 劣胜优汰.
- ▶ 事后信息不对称导致道德风险.

## Example (逆向选择)


- ▶ 坏车使得好车不能成交. (好人未必好报)
- ▶ 高风险的投保人使得低风险的投保人无法投保.
- ▶ 高水平的学者竞争不过灌水的学者.

## 逆向选择 — 劣币驱逐良币



- ▶ 假乞丐使得真乞丐得不到救济.
- ▶ 和珅: 往粥里掺沙子.
- ▶ 经济适用房不能建太好.

## 逆向选择 — 劣币驱逐良币



- ▶ 假设好车和坏车对卖家的保留价值分别为  $2x$  和  $x$ , 对买家的价值是卖家的  $a$  倍. 成交价为  $Q$ .
- ▶ 为使交易达成, 买家买车的期望收益应不小于不买车的期望收益.

$$(2ax - Q)p + (ax - Q)(1 - p) \geq 0$$

- ▶ 拥有好车的卖家能接受的最低价是  $Q \geq 2x$ .
- ▶ 这意味着, 买卖双方合意的价格需满足:

$$(1 + p)ax \geq Q \geq 2x \implies p \geq \frac{2}{a} - 1$$

- ▶ 买卖好车是双赢, 但除非好车比例够高, 否则交易无法达成.
- ▶ 除非好人够多, 否则不敢与陌生人交往 ☹

# 如何解决非对称信息的问题？

## 解决非对称信息的市场机制和政府管制

1. 信号显示 (信号传递): 主动传递真实信息. 如: 卖家承诺保修.
2. 信息甄别 (机制设计): 让对方说实话. 如: 保险公司向投保人提供不同的合同选择, 投保人根据自己的状况选择适合自己的合同.
3. 声誉机制: 品牌的价值. 信息越不对称的产品, 其品牌价值越大. 买土豆不太会关心品牌, 但买汽车买咨询服务会非常看重品牌.
4. 适度的政府管制. 但政府管制不当可能破坏声誉机制的有效性 — 管制导致企业预期不稳定, 追求短期行为; 管制导致垄断, 使得市场惩罚不可信; 管制导致腐败, 贿赂官员比贿赂投资者和客户更合算.

# Contents

1. Introduction

2. 逻辑与论证

3. 形而上学

4. 认识论

5. 伦理学

6. 美学

7. 科学哲学

8. 心灵哲学

9. 语言哲学

10. 博弈与社会

个体理性与囚徒困境  
非对称信息与逆向选择  
**机制设计与道德风险**  
不完全信息博弈与声誉  
演化博弈与自发秩序  
民主投票与群体聚合

# Cake Cutting

- ▶ Two Children:
    1. One cuts, the other chooses.
  - ▶ Three Children (A,B,C):
    1. A cuts a piece of the cake.
    2. B can leave it, or make it smaller.
    3. C can leave the remaining piece, or make it smaller.
- Whoever cuts the cake last, gets the remaining piece.

- ▶ 19 世纪中期法国的火车有头等座、二等座和三等座三种不同的车厢.
- ▶ 三种车厢票价相差较大.
- ▶ 头等车厢非常舒适, 二等车厢与三等车厢的区别是前者有顶盖, 后者没有. 这样, 坐三等车厢的旅客就要忍受日晒雨淋的痛苦.
- ▶ 给车厢加一个顶盖的成本微乎其微, 为什么公司不这样做呢?
- ▶ 为了吓唬富人, 故意让穷人受罪.

- ▶ 问题: 有时候, 拥有私人信息的一方有积极性通过一定的行动向另一方传递自己的私人信息, 但有时候他们没有积极性或没有有效的办法传递自己的私人信息.
- ▶ 机制设计: 没有私人信息的一方通过设计不同的分配方案使得有私人信息的一方通过自我选择揭示自己的私人信息.

**Example:** 保险市场中的混同均衡和分离均衡.

1. 保险金 2 万元; 只有第二年得病才可得到赔偿金 10 万元, 第一年得病得不到赔偿.
2. 保险金 7 万元; 无论第一年得病还是第二年得病, 都可得到赔偿金 10 万元.

高风险者选择合同 2; 低风险者选择合同 1.



## 逆向博弈论

已知理性人会选择最优策略, 为了诱导出某种类型的行为, 应该设计什么样的博弈?

## 博弈 vs 伦理

- ▶ 康德之流的义务论者可能会认为, 博弈对伦理无益. 因为, 伦理规范是约束你做那些你不想做的事, 而博弈论却是讲怎么得到你想要的东西.
- ▶ 休谟等效用主义者却认为, 除非伦理理论建议的行为符合每个人的实际利益, 否则毫无用处. 有效的制度设计, 就是通过对纳什均衡的选择实现帕累托最优.

# 拍卖

1. 高价格公开拍卖
2. 降价公开拍卖
3. 高价格密封拍卖
4. 次价格密封拍卖: 与高价格密封拍卖一样, 中标者仍然是出价最高者, 但中标者实际支付的是第二高报价. 次价格密封拍卖能让竞标者有积极性说真话.

## Theorem

次价格密封拍卖中, 说真话是竞标者的占优策略.

**Remark:** 比如: 对某古董, 你的实际评价是 1 万, 如果出价 1 万, 第二高出价 9 千, 你赚 1 千; 如果你出价低于 9 千, 你什么也得不到.

## VCG 机制 Vickrey-Clarke-Groves Mechanism

- 公共产品的偏好显示: 不同的人有不同的偏好, 是私人信息. 如何让每个人报告自己的真实偏好?
- 每个人可以任意地报告自己的偏好, 但可能要纳缴一定数量的“税”. 计算办法: 先将其他人的偏好加总, 给出总价值最大的项目; 然后将第一个人的偏好加上, 如果不影响结果, 不征税; 否则, 应纳税等于改变结果给其他人带来的损失.

$$p_i = \underbrace{\max_x \sum_{j \neq i} v_j(x)}_{i \text{ 不参与}} - \underbrace{\sum_{j \neq i} v_j(x^*)}_{i \text{ 参与}} \quad \text{where} \quad x^* = \operatorname{argmax}_x \sum_{i=1}^n v_i(x)$$

- 同学聚会去吃川菜还是粤菜? 每人报告自己的真实偏好是占优策略.

|    | 川菜 | 粤菜 | 税额 $p_i$ |
|----|----|----|----------|
| A  | 30 | 10 | 0        |
| B  | 0  | 40 | 30       |
| C  | 20 | 10 | 0        |
| 合计 | 50 | 60 | 30       |

## 公平与夏普利值

- ▶ A,B,C 合作开了一家公司. 公司任何决策只有超过 50% 的赞成票才能通过.
- ▶ 根据投资额, A 拥有 50% 的票力, B 拥有 40%, C 拥有 10%.
- ▶ 年终净赚 150 万, 根据票力之比, A,B,C 分别 75 万, 60 万, 15 万吗?
- ▶ C 提议: A 拿 80 万, 自己 70 万, B 一分没有.
- ▶ B 提议: A 拿 85 万, 自己 65 万, C 一分没有.
- ▶ 怎么分才公平?
- ▶ 三人中, 任何一人都不是决定性的, 都得与他人结盟才有决策权.
- ▶ 夏普利值的基本假设是: 各投票顺序联盟形成的可能性相同, 玩家的夏普利值为其对联盟的边际贡献之和除以各种可能的联盟组合总数.

|       |   |   |   |   |   |   |
|-------|---|---|---|---|---|---|
| 1     | A | A | B | B | C | C |
| 2     | B | C | A | C | A | B |
| 3     | C | B | C | A | B | A |
| 关键加入者 | B | C | A | A | A | A |

Table: 所有可能的投票顺序

- ▶ 作为关键加入者的次数. A: 4 次; B: 1 次; C: 1 次.
- ▶ 夏普利值. A:  $\frac{4}{6}$ ; B:  $\frac{1}{6}$ ; C:  $\frac{1}{6}$ .
- ▶ 根据影响力, A:  $150 \times \frac{4}{6} = 100$  万; B: 25 万; C: 25 万.

## 讨价还价与纳什讨价还价解

- ▶ 市场上有一个画家 A 和一个画廊 B.
- ▶ 若画家 A 自己卖画, 可得  $a = 1500$ .
- ▶ 若交给画廊 B 卖, 可得  $V = 6000$ .
- ▶ 若画廊 B 干别的事, 可得  $b = 1000$ .
- ▶ AB 该怎么分利?
- ▶  $S := V - a - b = 3500$  是合作带来的剩余价值.
- ▶ 我们用  $x$  表示 A 应分得的价值,  $y$  表示 B 应分得的价值.  $\alpha, \beta$  表示 A 和 B 剩余价值  $S$  的分配比例 (与边际贡献有关).


$$x = a + \alpha S, \quad y = b + \beta S$$

- ▶ 纳什讨价还价解即优化福利函数  $W(x, y) = (x - a)^\alpha (y - b)^\beta$

$$(x^*, y^*) = \operatorname{argmax}_{x, y: x+y=V} (x - a)^\alpha (y - b)^\beta$$

- ▶ 因为若缺少任何一方, 这 3500 的剩余价值都得不到, 所以每一方的边际贡献都是 3500. 总边际贡献是  $3500 + 3500 = 7000$ . 每一方的边际贡献占比都是  $\frac{3500}{3500+3500} = \frac{1}{2} = \alpha = \beta$ .
- ▶ A 应分得  $1500 + \frac{1}{2} \times 3500 = 1500 + 1750 = 3250$ ; B 应分得  $1000 + \frac{1}{2} \times 3500 = 1000 + 1750 = 2750$ .

# 纳什讨价还价解



## 谈判中的影响力 — 不可替代性

- ▶ 如果市场上还有一家画廊 C, 若 A 交给画廊 C 卖, 可得  $V' = 5000$ .
- ▶ 若画廊 C 干别的事, 可得  $c = 500$ .
- ▶ AB 又该怎么分利?
- ▶ AB 合作中 A 的边际贡献是  $V - a - b = 3500$ .
- ▶ 若 AB 不合作, 则 AC 合作, 因为 B 的存在, C 的边际贡献为 0, A 拿走所有剩余  $V' - c$ . 即 A 的市场价值不是  $a$  而是  $V' - c$ .
- ▶ 所以, AB 合作中 B 的边际贡献是
$$V - (V' - c) - b = 6000 - (5000 - 500) - 1000 = 500.$$
- ▶ A 的边际贡献占总边际贡献的  $\frac{3500}{3500+500} = \frac{7}{8}$ , B 占  $\frac{1}{8}$ .
- ▶ A 应分得:  $1500 + \frac{7}{8} \times 3500 = 4562.5$ .
- ▶ B 应分得:  $1000 + \frac{1}{8} \times 3500 = 1437.5$ .

**Remark:** 大牌影星天价片酬.

## 腐败 vs 信息

- ▶ 腐败的深层根源: 信息不对称;
- ▶ 特别是事后的信息不对称: 一方当事人的行为不能被另一方观察到;
- ▶ 研究行为信息不对称的理论叫“委托-代理”理论或道德风险理论.

### 委托-代理关系

- ▶ 法律上的委托 - 代理关系: 如果甲乙两人达成一个协议, 甲将做某事的权利交给乙, 甲为委托人, 乙为代理人.
- ▶ 代理人对委托人的责任: (1) 没有许可, 不能再代理; (2) 不能把自己放在与委托人利益冲突的地位; (3) 保密责任和诚信责任.
- ▶ 委托人对代理人的责任: (1) 补偿责任. 委托人给代理人补偿报酬; (2) 免除法律责任. 委托人要为代理人的行为承担法律责任; (3) 留置权. 如果委托人给代理人的补偿没有到位, 代理人有权滞留委托人的财产.
- ▶ 经济上的委托 - 代理关系要宽松很多: 只要一方行为影响另一方的利益, 就有委托 - 代理关系. 有私人信息的一方是代理人, 没有私人信息的称为委托人.



## 委托-代理问题

- ▶ 委托人与代理人可能的利益冲突：对委托人最优的选择不一定是对代理人最优的选择。
- ▶ 如果委托人能观察到代理人的行为，则可以通过强制性合同约定约束代理人的行为。
- ▶ 即使不能完全观察到代理人的行为，如果代理人不害怕风险，“承包制”可以使代理人成为完全的风险承担者。
- ▶ 但如果代理人承担责任的能力有限，“承包制”没有可行性。

# 对代理人的激励机制的设计

- ▶ 保险与激励的冲突
  - ▶ 最优风险分担: 如果委托人是风险中性的, 代理人是风险规避的, 风险应该完全由委托人承担, 代理人拿固定报酬.
  - ▶ 最优激励: 代理人应该承担完全风险.
  - ▶ 这就产生了保险与激励的冲突.
  - ▶ 最优激励合同要在保险与激励之间求得平衡.
    - 汽车的部分保险 (如 80%).
- ▶ 激励的强度
  - ▶ 代理人的边际生产率越高, 激励应该越强.
  - ▶ 代理人的产出的不确定性越大, 或测度越困难, 激励应该越弱.
  - ▶ 代理人越风险规避, 激励应该越弱.
  - ▶ 代理人对激励的反应程度: 反应越强, 激励应该越强.
- ▶ 相对业绩比较有助于改进激励, 但也可能导致代理人之间合谋或相互拆台.
- ▶ 论功行赏 vs 任人唯贤
  - 论功行赏可能导致每个人都被晋升到他不能胜任的位置
- ▶ 多重任务下的激励: 大学教学 + 科研

# 政府官员的激励

- ▶ 很多很多委托人;
- ▶ 多项任务;
- ▶ 业绩难以度量, 投入也不容易度量;
- ▶ 所以, 政府官员难以激励, 只能以监督为主.
- ▶ 但监督是不完全的, 是有成本的.
- ▶ 权利越大, 越难监督.
- ▶ “把权力关进笼子”. 民主、法治.

# 官员腐败问题

- ▶  $W$ : 官员工资.
- ▶  $B(q)$ : 权力租金, 即官员在位置上可能收受的贿赂, 也可看作不腐败的机会成本. 一般来说, 权力  $q$  越大, 权力租金越高.
- ▶  $p$ : 腐败行为被发现暴露的概率.
- ▶  $F$ : 对腐败的处罚.
- ▶  $U$ : 政府外的保留效用.
- ▶  $\alpha$ : 官员的羞耻感或脸皮厚度.
- ▶ 官员腐败的期望收益

$$(1 - p)(W + B(q)) + p(U - \alpha F)$$

- ▶ 官员不腐败的条件:

$$W \geq \frac{1 - p}{p} B(q) + U - \alpha F$$

- ▶ 如何控制腐败? 提高  $p, F, W, \alpha$ , 减少  $q$ .

# Contents

- 1. Introduction
- 2. 逻辑与论证
- 3. 形而上学
- 4. 认识论
- 5. 伦理学
- 6. 美学
- 7. 科学哲学
- 8. 心灵哲学
- 9. 语言哲学
- 10. 博弈与社会
  - 个体理性与囚徒困境
  - 非对称信息与逆向选择
  - 机制设计与道德风险
  - 不完全信息博弈与声誉
  - 演化博弈与自发秩序
  - 民主投票与群体聚合

## 狐狸、权力与不完全信息

- ▶ 小女孩提着一篮子鸡蛋穿过树林.
- ▶ 喜欢抢鸡蛋吃的狐狸跳了出来: “我是狐狸!”
- ▶ 小女孩: “怎么证明你是狐狸?”
- ▶ 狐狸: “我有厚厚的皮毛.”
- ▶ 小女孩: “兔子也有厚厚的皮毛.”
- ▶ 狐狸: “我有毛茸茸的尾巴.”
- ▶ 小女孩: “松鼠也有毛茸茸的尾巴.”
- ▶ 狐狸一直试图证明自己, 不知不觉跟着小女孩走出了树林.
- ▶ 一只猎犬经过吓跑了狐狸.
- ▶ 狐狸边跑边喊, “不信你问猎犬, 我真的是狐狸!”
- ▶ 小女孩: “我知道, 我早就知道.”

|     | 攻击     | 不攻击  |
|-----|--------|------|
| 防卫  | -2, -2 | 0, 0 |
| 不防卫 | -1, 1  | 0, 0 |

Table: 与狐狸博弈

|     | 攻击    | 不攻击  |
|-----|-------|------|
| 防卫  | 0, -2 | 0, 0 |
| 不防卫 | -1, 1 | 0, 0 |

Table: 与兔子/松鼠博弈

**Remark:** 权力需要被认可, 如果得不到认可, 权力也将不复存在. 如果有人试图用权力吓唬你, 你应该提出质疑, 让对方承担举证的责任.

## 声誉的积累

$$\begin{aligned} P(\text{君子} \mid \text{好事}) &= \frac{P(\text{君子} \wedge \text{好事})}{P(\text{好事})} \\ &= \frac{P(\text{好事} \mid \text{君子})P(\text{君子})}{P(\text{好事} \mid \text{君子})P(\text{君子}) + P(\text{好事} \mid \neg \text{君子})P(\neg \text{君子})} \end{aligned}$$

- ▶ 人不知而不愠, 不亦君子乎
- ▶ 勿以善小而不为, 勿以恶小而为之
- ▶ 狼来了
- ▶ 烽火戏诸侯
- ▶ “伪君子” 为什么更可恨?

# Contents

- 1. Introduction
- 2. 逻辑与论证
- 3. 形而上学
- 4. 认识论
- 5. 伦理学
- 6. 美学
- 7. 科学哲学
- 8. 心灵哲学
- 9. 语言哲学
- 10. 博弈与社会
  - 个体理性与囚徒困境
  - 非对称信息与逆向选择
  - 机制设计与道德风险
  - 不完全信息博弈与声誉
  - 演化博弈与自发秩序
  - 民主投票与群体聚合




## 演化稳定策略 Evolutionarily Stable Strategy

- ▶ 静态视角：一个特定的行为模式被称为是演化稳定的，如果它的种群不能被变异所入侵，或者说，任何偏离行为模式的个体具有更低的生存能力，种群将会恢复到原来的状态。
- ▶ 动态视角：假定初始状态存在多样的行为模式，随着时间的推移，如果某个特定的行为模式能逐步主导整个种群，这个特定的行为模式就是演化稳定的。

## 演化博弈 — 婚姻博弈

|     | 物质型  | 感情型  |
|-----|------|------|
| 物质型 | 1, 1 | 0, 0 |
| 感情型 | 0, 0 | 2, 2 |



- ▶ 假定总人口中, 物质型的比例为  $x$ , 感情型的比例为  $1 - x$ .
- ▶ 对任何一个个体而言, 物质型的期望效用:  $x1 + (1 - x)0 = x$ .
- ▶ 感情型的期望效用:  $x0 + (1 - x)2 = 2(1 - x)$ .
- ▶ 如果  $x > 2/3$ , 物质型更适合生存, 将演化成为稳定均衡.
- ▶ 如果  $x < 2/3$ , 感情型更适合生存, 将演化成为稳定均衡.
- ▶ 如果  $x = 2/3$ , 两类人有同样的适应性, 但此二元均衡是非稳定的.

## 演化博弈 — 鹰鸽博弈

|   | 鹰      | 鸽                          |
|---|--------|----------------------------|
| 鹰 | -1, -1 | 1, 0                       |
| 鸽 | 0, 1   | $\frac{1}{2}, \frac{1}{2}$ |

- ▶ 假定鹰派的比例是  $x$ , 鸽派的比例是  $1 - x$ .
- ▶ 鹰派的效用:  $-1x + 1(1 - x) = 1 - 2x$ .
- ▶ 鸽派的效用:  $0x + \frac{1}{2}(1 - x) = \frac{1}{2}(1 - x)$ .
- ▶ 如果  $x < 1/3$ , 鹰派占优势, 不稳定.
- ▶ 如果  $x > 1/3$ , 鸽派占优势, 不稳定.
- ▶ 如果  $x = 1/3$ , 同样的适应性, 稳定.
- ▶ 如果初始人口由单一类型构成, 另一类型可以成功入侵, 直到均衡.
- † 两个纯策略均衡: (鹰、鸽), (鸽、鹰); 一个混合均衡:  $(1/3, 2/3)$
- △ 假定存在某种显性的标记机制: 在博弈开始之前, 每个人收到一个信号:  $A$  或  $B$ ; 概率是  $1/2$ ; 信号完全负相关; 标记是公共知识.
- 1. 如果  $A$ , 选择“鹰”; 如果  $B$ , 选择“鸽”. 是 ESS.
- 2. 如果  $A$ , 选择“鸽”; 如果  $B$ , 选择“鹰”. 是 ESS.
- 3. 无论  $AB$ , 以  $1/3$  的概率选择“鹰”,  $2/3$  的概率选择“鸽”. 不是 ESS.

# 自发秩序与产权制度

- ▶ 社会秩序是所有人行为选择的结果, 但不是集体理性集中设计的结果, 而是自发演化的结果.
- ▶ 社会规范是演化稳定策略, 但不一定是帕累托最优的.
- ▶ 虽然不是集体理性集中设计的产物, 但“制度企业家”扮演了重要角色. (哲学王)
- ▶ 改变游戏规则, 进行制度创新. 创新意味着让人们用新的价值观念代替旧的价值观念、用新的行为方式代替旧的行为方式、用新的是非观和新的善恶观代替旧的是非观和旧的善恶观, 意味着我们要认同原来可能不认同的东西或不再认同我们原来认同的东西.  
— 儒家: “仁、义、礼、智、信”, “己所不欲勿施于人”, “以德报德, 以直报怨”, “君君臣臣父父子子”.
- ▶ 制度企业家面临的不确定性和风险挑战异于常人. 他们不能以“利”和“名”为目的, 买他们账的“客户”可能在遥远的未来.
- ▶ “自私的”基因 & 迷因 (meme)

# Contents

1. Introduction
2. 逻辑与论证
3. 形而上学
4. 认识论
5. 伦理学
6. 美学
7. 科学哲学
8. 心灵哲学
9. 语言哲学
10. 博弈与社会
  - 个体理性与囚徒困境
  - 非对称信息与逆向选择
  - 机制设计与道德风险
  - 不完全信息博弈与声誉
  - 演化博弈与自发秩序
  - 民主投票与群体聚合

# 群体聚合 Group Aggregation

## 提案:

- A. 大学教育应该免费.
- B. 人人都应该有上大学的权利.
- C. 政府应该增加在大学教育上的投入.

$$\frac{A \quad B}{C}$$

## 民意调查:

|      | A | B | C   |
|------|---|---|-----|
| 张三   | 1 | 1 | 1   |
| 李四   | 0 | 1 | 0   |
| 王五   | 1 | 0 | 0   |
| 群体聚合 | 1 | 1 | 1/0 |

**个体理性:** 直接对提案 C 进行投票, 个体自我一致.

**集体理性:** 先对理由 A, B 分别投票, 再推导结论 C.

**Remark:** 通过安排投票方式, 可以操纵选举结果.

# 孔多塞投票悖论

|    |                     |                             |                             |
|----|---------------------|-----------------------------|-----------------------------|
| 张三 | $a \succ b \succ c$ | $\xrightarrow{\text{多数原则}}$ | $a \succ b \succ c \succ a$ |
| 李四 | $b \succ c \succ a$ |                             |                             |
| 王五 | $c \succ a \succ b$ |                             |                             |

**Remark:** 如果你可以制定投票规则, 那么, 你想让谁胜出, 你可以通过“两两 PK”的方式让其胜出.


|      | $a \succ b$ | $b \succ c$ | $a \succ c$ |
|------|-------------|-------------|-------------|
| 张三   | 1           | 1           | 1           |
| 李四   | 0           | 1           | 0           |
| 王五   | 1           | 0           | 0           |
| 群体聚合 | 1           | 1           | 1/0         |

孔多塞投票的群体聚合

# 序贯多数投票

|    |                             |
|----|-----------------------------|
| 张三 | $a \succ b \succ c \succ d$ |
| 李四 | $b \succ c \succ d \succ a$ |
| 王五 | $c \succ d \succ a \succ b$ |

- ▶ 所有人都认为  $c \succ d$
- ▶  $d$  还能胜出吗?





# 投票制度

1. **相对多数法 (plurality method)**: 选民每人投一个候选人
2. **双选投票法 (vote-for-two method)**: 选民每人投两个候选人
3. **反相对多数法 (anti-plurality method)**: 选民每人投  $n - 1$  个候选人, 即投票剔除一个候选人
4. **绩点评分法 (GPA method)**: 选民对所有  $n$  个候选人进行排序
  - ▶ 第一名得  $n - 1$  分
  - ▶ 第二名得  $n - 2$  分
  - ▶ 倒数第二名得 1 分
  - ▶ 最后一名 0 分

GPA 得分最高者当选.

5. **排序选择法 (ranked-choice voting)**: 选民对所有  $n$  个候选人进行排序
  - 5.1 首轮计票时, 只计算选民的首选票. 如果有候选人获得过半数选票, 该候选人当选.
  - 5.2 如果没有候选人过半数, 就将票数最少的候选人淘汰, 把选择该候选人为首选的选票, 按次选票的候选人重新分配.
  - 5.3 重复第 2 步, 直到某个候选人获得过半数选票为止.

# 选举结果反映的究竟是民意还是选举方法的选择?

|       |                             |
|-------|-----------------------------|
| 2 个选民 | $a \succ b \succ c \succ d$ |
| 2 个选民 | $a \succ d \succ c \succ b$ |
| 2 个选民 | $c \succ b \succ d \succ a$ |
| 3 个选民 | $d \succ b \succ c \succ a$ |

Table: 9 个选民, 4 个候选人

- ▶ 根据“相对多数法”,  $a$  赢:  $a4 \succ d3 \succ c2 \succ b0$
- ▶ 根据“双选投票法”,  $b$  赢:  $b7 \succ d5 \succ a4 \succ c2$
- ▶ 根据“反相对多数法”,  $c$  赢:  $c9 \succ b7 = d7 \succ a4$
- ▶ 根据“绩点评分法”,  $d$  赢:  $d15 \succ b14 \succ c13 \succ a12$

## 当有候选人退出时会怎样?

|       |                             |
|-------|-----------------------------|
| 3 个选民 | $a \succ c \succ d \succ b$ |
| 6 个选民 | $a \succ d \succ c \succ b$ |
| 3 个选民 | $b \succ c \succ d \succ a$ |
| 5 个选民 | $b \succ d \succ c \succ a$ |
| 2 个选民 | $c \succ b \succ d \succ a$ |
| 5 个选民 | $c \succ d \succ b \succ a$ |
| 2 个选民 | $d \succ b \succ c \succ a$ |
| 4 个选民 | $d \succ c \succ b \succ a$ |

Table: 30 个选民, 4 个候选人

- ▶ 根据“相对多数法”,  $a$  赢:  $a9 \succ b8 \succ c7 \succ d6$
- ▶ 如果  $d$  退出:  $c11 \succ b10 \succ a9$
- ▶ 如果  $c$  退出:  $d11 \succ b10 \succ a9$
- ▶ 如果  $b$  退出:  $d11 \succ c10 \succ a9$
- ▶ 如果  $a$  退出:  $d12 \succ c10 \succ b8$
- ▶ 根据“绩点评分法”,  $d$  赢:  $d58 \succ c54 \succ b41 \succ a27$
- ▶ 根据“排序选择法”,  $c$  赢:  $c20 \succ b10$

# Arrow's Impossibility Theorem

## Theorem (Arrow's Impossibility theorem)

*In an election with candidates  $\geq 3$ , any voting system that is unanimous and independence of irrelevant alternatives must be a dictatorship!*

- ▶ unanimous: if everyone agrees, consensus decides the outcome
- ▶ independence of irrelevant alternatives: a voter can't move  $a$  above  $b$  by lying about how they feel about  $c$
- ▶ nondictatorship: no single voter gets to decide the outcome

## 对无关选项独立性 IIA 的质疑

| 排序 | 张三  | 李四  | 王五  | 赵六  |
|----|-----|-----|-----|-----|
| 1  | $x$ | $x$ | $a$ | $a$ |
| 2  | $a$ | $a$ | $b$ | $b$ |
| 3  | $b$ | $b$ | $y$ | $y$ |
| 4  | $y$ | $y$ | $x$ | $x$ |

| 排序 | 张三  | 李四  | 王五  | 赵六  |
|----|-----|-----|-----|-----|
| 1  | $a$ | $a$ | $y$ | $y$ |
| 2  | $b$ | $b$ | $a$ | $a$ |
| 3  | $x$ | $x$ | $b$ | $b$ |
| 4  | $y$ | $y$ | $x$ | $x$ |

- ▶ 在两个表中,  $x$  和  $y$  的相对排序是一样的. 张三和李四偏好  $x \succ y$ , 王五和赵六偏好  $y \succ x$ .
- ▶ 直观上, 表 1 中偏好  $x \succ y$  的人比偏好  $y \succ x$  的人的“感受更为强烈”; 表 2 则相反. 我们可能会说, 表 1 中  $x \succ y$  是有道理的, 而表 2 中  $y \succ x$  是有道理的.
- ▶ IIA 要求两表中社会对  $x$  和  $y$  的偏好一样: 要么  $x \succ y$ , 要么  $y \succ x$ .

# 社会选择理论 Social Choice Theory

- ▶ 计算社会选择理论: 用计算复杂性防止坏情况的发生
- ▶ 用逻辑做投票协议验证
  - ▶ 隐私性: 没有别人能知道你投的是谁
  - ▶ 无收据性: 你不能证明给别人你投了特定人的票
  - ▶ 可核查性: 你自己能检查你的票是不是被算进去了
  - ▶ 公平性: 之前投票的部分结果不会影响之后投票的结果

Thank 

# References I

- [Aks+26] Vitaly Aksenov et al. *Compression is all you need: Modeling Mathematics*. 2026. arXiv: 2603.20396 [cs.AI]. URL: <https://arxiv.org/abs/2603.20396>.
- [MEB23] Matt MacDermott, Tom Everitt, and Francesco Belardinelli. *Characterising Decision Theories with Mechanised Causal Graphs*. 2023. arXiv: 2307.10987 [cs.AI].
- [Wat69] Satoshi Watanabe. "Knowing and guessing: a quantitative study of inference and information". In: *New York: Wiley* (1969).
- [YS18] Eliezer Yudkowsky and Nate Soares. *Functional Decision Theory: A New Theory of Instrumental Rationality*. 2018. arXiv: 1710.05060 [cs.AI]. URL: <https://arxiv.org/abs/1710.05060>.



## References II

- [Zah26] Tom Zahavy. “Position: LLMs can’t jump”. In: *Forty-third International Conference on Machine Learning Position Paper Track*. 2026. URL: <https://openreview.net/forum?id=klU4737opt>.